

**PEMODELAN DEEP LEARNING BERBASIS GNN UNTUK REKOGNISI
KATA MELALUI GERAK BIBIR BAHASA INDONESIA**

Tugas Akhir
diajukan untuk memenuhi salah satu syarat memperoleh gelar sarjana
pada Program Studi S1 Sains Data
Direktorat Kampus Purwokerto
Universitas Telkom

2211110022
Muhammad Ihsan Prawira Hutomo



Universitas
Telkom

Program Studi Sarjana S1 Sains Data
Direktorat Kampus Purwokerto
Universitas Telkom
Purwokerto
2026

LEMBAR PERSETUJUAN

**Pemodelan Deep Learning Berbasis GNN untuk Rekognisi Kata melalui
Gerak Bibir Bahasa Indonesia**

*GNN-Based Deep Learning Modeling for Word Recognition on Indonesian
Lip Movement*

2211110022

MUHAMMAD IHSAN PRAWIRA HUTOMO

Tugas akhir ini telah diperiksa dan disetujui untuk diuji

Purwokerto, 22 Desember 2025

Menyetujui

Pembimbing I,

Pembimbing II,



Andi Prademon Yunus, ST.,
M.Sc. Eng., Ph.D.
NIP: 23930008



Aditya Dwi Putro W., S.Kom.,
M.Kom.
NIP: 17930052

Mengetahui

Ketua Program Studi
Sarjana S1 Sains Data,



Sudianto, S.Pd., M.Kom.
NIP: 24930008

LEMBAR PENGESAHAN

Pemodelan Deep Learning Berbasis GNN untuk Rekognisi Kata melalui
Gerak Bibir Bahasa Indonesia
*GNN-Based Deep Learning Modeling for Word Recognition on Indonesian Lip
Movement*

2211110022

Muhammad Ihsan Prawira Hutomo

Tugas akhir ini telah diterima dan disahkan untuk memenuhi sebagai syarat
memperoleh gelar pada Program Studi Sarjana S1 Sains Data
Direktorat Kampus Purwokerto
Universitas Telkom

Purwokerto, 20 Januari 2026

Menyetujui

Pembimbing I,



Andi Prademon Yunus, S.T., M.Sc.Eng., Ph.D

NIP: 23930008

Pembimbing II,



Aditya Dwi Putro W., S.Kom. M.Kom

NIP: 17930052

Penguji I,



Wahyu Andi Saputra, S.Pd., M.Eng

NIP: 20910009

Penguji II,



Diah Septiani, S.Kom., M.C.S.(AI)

NIP: 17930050

Ketua Program Studi
Sarjana S1 Sains Data,



Sudianto, S.Pd., M.Kom

NIP: 24930008

LEMBAR ORISINALITAS

Dengan ini saya, Muhammad Ihsan Prawira Hutomo, menyatakan sesungguhnya bahwa Tugas Akhir saya dengan judul “Pemodelan Deep Learning Berbasis GNN untuk Rekognisi Kata melalui Gerak Bibir Bahasa Indonesia” beserta dengan seluruh isinya merupakan hasil karya saya sendiri, dengan tidak melakukan penjiplakan yang tidak sesuai dengan etika keilmuan yang berlaku dengan masyarakat keilmuan, serta produk dari tugas akhir ini bukan merupakan hasil dari *Generative AI*. Saya siap menanggung risiko/sanksi yang diberikan jika di kemudian hari ditemukan pelanggaran terhadap etika keilmuan dalam Laporan Tugas Akhir, atau jika ada klaim dari pihak lain terhadap keaslian karya.

Purwokerto, 20 Januari 2026

Yang menyatakan



Muhammad Ihsan Prawira Hutomo

NIM: 2211110022

ABSTRAK

Visual Speech Recognition (VSR) atau *lip reading* merupakan teknologi krusial untuk membantu komunikasi pada penyandang gangguan pendengaran dan lingkungan bising. Namun, pendekatan konvensional berbasis piksel seperti CNN sering mengalami *overfitting* terhadap identitas subjek dan gagal melakukan generalisasi pada penutur baru. Penelitian ini mengusulkan pendekatan baru menggunakan *Graph Neural Network* (GNN) untuk memodelkan hubungan spasial-temporal titik *landmark* bibir pada Dataset IndoLR. Arsitektur hibrida yang dikembangkan, yaitu GIN-LSTM-Mamba, mengintegrasikan *Graph Isomorphism Network* (GIN) untuk ekstraksi fitur spasial, LSTM untuk dinamika temporal, dan *State Space Model* (Mamba) untuk efisiensi dependensi jangka panjang. Ekstraksi fitur dilakukan menggunakan MediaPipe *Face Mesh* pada 40 titik bibir dengan fitur geometris dan kinematik. Evaluasi dilakukan menggunakan skenario *Standard Split* dan *Leave-One-Subject-Out* (LOSO). Hasil eksperimen menunjukkan bahwa model GIN-LSTM-Mamba mencapai akurasi 97,84% pada tingkat kata dan 95,78% pada tingkat frasa dalam skenario *Standard Split*. Pada uji generalisasi (LOSO), model ini terbukti lebih robust dengan akurasi rata-rata 53,50% (Kata) dan 60,51% (Frasa), mengungguli *baseline* LRCN yang hanya mencapai akurasi 26,95% (Kata) dan 41,67% (Frasa). Analisis *Explainable AI* menggunakan GNNExplainer mengonfirmasi bahwa model memfokuskan atensi pada kontur bibir luar (*outer lips*) yang relevan secara anatomis.

Kata Kunci: Indonesia Lip Reading, *Visual Speech Recognition*, Graph Neural Network (GNN), Graph Isomorphism Network (GIN), Mamba

ABSTRACT

Visual Speech Recognition (VSR) or lip reading is a crucial technology for assisting communication for hearing-impaired individuals and in noisy environments. However, conventional pixel-based approaches such as CNNs often suffer from overfitting to subject identities and fail to generalize to new speakers. This study proposes a novel approach using Graph Neural Networks (GNN) to model the spatial-temporal relationships of lip landmarks on the IndoLR Dataset. The developed hybrid architecture, GIN-LSTM-Mamba, integrates Graph Isomorphism Network (GIN) for spatial feature extraction, LSTM for temporal dynamics, and Mamba State Space Model for efficient long-range dependency modeling. Feature extraction utilizes MediaPipe FaceMesh on 40 lip nodes with geometric and kinematic features. The evaluation was conducted using Standard Split and Leave-One-Subject-Out (LOSO) scenarios. Experimental results demonstrate that the GIN-LSTM-Mamba model achieves an accuracy of 97.84% for words and 95.78% for phrases in the Standard Split scenario. In the generalization test (LOSO), the model proved to be more robust with an average accuracy of 53.50% (Words) and 60.51% (Phrases), significantly outperforming the LRCN baseline which only reached 26.95% (Words) and 41.67%(Phrase). Explainable AI analysis using GNNExplainer confirmed that the model focuses attention on the anatomically relevant outer lip contours.

Keywords: Indonesia Lip Reading, Visual Speech Recognition, Graph Neural Network (GNN), Graph Isomorphism Network (GIN), Mamba

KATA PENGANTAR

Puji dan syukur penulis panjatkan ke hadirat Tuhan Yang Maha Esa, karena atas rahmat dan karunia-Nya penulis dapat menyelesaikan laporan Tugas Akhir ini dengan baik. Laporan Tugas Akhir ini disusun sebagai salah satu syarat untuk menyelesaikan pendidikan dan memperoleh gelar akademik pada Program Studi di Telkom University.

Penyusunan laporan Tugas Akhir ini tidak terlepas dari bantuan, bimbingan, serta dukungan dari berbagai pihak. Oleh karena itu, pada kesempatan ini penulis menyampaikan ucapan terima kasih yang sebesar-besarnya kepada:

1. Tuhan Yang Maha Esa, atas limpahan rahmat dan karunia-Nya sehingga penulis diberikan kelancaran dalam menyelesaikan Tugas Akhir ini.
2. Kedua orang tua penulis, yang senantiasa memberikan doa, dukungan moral, motivasi, dan kasih sayang selama proses perkuliahan hingga penyusunan Tugas Akhir.
3. Bapak Prof. Dr. Suyanto, S.T., M.Sc., selaku Rektor Telkom University, atas kebijakan dan fasilitas pendidikan yang telah diberikan.
4. Ibu Dr. Tenia Wahyuningrum, S.Kom., M.T., selaku Direktur Telkom University Kampus Purwokerto, atas dukungan dan arahan dalam menunjang proses akademik penulis.
5. Bapak Sudianto, S.Pd., M.Kom., selaku Ketua Program Studi, atas bimbingan, arahan, dan dukungan akademik yang diberikan selama masa studi.
6. Bapak Andi Prademon Yunus, S.T., M.Sc. Eng., Ph.D., selaku Dosen Pembimbing I, atas seluruh bimbingan, arahan, serta ilmu yang sangat berharga. Penulis juga mengucapkan terima kasih atas kesediaan beliau meluangkan waktu untuk hadir dalam pertemuan bimbingan rutin serta dukungan fasilitas server komputasi yang sangat membantu kelancaran penyusunan Tugas Akhir ini.
7. Bapak Aditya Dwi Putro W., S.Kom., M.Kom., selaku Dosen Pembimbing II, atas bimbingan, masukan, serta kesediaan beliau dalam memberikan

konsultasi untuk membantu penyelesaian berbagai permasalahan selama penyusunan Tugas Akhir.

8. Teman-teman serta seluruh pihak terkait, baik secara individu maupun lembaga, yang telah memberikan bantuan, dukungan moral, motivasi, serta kerja sama yang tidak dapat penulis sebutkan satu per satu.

Penulis menyadari bahwa laporan Tugas Akhir ini masih memiliki keterbatasan dan kekurangan. Oleh karena itu, kritik dan saran yang membangun sangat diharapkan. Semoga laporan Tugas Akhir ini dapat memberikan manfaat bagi pembaca dan pengembangan ilmu pengetahuan.

Purwokerto, 9 Januari 2026

Penulis

DAFTAR ISI

LEMBAR PENGESAHAN	iii
LEMBAR ORISINALITAS	iv
ABSTRAK	v
ABSTRACT	vi
KATA PENGANTAR	vii
DAFTAR ISI	ix
DAFTAR GAMBAR	xii
DAFTAR TABEL	xiii
BAB I PENDAHULUAN	1
1.1. Latar Belakang	1
1.2. Rumusan Masalah	2
1.3. Tujuan Penelitian	3
1.4. Manfaat Penelitian	3
1.5. Batasan Masalah	4
BAB II LANDASAN TEORI	5
2.1. Tinjauan Pustaka	5
2.2. Landasan Teori	12
2.2.1. <i>Visual Speech Recognition</i> (VSR)	12
2.2.2. <i>Graph Extraction</i>	12
2.2.3. <i>Graph Neural Network</i> (GNN)	14
2.2.4. Arsitektur Populer <i>Graph Neural Network</i> (GNN)	15
2.2.5. <i>Convolution Neural Network</i> (CNN)	18
2.2.6. <i>Temporal Modeling</i>	19
2.2.7. <i>LSTM (Long Short-Term Memory)</i>	20
2.2.8. <i>Mamba SSM</i>	21
2.2.9. <i>Feature Engineering</i>	25
2.2.10. <i>LOSO</i>	25
2.2.11. Evaluasi Kinerja Model VSR	25
BAB III METODE PENELITIAN	30
3.1. Subjek dan Objek Penelitian	30

3.2.	Alat dan Bahan Penelitian	30
3.2.1.	Alat Penelitian	30
3.2.2.	Bahan Penelitian	30
3.3.	Diagram Alir Penelitian	31
3.3.1.	Identifikasi Masalah	32
3.3.2.	Studi Literatur	32
3.3.3.	<i>Data Collection</i>	33
3.3.4.	<i>Data Understanding</i>	33
3.3.5.	Statistik Deskriptif & Visualisasi Data	35
3.3.6.	<i>Landmark Extraction</i>	36
3.3.7.	<i>Graph Construction</i>	37
3.3.8.	<i>Speech-Level</i>	40
3.3.9.	<i>Feature Engineering</i>	40
3.3.10.	<i>Dataset Splitting</i>	46
3.3.11.	Modeling	49
3.3.12.	Explainable AI Menggunakan GNNExplainer	51
BAB IV	HASIL DAN PEMBAHASAN	53
4.1.	Hasil	53
4.1.1.	Statistik Deskriptif & Visualisasi Data	53
4.1.2.	<i>Landmark Extraction</i>	56
4.1.3.	<i>Graph Construction</i>	58
4.1.4.	<i>Feature Engineering</i>	58
4.1.5.	<i>Splitting</i>	59
4.1.6.	<i>Modeling</i>	59
4.1.7.	Hasil Eksperimen	60
4.1.8.	<i>Explainable AI</i> menggunakan GNNExplainer	69
4.2.	Pembahasan	72
4.2.1.	Analisis Efektivitas Representasi Tingkatan Fitur	72
4.2.2.	Analisis Evolusi Arsitektur Model	72
4.2.3.	Analisis Generalisasi dan <i>Robustness</i> (Standard vs LOSO)	73
4.2.4.	Komparasi dengan Pendekatan Berbasis Piksel (LRCN)	73

4.2.5. Analisis Interpretabilitas Fitur Bibir	74
BAB V KESIMPULAN DAN SARAN	75
5.1. Kesimpulan	75
5.2. Saran.....	76
DAFTAR PUSTAKA	78
LAMPIRAN.....	82

DAFTAR GAMBAR

Gambar 2. 1 <i>Landmark Detection</i> pada Wajah [19]	13
Gambar 2. 2 Ilustrasi Cara Kerja <i>Graph Neural Network</i> (GNN)	14
Gambar 2. 3 Ilustrasi Cara Kerja LSTM	20
Gambar 2. 4 Arsitektur Mamba	22
Gambar 3. 1 Diagram Alir Penelitian	31
Gambar 3. 3 Koordinat <i>Node</i> yang Dinormalisasikan	41
Gambar 3. 4 Visualisas Fitur Geometris (F1)	42
Gambar 3. 5 Diagram Cara Kerja <i>Standard Split</i>	47
Gambar 3. 6 Diagram Cara Kerja LOSO <i>Split</i>	48
Gambar 4. 1 Distribusi Jumlah Video Setiap Subjek	53
Gambar 4. 2 Jumlah video Setiap Kelas untuk Kategori Kata (kiri) dan Frasa (Kanan)	55
Gambar 4. 3 Visualisasi Ekstraksi <i>Landmark</i> pada 8 subjek	57
Gambar 4. 4 Tahapan Pemrosesan Data Visual	57
Gambar 4. 5 <i>Training History Model Spatial Only</i> Level Kata	62
Gambar 4. 6 <i>Training History Model Spatial Only</i> Level Frasa	62
Gambar 4. 7 <i>Training History Model Hybrid (Spatial-Temporal)</i> Level Kata	64
Gambar 4. 8 <i>Training History Model Hybrid (Spatial-Temporal)</i> Level Frasa	64
Gambar 4. 9 <i>Training History (Loss dan Accuracy)</i> Model GIN-LSTM-MAMBA Terbaik pada Level Kata F2 (Atas) dan Level Frasa F1 (Bawah).	66
Gambar 4. 10 Visualisasi <i>Node Importance</i>	70
Gambar 4. 11 Visualisasi <i>Edge Importance</i>	71

DAFTAR TABEL

Tabel 2. 1 Ringkasan Penelitian Terdahulu	7
Tabel 4. 1 Distribusi Jumlah Video per Kelas	54
Tabel 4. 2 Statistik Durasi Video (detik)	55
Tabel 4. 3 Persebaran Data menggunakan <i>Standard Splitting</i>	59
Tabel 4. 4 Konfigurasi Global yang digunakan Tiap Model	60
Tabel 4. 5 Ikhtisar Arsitektur Setiap Model	60
Tabel 4. 6 Hasil Evaluasi <i>Baseline Spatial Modes (Split Standard)</i>	61
Tabel 4. 7 Hasil Evaluasi <i>Hybrid Spatial-Temporal Models (Standard Split)</i>	63
Tabel 4. 8 Hasil Evaluasi Model GIN-LSTM-MAMBA	65
Tabel 4. 9 <i>Classification Report</i> untuk Level Kata pada <i>Split Standard</i>	66
Tabel 4. 10 <i>Classification Report</i> untuk Level Frasa pada <i>Standard Split</i>	67
Tabel 4. 11 Rata-rata Performa Model tiap Subjek pada Skenario LOSO	68
Tabel 4. 12 Perbandingan GIN-LSTM-Mamba vs LRCN (<i>Standard Split & LOSO</i>)	69

BAB I

PENDAHULUAN

1.1. Latar Belakang

Komunikasi merupakan aspek fundamental dalam kehidupan manusia yang tidak hanya bergantung pada suara, tetapi juga pada isyarat visual seperti ekspresi wajah dan gerakan bibir [1]. Dalam kondisi ideal, informasi disampaikan secara simultan melalui saluran audio dan visual. Namun, pada situasi tertentu seperti lingkungan yang bising, rekaman video yang rusak audionya, atau individu dengan gangguan pendengaran ketergantungan terhadap sinyal visual menjadi sangat penting. Dalam konteks inilah muncul kebutuhan akan sistem pengenalan gerak bibir, atau dikenal sebagai *Visual Speech Recognition* (VSR).

Bagi penyandang gangguan pendengaran, kemampuan membaca gerak bibir menjadi metode penting dalam memahami percakapan. Di Indonesia, berdasarkan estimasi Kementerian Sosial, terdapat lebih dari 5,1 juta penyandang disabilitas, dengan proporsi signifikan mengalami gangguan pendengaran [2]. Hal ini memperkuat urgensi pengembangan teknologi VSR dalam Bahasa Indonesia, baik sebagai alat bantu komunikasi inklusif maupun sebagai solusi alternatif untuk pemrosesan informasi dalam video yang tidak memiliki audio.

Penelitian dalam bidang VSR telah berkembang pesat, terutama berkat kemajuan dalam deep learning. Pendekatan konvensional yang paling umum digunakan adalah arsitektur *Convolutional Neural Network* (CNN) untuk mengekstraksi fitur visual, serta model temporal seperti *Long Short-Term Memory* (LSTM) atau *Gated Recurrent Unit* (GRU) untuk memodelkan urutan gerakan bibir dari *frame* video. Arsitektur seperti LipNet, 3D-CNN, dan *hybrid* CNN-LSTM telah menunjukkan performa tinggi dalam beberapa *benchmark* dataset. Namun, sebagian besar penelitian tersebut berfokus pada bahasa asing seperti Arab Inggris, Mandarin, atau Yunani [3], [4], [5], [6], [7]

Di sisi lain, ketersediaan dataset untuk penelitian VSR dalam Bahasa Indonesia masih menjadi tantangan tersendiri. Namun, studi ini memanfaatkan dataset IndoLR, yang merupakan dataset publik pertama yang dirancang dengan mempertimbangkan kelengkapan variasi delapan jenis bentuk bibir yang berbeda.

Dataset IndoLR menyediakan sampel data yang komprehensif baik pada level kata (10 kategori) maupun level frasa (4 kategori) yang merefleksikan kata-kata umum dalam komunikasi sehari-hari. Dengan total 2.400 sampel video kata dan 1.600 sampel video frasa, dataset ini menawarkan representasi visual yang lebih kaya untuk mengakomodasi variabilitas bentuk bibir pembicara [3].

Terkait karakteristik dataset IndoLR yang memuat delapan jenis bentuk bibir berbeda, penelitian sebelumnya telah menerapkan pendekatan *Long-Term Recurrent Convolutional Network* (LRCN) [3]. Studi ini memanfaatkan MediaPipe *Face Mesh* untuk mendeteksi *landmark* bibir secara presisi untuk ekstraksi fitur, yang kemudian diproses melalui lapisan konvolusi (CNN). Hasil eksperimen menunjukkan efektivitas yang signifikan, di mana model LRCN-3Conv berhasil mencapai akurasi sebesar 95,42% pada pengujian tingkat kata dan 95,63% pada tingkat frasa.

Salah satu pendekatan yang belum banyak dieksplorasi dalam konteks Bahasa Indonesia adalah penggunaan *Graph Neural Network* (GNN). Berbeda dengan CNN yang mengolah data dalam bentuk *grid* piksel, GNN memungkinkan pemodelan relasi antar titik-titik penting (*landmark*) pada wajah dalam bentuk graf, di mana simpul (*node*) mewakili titik bibir dan sisi (*edge*) menggambarkan hubungan spasial atau temporal antar titik tersebut[8]. Pendekatan ini sebelumnya telah digunakan secara luas dalam domain lain seperti pengenalan ekspresi wajah [9] dan pemodelan pose manusia (*human pose estimation*) [10].

Berdasarkan alasan tersebut, penelitian ini diarahkan untuk mengeksplorasi potensi pendekatan berbasis GNN dalam pengenalan kata Bahasa Indonesia dari gerakan bibir menggunakan dataset IndoLR. Dengan memanfaatkan fitur *landmark* dari wajah sebagai representasi graf, pendekatan ini diharapkan dapat meningkatkan akurasi sistem VSR dan menjadi alternatif efektif pada kondisi audio yang rusak atau tidak tersedia.

1.2. Rumusan Masalah

Sebagian besar penelitian VSR Bahasa Indonesia masih mengandalkan pendekatan konvensional seperti CNN dan LSTM yang memiliki keterbatasan

dalam menangkap struktur spasial dan temporal secara eksplisit. Di sisi lain, pendekatan berbasis *Graph Neural Network* (GNN) mulai menunjukkan potensi tinggi dalam pemodelan hubungan antar *landmark* wajah, tetapi masih jarang diterapkan dalam konteks VSR.

Berdasarkan hal tersebut, permasalahan yang ingin dijawab dalam penelitian ini adalah:

1. Bagaimana merancang dan membangun model *Visual Speech Recognition* (VSR) berbasis *Graph Neural Network* (GNN) yang mampu menangkap hubungan spasial dan temporal antar titik-titik *landmark* wajah untuk mengenali kata Bahasa Indonesia dari video?
2. Bagaimana performa model GNN yang diusulkan dibandingkan dengan pendekatan konvensional (CNN) yang pernah digunakan pada dataset IndoLR?

1.3. Tujuan Penelitian

Penelitian ini bertujuan untuk membangun dan mengevaluasi model VSR berbasis *Graph Neural Network* (GNN) guna mengenali kata dalam Bahasa Indonesia dari video pada dataset IndoLR. Pendekatan GNN digunakan untuk memodelkan hubungan spasial-temporal antar titik *landmark* wajah secara lebih eksplisit, sebagai alternatif dari pendekatan konvensional berbasis CNN atau LSTM.

Secara khusus, penelitian ini ditujukan untuk:

1. Mengembangkan arsitektur *deep learning* berbasis GNN untuk pengenalan kata dari gerakan bibir dengan menerapkan ekstraksi fitur *landmark* wajah sebagai representasi graf untuk input model.
2. Mengevaluasi performa model terhadap subset pengujian IndoLR dan membandingkannya dengan baseline terdahulu dan menilai potensi GNN dalam menangani variasi visual pada data video alami.

1.4. Manfaat Penelitian

Penelitian ini diharapkan memberikan kontribusi baik dari sisi akademis maupun praktis, terutama dalam konteks pengembangan teknologi VSR yang

mendukung kebutuhan lokal dan kelompok disabilitas. Manfaat yang dapat diambil dari penelitian ini antara lain:

1. Kontribusi Awal VSR Bahasa Indonesia Berbasis GNN dengan menjadi salah satu studi pertama yang menerapkan GNN pada Bahasa Indonesia.
2. Perbandingan Empiris antara GNN dan CNN menyediakan hasil eksperimen kuantitatif yang membandingkan pendekatan GNN dengan metode *baseline* konvensional.
3. Penerapan Interpretabilitas pada GNN dengan mengetahui fitur penting dalam klasifikasi gerakan bibir menggunakan pendekatan interpretabilitas seperti GNNExplainer.

1.5. Batasan Masalah

Penelitian ini memiliki ruang lingkup yang telah ditentukan secara eksplisit untuk menjaga fokus, keterukuran, dan ketercapaian target dalam batas waktu serta sumber daya yang tersedia. Batasan ini disusun guna menghindari perluasan topik ke luar cakupan metodologi dan teknis yang telah dirumuskan. Batasan-batasan tersebut adalah sebagai berikut:

1. Fokus pada Pengklasifikasian Kata Tunggal (*Word-Level*) & Frasa (*Phrase Level*).
2. Penggunaan Dataset IndoLR dengan 4.147 video untuk Kata Tunggal dan 1654 video untuk frasa dengan 8 variasi bentuk bibir.
3. Evaluasi Berbasis Akurasi Klasifikasi meskipun *precision*, *recall*, dan *F1-score* juga akan dilaporkan.
4. Skenario *Visual-Only* tanpa penggunaan data suara dalam pelatihan maupun pengujian.

BAB II

LANDASAN TEORI

2.1. Tinjauan Pustaka

Penelitian ini menggunakan metode *Systematic Literature Review* (SLR) untuk mengevaluasi perkembangan teknologi *visual speech recognition*, khususnya dalam konteks Bahasa Indonesia dan penggunaan *Deep Learning* [11]. Literatur dikumpulkan dari Google Scholar, IEEE Xplore, dan ScienceDirect, menggunakan kata kunci seperti “*Lip Reading*”, “*Indonesia Lip Reading*”, “*Visual Speech Recognition*”, “*Graph Lip Reading*” dan “*Deep Learning for Lip Reading*”. Artikel yang terpilih adalah yang terbit pada tahun 2020–2025 dan relevan dengan topik *visual speech recognition* berbasis *machine learning*.

Sebanyak 11 artikel terpilih melalui proses penyaringan dan dikelola menggunakan Mendeley. Temuan menunjukkan bahwa pendekatan CNN mendominasi untuk ekstraksi fitur visual, sementara keterbatasannya dalam menangkap informasi temporal diatasi dengan integrasi model temporal seperti LSTM, GRU, atau TCN[5], [12], [13].

Model Transformer mulai digunakan namun hasilnya belum stabil dan cenderung rendah dalam kasus VSR [14]. *Graph Neural Network* (GNN) masih jarang digunakan dalam *lip reading*, meskipun studi menunjukkan potensinya tinggi untuk memahami hubungan spasial antar bagian wajah[8], [9].

Faktor lain yang mempengaruhi performa model adalah bahasa dataset, resolusi video, dan jumlah data. Model yang dilatih pada bahasa Inggris memiliki performa tinggi namun menurun saat diterapkan pada bahasa lain seperti Mandarin [7]. Dataset besar dan resolusi optimal tetap penting, meskipun *preprocessing* yang baik dapat menjaga performa pada resolusi.

Dalam pemodelan kata, penggunaan *landmark* wajah dan mekanisme *attention* menjadi semakin penting [3]. GNN yang memanfaatkan struktur wajah berdasarkan *landmark* telah terbukti meningkatkan akurasi pada tugas ekspresi wajah dan dapat diterapkan pada *lip reading* [9], [15]. Integrasi audio-visual juga terbukti meningkatkan akurasi model, namun pada VSR murni, pendekatan visual tetap menjadi fokus utama terutama dalam kondisi bising.

Terdapat kesenjangan penelitian signifikan dalam penerapan GNN untuk *lip reading* dalam Bahasa Indonesia. Hingga saat ini, belum ada penelitian terdokumentasi yang mengeksplorasi pendekatan ini, meskipun tersedia dataset seperti IndoLR yang memungkinkan eksplorasi tersebut.

Tabel 2. 1 Ringkasan Penelitian Terdahulu

Nomor	Judul dan Penulis, tahun.	Rumusan Masalah	Metode,Data	Simpulan Penelitian/ Hasil	Perbedaan dengan Penelitian
1	<i>Indonesian Lip-Reading Detection and Recognition Based on Lip Shape Using Face Mesh and Long-Term Recurrent Convolutional Network</i> , Abas Setiawan, 2024 [3]	Sebagai bentuk komunikasi dasar manusia yaitu bicara, terdapat kendala dalam menginterpretasikan sebuah pembicaraan ketika suara dalam keadaan tertentu terdengar jelas dan juga sebagai alat bantu komunikasi bagi penderita gangguan pendengaran.	<i>Long-Term Recurrent Convolutional Network</i> , Dataset IndoLR(Terdiri dari 4147 video kata dan 1654 video frasa dengan resolusi 640x480 piksel) dengan memerhatikan subjek dengan bentuk bibir yang berbeda.	Model LRCN yang dipakai mendapat akurasi 95.42% yang unggul dari beberapa model yang digunakan, penggunaan MediaPipe FaceMesh efektif dalam segmentasi bibir, dan pembuatan Dataset IndoLR menjadi Dataset Open pertama dalam bahasa Indonesia dengan beragam bentuk bibir tapi dengan kelas berjumlah 10 kata & 4 frasa.	Mengusulkan perbedaan metode dalam ekstraksi fitur bibir dan juga pemodelan yaitu GNN daripada model berbasis CNN.
2	<i>Recognizing Indonesian Words Based on Visual Cues of Lip Movement Using Deep Learning</i> , Griffani Megiyanto Rahmatullah, et al, 2025 [4]	Dataset <i>lipreading</i> dalam Bahasa Indonesia masih sangat terbatas, sehingga diperlukan alat untuk menghasilkan dataset <i>lipreading</i> secara otomatis.	Metode yang digunakan adalah <i>Advanced Residual Network</i> (ARN) dengan ResNet-34, Channel Spatial Attention (CSA), Bi-GRU, dan Mamba (BGM) untuk pemodelan urutan. Dilengkapi modul keputusan kata dan dilakukan hyperparameter tuning.	Model menghasilkan akurasi sebesar 60,51%, yang menunjukkan adanya potensi untuk pengembangan lebih lanjut.	Perbedaan pada dataset yang digunakan dan pemodelan yang dipilih yaitu GNN daripada model berbasis CNN
3	<i>Adaptive Semantic-Spatio-Temporal Graph Convolution Network (ASST-GCN) for Lip Reading</i> , ChangChong Sheng, 2021[9]	Metode <i>deep learning</i> saat ini untuk <i>lip reading</i> hanya fokus pada penampilan dan informasi aliran optik, tidak sepenuhnya	Menggunakan model ASST-GCN dengan dua <i>visual flow</i> depan untuk menggabungkan informasi penampilan dan kontur mulut. Dataset LRW dan LRS2 berbahasa inggris.	Metode yang memperhatikan spasial temporal serta penampilan dan kontur mulur yang diajukan memiliki akurasi 85.7% mengungguli metode	Pengujian model dilakukan pada 2 dataset untuk melakukan benchmark tidak spesifik pada

Nomor	Judul dan Penulis, tahun.	Rumusan Masalah	Metode,Data	Simpulan Penelitian/ Hasil	Perbedaan dengan Penelitian
		memanfaatkan karakteristik gerakan bibir. Deformasi kontur mulut yang penting untuk pengenalan kata sering diabaikan sehingga perlu dikembangkan model yang dapat belajar dari informasi spasial dan temporal dengan penampilan dan kontur mulut.		<i>lip reading</i> terkini pada benchmark yang dilakukan pada skala besar.	dataset berbahasa tertentu.
4	<i>Lip-Reading Advancements: A 3D Convolutional Neural Network/Long Short-Term Memory Fusion for Precise Word Recognition</i> , Themis Exarcos et.al, 2024[5]	Kurangnya dataset <i>lip reading</i> untuk bahasa Yunani, serta tantangan dalam mengenali kata dengan akurat dari gerakan bibir yang dipengaruhi oleh variasi pencahayaan, pola ucapan, dan karakteristik wajah individu.	Mengembangkan model <i>lip reading</i> yang efektif untuk bahasa Yunani dengan menggabungkan 3D CNN. Dataset MobLip dengan 55.275 gambar gerakan bibir dari 30 peserta yang mengucapkan kata-kata dalam bahasa Yunani. dan LSTM untuk pengenalan kata yang akurat.	Model mencapai akurasi hingga 87,5% dalam pengenalan kata. Personalisasi model untuk setiap peserta memberikan hasil yang lebih baik dibandingkan model umum. Penggunaan 3D CNN untuk fitur spasial dan LSTM untuk dinamika temporal menunjukkan efektivitas dalam mengatasi variasi pencahayaan & pola ucapan.	Menggunakan Dataset untuk Bahasa Yunani yang pengucapan dan kata yang berbeda dengan Bahasa Indonesia, serta model yang digunakan adalah 3D CNN.
5	<i>A Novel Machine Lip Reading Model</i> , Hongyang Huang et.al, 2021[14]	Melakukan metode Transformer yang belum pernah dilakukan pada kasus <i>lip reading</i> untuk menguji keefektifitas model.	Pretrained VGG16 untuk ekstraksi bibir dan Transfomer pada pemodelan <i>lip reading</i> . Dataset GRID, 33.000 sampel video 3 detik dengan frame rate 25fps.	Model mencapai akurasi rendah 45,81% menunjukkan Transformer belum cocok dan masih perlu perkembangan dalam pemodelannya.	Metode yang dilakukan yaitu Transformer dan dataset GRID yang menggunakan Bahasa Inggris.

Nomor	Judul dan Penulis, tahun.	Rumusan Masalah	Metode,Data	Simpulan Penelitian/ Hasil	Perbedaan dengan Penelitian
6	<i>Novel Algorithm Utilizing Deep Learning for Enhanced Arabic Lip Reading Recognition</i> , Doaa Sami Khafaga1 et.al, 2021[6]	Mengembangkan sistem pengenalan viseme real-time untuk membantu orang dengan gangguan pendengaran dan penggunaan dalam lingkungan bising.	Ekstraksi fitur bibir dengan viseme dan <i>deep-CNN</i> untuk pemodelan <i>lip reading</i> . Dataset <i>benchmark</i> SAVE berbahasa Arab dengan standar NTSC 30 frame per detik, serta file audio untuk validasi.	Penggunaan ekstraksi bibir <i>Viseme</i> dengan <i>deep CNN</i> setelah <i>fine tuning</i> mendapat akurasi 95.3%, hasil yang sangat tinggi dalam kasus <i>lip reading</i> .	Metode yang digunakan berbasis CNN dan Bahasa yang digunakan adalah Bahasa Arab.
7	<i>HLR-Net: A Hybrid Lip-Reading Model Based on Deep Convolutional Neural Networks</i> , Amany M. Sarhan et al., 2021[12]	Dengan diketahui kurang efektifnya arsitektur <i>sequence-to-sequence</i> sehingga mengusulkan metode Hybrid berbasis CNN menggabungkan fitur spasio temporal.	Ekstraksi bibir, lalu Normalisasi Frame, kemudian <i>Encoder</i> menggunakan <i>Inception</i> Layer, Preservasi Gradien, Bi-Gru kemudian dilakukan Decoder dengan <i>Attention Layer</i> dan CTC (<i>Connectionist Temporal Classification</i>). Dataset GRID Corpus (34 speaker, 34.000 kalimat, 28 jam rekaman video)	HLR-Net mengungguli <i>state-of-the-art</i> pada dataset yang sama dengan akurasi 83% pada level kata.	Metode yang digunakan serta Bahasa menggunakan dataset GRID Corpus berbahasa Inggris.
8	<i>Lip-reading with Densely Connected Temporal Convolutional Networks</i> , Pingchuan Ma et al., 2021 [7]	Arsitektur <i>Temporal Convolutional Network</i> (TCN) konvensional memiliki <i>receptive field</i> temporal yang jarang (<i>sparse</i>), yang dianggap kurang mampu menangkap variasi dinamis gerakan bibir sehingga mengusulkan pengembangan model	Model ini menggabungkan DC-TCN (FD dan PD) untuk pemrosesan temporal, SE Block untuk attention antar channel, serta 3D CNN dan ResNet-18 di front-end untuk ekstraksi fitur spasial-temporal. Dataset LRW berbahasa Inggris dan LRW-100 berbahasa Mandarin	Pada dataset LRW berbahasa Inggris didapatkan akurasi 88.36%, dan untuk LRW-100 berbahasa mandarin didapat akurasi 43.65%.	Pengembangan model yang dilakukan menggunakan CNN yang memiliki implementasi <i>Densely Connected</i> untuk menangani masalah temporal data, dan penelitian menguji 2 dataset secara terpisah untuk mendapatkan

Nomor	Judul dan Penulis, tahun.	Rumusan Masalah	Metode,Data	Simpulan Penelitian/ Hasil	Perbedaan dengan Penelitian
		DC-TCN dengan koneksi padat (<i>dense connections</i>) dan mekanisme perhatian (<i>attention</i>) untuk meningkatkan akurasi <i>lip-reading</i> kata terisolasi.			informasi keandalan model.
9	<i>Improved Lip-Reading Language using Gated Recurrent Units</i> , Zulfa et al., 2021 [13]	Metode konvensional (MFCC+LSTM dan CNN+LSTM) memiliki akurasi rendah dan waktu komputasi tinggi akibat kompleksitas LSTM. Tantangan tambahan yaitu variasi sudut kamera, intensitas cahaya, dan ketidakseimbangan data.	Wajah dan bibir dideteksi dari video, lalu fitur citra diekstraksi dengan CNN dan fitur audio dengan MFCC. Kedua fitur diklasifikasikan menggunakan GRU, kemudian hasilnya difilter untuk menghindari overfitting. Dataset <i>Lip Reading Sentences</i> (LRS) dengan variasi pencahayaan, sudut kamera, dan ketidakseimbangan data.	Akurasi 74.95% lebih tinggi daripada menggunakan LSTM dengan waktu pelatihan yang lebih rendah.	Pemodelan dilakukan berbasis CNN dan dataset yang digunakan berbahasa Inggris.
10	<i>A Descriptive Human Visual Cognitive Strategy using Graph Neural Network for Facial Expression Recognition</i> , Shuai Liu et al, 2024[15]	Bagaimana mengatasi keterbatasan metode FER yang hanya fokus pada struktur perhatian kompleks dan kurang mempertimbangkan hubungan antar bagian ekspresi wajah serta masalah interpretabilitas	Model <i>Graph Neural Network</i> (GNN) dengan membagi wajah menjadi enam bagian dan menggunakan strategi kognisi visual manusia untuk memilih fitur wajah kunci sebagai node graf, kemudian membangun model GNN	Model GNN bekerja baik pada kasus terkait fitur wajah yang menunjukkan kemampuan karakterisasi, generalisasi, dan ketahanan yang lebih baik dibandingkan dengan metode lainnya, termasuk metode <i>state-of-the-art</i> .	Penelitian dilakukan pada kasus pengenalan <i>facial expression</i> .

Nomor	Judul dan Penulis, tahun.	Rumusan Masalah	Metode,Data	Simpulan Penelitian/ Hasil	Perbedaan dengan Penelitian
		dengan mengusulkan GNN berdasarkan hubungan konotatif antar <i>node</i>	berdasarkan hubungan konotatif antar <i>node</i> . Dataset antara lain : Helen dataset , the 300 W dataset, dan the LFPW dataset		
11	<i>Deep Audio-Visual Speech Recognition</i> , Triantafyllos Afouras et al, 2022 [16]	Pengenalan kalimat dan frasa alami dari video wajah yang berbicara, baik dengan maupun tanpa audio, dalam skenario dunia nyata yang tidak terbatas, serta sejauh mana <i>lip reading</i> dapat melengkapi pengenalan ucapan berbasis audio terutama saat kondisi audio buruk.	Dibandingkan dua model berbasis <i>transformer</i> (CTC dan <i>seq2seq loss</i>) menggunakan dataset baru LRS2-BBC berisi ribuan kalimat dari TV Inggris.	Dengan ditambahkannya audio pada pemodelan sehingga mengungguli model lain pada kasus <i>lipreading</i> .	Terdapatnya penggunaan audio pada pemodelan.

2.2. Landasan Teori


2.2.1. Visual Speech Recognition (VSR)

Visual Speech Recognition (VSR) merupakan cabang dari pengenalan ujaran yang berfokus pada pemrosesan informasi visual, terutama dari gerakan bibir dan bagian wajah lainnya untuk mengenali kata-kata yang diucapkan tanpa mengandalkan input suara. Istilah ini sering digunakan secara bergantian dengan *lip reading*, meskipun dalam cakupan penelitian, VSR cenderung mengarah pada pendekatan otomatis berbasis komputer. VSR menjadi relevan dalam berbagai kondisi seperti lingkungan bising, keterbatasan alat bantu dengar, serta pada konteks komunikasi yang bergantung pada penglihatan, seperti pada penyandang gangguan pendengaran. Sistem VSR secara umum bekerja dengan mengekstraksi urutan gambar dari video yang menunjukkan seseorang sedang berbicara, lalu mengolah informasi visual tersebut untuk mengenali kata atau frasa [9]. Tidak seperti *Automatic Speech Recognition* (ASR) yang berbasis audio, VSR mengandalkan perubahan bentuk mulut, gerakan bibir, lidah, dan rahang bawah sebagai fitur utama. Dalam bidang pengolahan visual, tantangan utama dalam VSR adalah ketidakterlihatannya beberapa fonem (misalnya k dan g yang memiliki bentuk bibir mirip) dan keterbatasan informasi artikulatoris yang bisa ditangkap kamera [17].

Oleh karena itu, banyak penelitian terkini berfokus pada pemanfaatan model *deep learning* untuk menangkap pola spasial dan temporal dari video, guna meningkatkan akurasi sistem VSR. Penelitian ini mengangkat *lip reading* sebagai pendekatan utama untuk mengenali kata dalam Bahasa Indonesia melalui video tanpa suara, dengan menerapkan teknik visual *feature extraction* dan *temporal modeling* secara mendalam.

2.2.2. Graph Extraction


Setelah area bibir berhasil dipotong, langkah selanjutnya adalah mendeteksi titik-titik *landmark* pada bibir. Dalam penelitian ini, digunakan MediaPipe *Face Mesh* untuk mendeteksi 468 titik wajah, di antaranya terdapat 40 titik merepresentasikan struktur bibir (bagian atas, bawah, dalam, dan luar) [18].



Gambar 2. 1 *Landmark Detection* pada Wajah [19]

Titik-titik ini berupa koordinat (x, y, z) pada setiap frame yang telah dipotong. Informasi ini bersifat spasial dan menggambarkan bentuk serta posisi bibir pada setiap waktu. Koordinat x dan y merepresentasikan posisi *landmark* pada bidang dua dimensi citra, sedangkan koordinat z merupakan nilai kedalaman relatif yang diprediksi oleh MediaPipe berdasarkan model pembelajaran mesin internalnya, sehingga tidak diperoleh dari pengukuran kedalaman secara langsung. Koordinat *landmark* dari setiap *frame* selanjutnya digunakan sebagai *node*, dan konstruksi graf dilakukan menggunakan bawaan MediaPipe *FaceMesh Tessellation* untuk pemodelan *Graph Neural Network* (GNN) [20].

2.2.3. Graph Neural Network (GNN)



Gambar 2. 2 Ilustrasi Cara Kerja *Graph Neural Network* (GNN) [8]

Graph Neural Network (GNN) adalah salah satu pendekatan *deep learning* yang dirancang untuk mengolah data yang memiliki struktur graf, di mana data tersebut dapat terdiri dari simpul (*nodes*) yang terhubung oleh sisi (*edges*) [21]. Dalam konteks *lip reading*, titik-titik *landmark* pada wajah, seperti sudut bibir, ujung hidung, dan bagian lainnya, dapat dipandang sebagai *node* dalam graf, dengan hubungan spasial antar titik ini yang diwakili oleh *edge* [9].

Penggunaan GNN dalam *lip reading* diharapkan memberikan keunggulan dibandingkan pendekatan berbasis *grid* seperti CNN karena GNN dapat secara eksplisit memodelkan hubungan spasial antara titik-titik penting pada wajah, yang sangat relevan dalam memahami pergerakan bibir [15]. Dalam GNN, informasi dihimpun dari setiap simpul berdasarkan hubungan antar simpul yang ada dalam graf, memungkinkan model untuk memanfaatkan informasi spasial dan temporal dengan cara yang lebih fleksibel dan efisien. Pada umumnya, GNN digunakan untuk memodelkan hubungan antar titik-titik *landmark* wajah dalam bentuk graf [22].

Salah satu keunggulan GNN dalam VSR adalah kemampuannya untuk mengenali hubungan dinamis antar *landmark* yang berubah seiring waktu, sebuah aspek yang sering kali diabaikan oleh model CNN yang hanya mengandalkan pemrosesan *frame per frame* [5].

Proses utama dalam GNN dilakukan melalui tahapan yang dikenal sebagai *message passing* atau *neighborhood aggregation* [23]. Rumus umum untuk memperbarui representasi *node* h_v pada lapisan ke- k adalah sebagai berikut:

$$h_v^{(k)} = \sigma \left(W^{(k)} \cdot \text{AGG} \left(\{h_u^{(k-1)} \mid u \in \mathcal{N}(v) \cup \{v\}\} \right) \right) \quad (2.1)$$

di mana:

- $h_v^{(k)}$: Representasi fitur dari *node* v pada *layer* ke- k ,
- σ : Fungsi aktivasi non-linear (seperti ReLU, Sigmoid),
- $W^{(k)}$: Matriks bobot learnable pada lapisan ke- k ,
- AGG: Fungsi agregasi yang digunakan pada lapisan ke- k , seperti *mean*, *sum*, *max*, atau *attention*,
- $h_u^{(k-1)}$: Representasi tetangga u pada lapisan sebelumnya (ke $k - 1$),
- $u \in \mathcal{N}(v) \cup \{v\}$: Himpunan tetangga dari *node* v .

Dalam pengembangan model berbasis GNN, pemilihan arsitektur yang tepat menjadi aspek krusial untuk memastikan kemampuan model dalam menangkap pola spasial dan temporal dari data graf. Beragam varian GNN telah dikembangkan untuk menjawab kebutuhan pemodelan graf yang kompleks, masing-masing dengan pendekatan berbeda dalam proses propagasi informasi antar simpul (*node*) dan penyesuaian bobot antar sisi (*edge*). Pemilihan varian arsitektur ini bergantung pada karakteristik data serta jenis hubungan yang ingin dimodelkan, seperti struktur spasial statis atau hubungan temporal dinamis antarsekuens [24].

2.2.4. Arsitektur Populer *Graph Neural Network* (GNN)

Perkembangan arsitektur GNN didorong oleh upaya untuk meningkatkan efisiensi komputasi dan kemampuan ekspresif dalam menangkap struktur graf. Berikut adalah model-model GNN yang paling umum digunakan dalam literatur:

1. *Graph Convolutional Network* (GCN)

GCN menggunakan pendekatan konvolusi yang dinormalisasi secara simetris [25]. Model ini bekerja dengan mengambil nilai rata-rata

tertimbang dari fitur-fitur *node* tetangga untuk memperbarui representasi *node* target dengan formula sebagai berikut:

$$h_v^{(k)} = \sigma \left(W^{(k)} \left(\sum_{u \in N(v) \cup \{v\}} \frac{1}{\sqrt{\deg(v)\deg(u)}} h_u^{(k-1)} \right) \right) \quad (2.2)$$

di mana:

- $h_v^{(k)}$: Representasi fitur *node* v pada *layer* k ,
- $\frac{1}{\sqrt{\deg(v)\deg(u)}}$: Koefisien normalisasi simetris berdasarkan derajat *node* v dan *node* u ,
- $W^{(k)}$: Matriks bobot yang dapat dilatih,
- $h_u^{(k-1)}$: Fitur dari *node* tetangga u dari layer sebelumnya.
- σ : fungsi aktivasi sigmoid.

2. GraphSAGE

GraphSAGE memperkenalkan teknik agregasi induktif [26]. Berbeda dengan GCN yang menggunakan seluruh tetangga, GraphSAGE dapat melakukan *sampling* pada sejumlah *node* tetangga dan menggabungkan (*concatenate*) fitur *node* target dengan hasil agregasi lingkungannya dengan formula sebagai berikut:

$$h_{N(v)}^{(k)} = \text{AGG}^{(k)}(\{h_u^{(k-1)}, \forall u \in N(v)\}) \quad (2.3)$$

$$h_v^{(k)} = \sigma \left(W^{(k)} \cdot [h_v^{(k-1)} \parallel h_{N(v)}^{(k)}] \right) \quad (2.4)$$

di mana:

- $h_{N(v)}^{(k)}$: Representasi fitur *node* v dari fitur tetangga-tetangga *node* v tanpa *node* v itu sendiri,
- $\text{AGG}^{(k)}$: Fungsi agregasi (bisa berupa *Mean*, *Max Pool*),
- $h_u^{(k-1)}$: Representasi dari *node* tetangga u dari layer sebelumnya,
- $\forall u \in N(v)$: Semua *node* u yang merupakan tetangga dari v ,
- $\parallel$: Simbol operasi konkatenasi (penggabungan dua vektor),
- $W^{(k)}$: Matriks bobot yang dapat dilatih,

- σ : Fungsi aktivasi.

3. *Graph Isomorphism Network* (GIN)

Graph Isomorphism Network (GIN) adalah varian arsitektur *Graph Neural Network* (GNN) yang dirancang untuk mengatasi kelemahan arsitektur GNN sebelumnya (seperti GCN dan GraphSAGE) yang dianggap kurang maksimal dalam membedakan struktur graf yang berbeda (*discriminative power*) [27].

Nama "*Isomorphism*" diambil dari Tes Weisfeiler-Lehman (WL Test), sebuah algoritma standar untuk menguji apakah dua graf memiliki struktur topologi yang identik (isomorfis). GIN memiliki kemampuan ekspresif yang setara dengan WL Test, menjadikannya salah satu GNN paling kuat untuk mengenali pola struktural yang halus.

Berbeda dengan GCN yang menggunakan operasi *mean pooling* (rata-rata) atau GraphSAGE yang menggunakan *max pooling*, GIN menggunakan *Sum Aggregation* (penjumlahan). *Mean/Max Pooling* cenderung "meratakan" fitur. Mereka bisa gagal membedakan antara *node* yang memiliki 2 tetangga dengan fitur X, dan *node* yang memiliki 100 tetangga dengan fitur X (karena rata-ratanya sama). *Sum Aggregation* pada GIN menangkap "jumlah" informasi. Ini memungkinkan model memahami struktur penuh dari tetangga *node*, bukan hanya representasi rata-ratanya [27].

Secara matematis, proses update fitur *node* pada layer ke-k dalam GIN dirumuskan sebagai berikut:

$$h_v^{(k)} = \text{MLP}^{(k)} \left((1 + \varepsilon^{(k)}) h_v^{(k-1)} + \sum_{u \in N(v)} h_u^{(k-1)} \right) \quad (2.5)$$

di mana:

- $\text{MLP}^{(k)}$: *Multi-Layer Perceptron* (terdiri dari lapisan *Linear* -> ReLU -> *Linear*),

- $\varepsilon^{(k)}$: Parameter (*epsilon*) yang dapat dipelajari (*learnable scalar*) atau konstanta tetap. Ini menentukan seberapa penting fitur *node* itu sendiri dibandingkan tetangganya,
- $h_v^{(k)}$: Representasi fitur *node* v pada *layer* k ,
- $\sum_{u \in N(v)}$: Agregasi berbasis penjumlahan (*sum aggregation*) dari fitur-fitur simpul tetangga u yang berada dalam himpunan tetangga $N(v)$,
- $h_u^{(k-1)}$: Fitur dari *node* tetangga u dari *layer* sebelumnya.

2.2.5. Convolution Neural Network (CNN)


Convolutional Neural Network (CNN) merupakan arsitektur jaringan saraf yang dirancang khusus untuk memproses data dalam bentuk *grid*, seperti citra atau video. Dalam *lip reading*, CNN digunakan untuk mengekstrak fitur spasial dari setiap *frame* video mulut, seperti bentuk bibir, kontur mulut, dan pola pergerakan [5].

Secara umum, CNN terdiri dari beberapa lapisan konvolusi yang bertugas mengekstraksi fitur, lapisan aktivasi (fungsi non-linearitas yang mengubah nilai dalam rentang tertentu) seperti ReLU, dan lapisan *pooling* yang mereduksi dimensi spasial. Pada *lip reading* berbasis CNN, setiap frame video mulut diolah sebagai input citra dua dimensi, lalu hasil ekstraksinya digabungkan secara berurutan untuk mengenali kata yang diucapkan. Namun, pendekatan ini sering kali mengandalkan metode tambahan yaitu *Sequence Modelling* seperti *Long Short-Term Memory (LSTM)* atau *Gated Recurrent Unit (GRU)* untuk menangani aspek temporal antar *frame*. Meskipun pendekatan berbasis CNN telah menghasilkan performa yang baik, model ini masih memiliki keterbatasan dalam memahami hubungan antar titik pada area wajah yang tidak tersusun dalam *grid* secara alami, seperti bentuk bibir melengkung atau pergerakan *non-linear* antar *frame* [5], [13]. Hal ini menjadi alasan utama munculnya pendekatan berbasis graf seperti GNN untuk mengatasi keterbatasan ini.

2.2.6. Temporal Modeling

Pemodelan temporal merupakan salah satu aspek kunci dalam penelitian VSR karena gerakan bibir yang diobservasi dalam video merupakan rangkaian pergerakan yang terjadi dalam urutan waktu. Pada VSR, pemahaman tentang bagaimana urutan *frame* video (yang berisi gerakan bibir) berinteraksi satu sama lain sangat penting untuk menentukan kata yang diucapkan [28]. Berbagai metode *deep learning* telah dikembangkan untuk menangkap informasi temporal ini. Salah satu pendekatan yang umum digunakan adalah model seperti *Long Short-Term Memory* (LSTM) dan *Gated Recurrent Units* (GRU), yang memungkinkan model untuk mengingat dan memproses informasi yang relevan dari urutan *frame* sebelumnya. Model-model ini bekerja dengan cara mengembangkan mekanisme memori yang membantu dalam menyimpan informasi temporal yang ada di dalam video [13], [28]. Namun, seiring dengan perkembangan teknologi, ada juga pendekatan baru yang menggunakan *Transformer* dan *Self-Attention* yang lebih efektif dalam menangani panjang urutan dan hubungan jangka panjang antar *frame* [14], [22].

2.2.7. LSTM (Long Short-Term Memory)



Gambar 2. 3 Ilustrasi Cara Kerja LSTM

LSTM memproses sekuens temporal dengan mempertahankan *hidden state* dan *cell state* untuk mengingat informasi jangka panjang dan pendek secara selektif. Proses Operasi *Forward Pass* dilakukan pada setiap *timestep (frame)* dengan empat komponen utama:

- *Forget Gate* (f_t): Memutuskan informasi mana yang harus dibuang dari memori berdasarkan input saat ini (x_t) dan keadaan sebelumnya (h_{t-1}).

Rumus:

$$F_t = f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (2.6)$$

- *Input Gate* (I_t): Memutuskan nilai baru mana yang akan disimpan dalam memori. Menggunakan fungsi aktivasi sigmoid dan tanh untuk menciptakan kandidat memori baru ($\tilde{C}_t$). Rumus:

$$I_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (2.7)$$

$$\tilde{C}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c) \quad (2.8)$$

- *Cell State Update* (c_t): Memperbarui memori jangka panjang dengan membuang informasi lama dan menambahkan informasi baru. Rumus :

$$c_t = f_t \odot c_{t-1} + I_t \odot \tilde{c}_t \quad (2.9)$$

- *Output Gate*(o_t): Memutuskan bagian mana dari memori yang akan menjadi hidden state (h_t) untuk diteruskan ke tahap berikutnya. Rumus:


$$o_t = \sigma(W_o \cdot [H_{t-1}, x_t] + b_o) \quad (2.10)$$

Dimana:

- x_t : *Input* pada waktu saat ini (data baru)
- h_{t-1} : *Output* dari sel sebelumnya (memori jangka pendek)
- C_{t-1} : Keadaan sel sebelumnya (memori jangka panjang)
- σ (*Sigmoid*) : Fungsi aktivasi untuk gerbang (menghasilkan angka 0 sampai 1)
- $\tanh$: Fungsi aktivasi untuk menormalkan nilai (menghasilkan angka -1 sampai 1)
- W & b : Bobot (*Weight*) dan Bias yang dipelajari model saat pelatihan

2.2.8. Mamba SSM

Penelitian ini mengadopsi arsitektur Mamba [29], sebuah pengembangan dari *State Space Models* (SSM) yang dirancang untuk pemodelan sekuens yang efisien. Mamba mengatasi batasan komputasi kuadratik pada *Transformer* dengan menawarkan kompleksitas linear $O(L)$ terhadap panjang sekuens. Inovasi utama model ini terletak pada Mekanisme Seleksi (*Selection Mechanism*), yang memungkinkan model secara dinamis menyaring informasi mengingat data yang relevan dan melupakan yang tidak relevan—berdasarkan konten input saat itu (*input-dependent*).



Gambar 2. 4 Arsitektur Mamba

Berdasarkan diagram arsitektur Mamba pada Gambar 2.4, proses komputasi di dalam *Mamba Block* dapat diuraikan menjadi empat tahapan utama. Berikut adalah formalisasi matematis yang disederhanakan untuk merepresentasikan aliran sinyal pada gambar:

1. Proyeksi Linear & Percabangan (*Linear Projection & Gating*)

Blok ini diawali dengan memperluas dimensi input u menggunakan proyeksi linear. Aliran data dipisahkan menjadi dua cabang: cabang pemrosesan utama (x) dan cabang gerbang atau *gating branch* (z).

$$x, z = \text{Linear}(u) \quad (2.11)$$

Dimana:

- x : Vektor fitur yang akan diproses melalui konvolusi dan SSM,
- z : Sinyal kontrol yang digunakan pada tahap akhir untuk mengatur aliran informasi,
- $u \in R^{B \times T \times F}$: Input sekuens (*Batch, Time, Features*),

- *Linear : Fully Connected Layer* (biasanya diperbesar dengan faktor ekspansi sebesar 2 kali),

2. Konvolusi Causal (Conv1d)

Pada jalur utama, fitur x diproses melalui konvolusi 1D kausal. Tahap ini memberikan bias induktif lokal, memastikan model menangkap ketergantungan jarak pendek (*local dependencies*) sebelum masuk ke pemrosesan memori jangka panjang.

$$x' = \text{SiLU}(\text{Conv1d}(x)) \quad (2.12)$$

di mana:

- x' : Fitur hasil konvolusi yang telah diaktivasi,
- SiLU : Fungsi aktivasi *Sigmoid Linear Unit* ($x \cdot \sigma(x)$),
- Conv1d(x) : Operasi konvolusi 1 dimensi dengan *padding* kausal (hanya melihat masa lalu).

3. Selective SSM (State Space Model)

Ini adalah komponen inti di mana kompresi memori terjadi. Berbeda dengan *Recurrent Neural Networks* (RNN) konvensional, parameter matriks dalam Mamba (B, C, Δ) berubah sesuai dengan input pada setiap langkah waktu (*time-varying*).

Proses ini terdiri dari tiga langkah sub-tahapan:

a. Proyeksi Parameter Selektif (*Parameter Projection*)

Input x' diproyeksikan untuk mendapatkan parameter dinamik Δ_t, B_t , dan C_t . Langkah inilah yang membuat Mamba bersifat "selektif" (*input-dependent*).

$$\Delta_t = \text{Softplus}(\text{Linear}_\Delta(x'))$$

$$B_t = \text{Linear}_B(x')$$

$$C_t = \text{Linear}_C(x')$$

b. Diskretisasi (*Discretization*)

Parameter sistem kontinu A dan input selektif B_t diubah menjadi bentuk diskrit menggunakan metode *Zero-Order Hold* (ZOH) dengan langkah waktu Δ_t .

$$\overline{A}_t = \exp(\Delta_t A) \quad (2.13a)$$

$$\overline{B}_t = (\Delta_t A)^{-1}(\exp(\Delta_t A) - I) \cdot \Delta_t B_t \quad (2.13b)$$

c. Persamaan Rekurensi SSM

Setelah didiskretisasi, pembaruan *hidden state* (h_t) dan komputasi *output* (y_t) dilakukan dengan persamaan rekurensi:

$$h_t = \overline{A}_t h_{t-1} + \overline{B}_t x'_t \quad (2.13c)$$

$$y_t = C_t h_t \quad (2.14)$$

Dimana:

- h_t : *Hidden state* berdimensi (B (*Batch*), D (*Dimension*), N(SSM *State Dimension*)),
- A : Parameter matriks evolusi sistem yang bersifat statis (biasanya diagonal),
- Δ_t : Parameter *step size* (delta) yang mengontrol durasi fokus memori.
- $\overline{A}_t, \overline{B}_t$: Parameter sistem terdiskretisasi yang berubah terhadap waktu,
- B_t, C_t : Parameter proyeksi *input* dan *output*.

4. Mekanisme *Gating & Output* (*Output Projection*)

Tahap akhir menggabungkan hasil dari SSM (y_t) dengan cabang gerbang (z) yang telah disiapkan di awal. Mekanisme ini menggunakan fungsi aktivasi multiplikatif untuk memodulasi output.

$$Output = \text{Linear}(y_t \odot \text{SiLU}(z)) \quad (2.15)$$

Operasi $\odot$ melambangkan perkalian elemen (*element-wise multiplication*). Struktur ini memungkinkan jaringan untuk secara efektif mengatur seberapa banyak informasi historis yang diteruskan ke lapisan berikutnya.

2.2.9. Feature Engineering

Feature Engineering adalah proses transformasi data mentah menjadi representasi fitur yang lebih informatif untuk meningkatkan kemampuan model pembelajaran mesin dalam mempelajari pola. Dalam konteks analisis video berbasis *landmark*, data mentah sering kali hanya berupa deretan koordinat posisi (x, y, z) . Meskipun data ini memuat informasi posisi, representasi tersebut mungkin belum cukup kuat untuk menangkap karakteristik kompleks seperti bentuk spesifik bibir atau dinamika pergerakannya. Oleh karena itu, rekayasa fitur dilakukan untuk mengekstrak atribut turunan yang lebih diskriminatif seperti fitur geometris dan kinematik [29].

2.2.10. LOSO

Leave-One-Subject-Out (LOSO) adalah protokol evaluasi yang memisahkan data pelatihan dan pengujian pada level subjek, bukan *instance* individual. Pada setiap iterasi, data dari satu subjek sepenuhnya dijadikan set uji, sementara data dari subjek lainnya digunakan untuk pelatihan. Pendekatan ini menjamin evaluasi yang bebas kebocoran identitas (*subject-independent*), sehingga performa model mencerminkan kemampuan generalisasi terhadap individu yang belum pernah dilihat sebelumnya, bukan sekadar penyesuaian terhadap fitur spesifik subjek dalam data latih. LOSO sering digunakan dalam domain bio-signifik seperti EEG, perilaku manusia, dan pengenalan visual karena karakteristik data yang memiliki variabilitas antar subjek yang tinggi. Evaluasi dengan LOSO cenderung lebih konservatif dan realistis dibandingkan *k-fold* konvensional yang dapat menghasilkan estimasi akurasi optimistis akibat *overlap* sampel dalam *fold* yang berbeda. Namun, LOSO juga lebih komputasi intensif karena kebutuhan melatih model sebanyak jumlah subjek dalam dataset [30].

2.2.11. Evaluasi Kinerja Model VSR

Evaluasi kinerja merupakan bagian yang sangat penting dalam proses pengembangan model VSR. Evaluasi dilakukan untuk mengukur seberapa akurat model dalam mengidentifikasi kata yang diucapkan hanya berdasarkan masukan visual berupa gerakan bibir. Dalam penelitian ini, evaluasi dilakukan pada data

pengujian yang telah dipisahkan dari data pelatihan dan validasi, dengan tujuan mendapatkan hasil yang objektif dan tidak bias terhadap proses pelatihan model.

Beberapa metrik evaluasi yang digunakan dalam penelitian ini meliputi *classification report* berisi akurasi, *precision*, *recall*, *F1-score*, serta visualisasi *importance node* menggunakan GNNExplainer. Masing-masing metrik memberikan pandangan yang berbeda dalam mengukur performa model klasifikasi kata berbasis visual.

2.2.11.1. *Classification Report*

Sebelum membahas metrik evaluasi pada *Classification Report*, kinerja model terlebih dahulu dianalisis menggunakan *Confusion Matrix*. *Confusion Matrix* merupakan tabel evaluasi yang menggambarkan perbandingan antara label aktual dan hasil prediksi model, sehingga memberikan representasi yang jelas mengenai jenis kesalahan yang terjadi selama proses klasifikasi. Matriks ini terdiri dari empat komponen utama, yaitu *True Positive* (TP), *True Negative* (TN), *False Positive* (FP), dan *False Negative* (FN). Melalui *Confusion Matrix*, dapat diketahui sejauh mana model mampu mengklasifikasikan data secara benar maupun salah pada masing-masing kelas, yang selanjutnya menjadi dasar perhitungan berbagai metrik evaluasi seperti Precision, Recall, F1-Score, dan Akurasi .

Evaluasi kinerja model dilakukan menggunakan *classification report* yang terdiri atas beberapa metrik utama untuk mengukur keandalan prediksi [3]. Metrik pertama adalah *Precision*, yang berfungsi untuk mengukur ketepatan prediksi positif yang dihasilkan oleh model. Nilai ini diperoleh dengan membandingkan prediksi benar positif terhadap keseluruhan hasil prediksi positif, sebagaimana ditunjukkan dalam persamaan berikut:

$$\text{Precision} = \frac{TP}{TP + FP} \quad (2.16)$$

Selain ketepatan, evaluasi juga mempertimbangkan *Recall*, yaitu metrik yang merefleksikan kemampuan model dalam mengidentifikasi seluruh sampel aktual dari suatu kelas. Nilai *Recall* dihitung dengan membagi jumlah prediksi benar positif dengan total data yang sebenarnya positif (jumlah benar positif dan salah negatif), sesuai dengan rumus berikut:

$$\text{Recall} = \frac{TP}{TP + FN} \quad (2.17)$$

Untuk menjembatani keseimbangan antara *Precision* dan *Recall*, terutama pada kondisi distribusi kelas yang tidak seimbang, digunakan metrik *F1-Score*. Metrik ini merupakan rata-rata harmonik dari kedua nilai tersebut dan dihitung menggunakan persamaan:

$$\text{F1-Score} = \frac{2TP}{2TP + FP + FN} \quad (2.18)$$

Dalam laporan ini juga disertakan nilai *Support*, yang menunjukkan jumlah sampel aktual pada masing-masing kelas. Namun, sebagai metrik evaluasi utama, penelitian ini menggunakan Akurasi yang merepresentasikan proporsi prediksi benar terhadap seluruh sampel uji. Pemilihan akurasi didasarkan pada kemampuannya dalam memberikan gambaran performa model secara global serta sebagai acuan komparasi terhadap penelitian sebelumnya[3]. Rumus akurasi dinyatakan sebagai:

$$\text{Akurasi} = \frac{TP + TN}{TP + TN + FP + FN} \quad (2.19)$$

di mana:

TP : Jumlah data kelas positif yang diprediksi secara benar sebagai positif,

TN: Jumlah data kelas negatif yang diprediksi secara benar sebagai negatif,

FP: Jumlah data kelas negatif yang salah diprediksi sebagai positif,

FN : Jumlah data kelas positif yang salah diprediksi sebagai negatif.

2.2.11.2. *Explainable* AI (xAI)

Explainable AI (xAI) berfungsi sebagai kerangka kerja untuk membongkar kompleksitas model "kotak hitam", dan dalam konteks data relasional, GNNExplainer hadir sebagai solusi spesifik yang menjembatani prediksi GNN dengan interpretasi manusia. Pendekatan ini bekerja dengan cara mengisolasi subgraf krusial dan subset fitur *node* yang paling signifikan melalui teknik optimasi informasi mutual, sehingga mampu menjelaskan apakah suatu keputusan diambil

berdasarkan pola hubungan antar entitas (struktur *edge*) atau karakteristik spesifik dari entitas itu sendiri (fitur). Dengan mengidentifikasi struktur minimal yang paling mempertahankan probabilitas prediksi asli, GNNExplainer mengubah komputasi grafik yang rumit menjadi visualisasi yang dapat dipahami, yang sangat krusial untuk validasi keputusan di bidang kritis seperti penemuan obat-obatan atau deteksi penipuan keuangan.

Secara prinsip, GNNExplainer bekerja sebagai masalah optimasi yang berupaya memaksimalkan *Mutual Information* (MI) antara prediksi model asli dengan distribusi prediksi yang dihasilkan oleh subgraf kandidat. Proses optimasi ini dilakukan dengan tetap memberikan penalti pada kompleksitas subgraf, sehingga penjelasan yang dihasilkan bersifat *compact* (ringkas) dan relevan, hanya menyoroti komponen struktural yang benar-benar krusial bagi prediksi [31].

2.2.11.3. FLOPS

FLOPS (*Floating Point Operations Per Second*) merupakan metrik yang digunakan untuk mengukur kompleksitas komputasi suatu model atau algoritma, khususnya dengan menghitung jumlah operasi aritmetika *floating-point* (seperti penjumlahan, perkalian, pembagian) yang dilakukan selama proses komputasi. Dalam konteks pembelajaran mesin dan *deep learning*, FLOPS umumnya digunakan untuk mengestimasi biaya komputasi model pada saat forward pass maupun training [32].

Secara umum, semakin besar nilai FLOPS, maka semakin tinggi kebutuhan sumber daya komputasi yang diperlukan, baik dari sisi waktu eksekusi maupun konsumsi energi. Oleh karena itu, FLOPS sering dijadikan indikator efisiensi model, terutama ketika membandingkan beberapa arsitektur dengan tingkat akurasi yang serupa.

Dalam penelitian *Deep Learning*, FLOPS tidak hanya bergantung pada jumlah parameter model, tetapi juga pada struktur arsitektur, jenis operasi (misalnya konvolusi, perkalian matriks, atau agregasi graf) [33], serta ukuran input data. Sebagai contoh, dua model dengan jumlah parameter yang sama dapat memiliki nilai FLOPS yang berbeda akibat perbedaan pola komputasi.

Pada GNN, perhitungan FLOPS umumnya melibatkan operasi agregasi tetangga (*neighborhood aggregation*), transformasi linear, dan fungsi aktivasi pada setiap *node* dan *edge*. Dengan demikian, FLOPS pada GNN juga dipengaruhi oleh jumlah *node*, jumlah *edge*, dan derajat rata-rata graf.

Penggunaan FLOPS sebagai metrik evaluasi membantu peneliti dalam menilai *trade-off* antara akurasi model dan efisiensi komputasi, khususnya untuk aplikasi *real-time* atau sistem dengan keterbatasan sumber daya.

BAB III

METODE PENELITIAN

3.1. Subjek dan Objek Penelitian

Subjek dalam penelitian ini adalah proses klasifikasi kata dan frasa dalam Bahasa Indonesia berdasarkan representasi visual gerakan bibir dari video tanpa audio, menggunakan pendekatan *Deep Learning* berbasis GNN.

Objek penelitian ini adalah dataset IndoLR (*Indonesian Lip Reading*). Dataset ini merupakan dataset publik pertama untuk *lip reading* Bahasa Indonesia yang secara spesifik mempertimbangkan variasi delapan jenis bentuk bibir dari penutur yang berbeda. Data ini direkam secara khusus dalam lingkungan terkontrol untuk memastikan representasi visual yang akurat pada level kata dan frasa.

3.2. Alat dan Bahan Penelitian

3.2.1. Alat Penelitian

Alat yang digunakan pada penelitian ini meliputi perangkat keras (*Hardware*) dan perangkat lunak (*software*).

Adapun detail dari alat-alat yang digunakan adalah sebagai berikut:


1. Perangkat Keras (*Hardware*)
 - a. Server RTX 4090 Desktop
2. Perangkat Lunak (*Software*)
 - a. *Integrated Development Environment* (IDE) VS Code
 - b. Dokumen Editor *Microsoft Office*
 - c. *Mendeley Reference Manager*

3.2.2. Bahan Penelitian

Bahan penelitian ini adalah dataset *Indonesian Lip Reading* dataset (IndoLR) yang terdiri dari 5807 video pendek berisi pengucapan 10 kata & 4 frasa dalam Bahasa Indonesia. Setiap video memiliki resolusi 640×480 , durasi sekitar 1 detik, dan *frame rate* sebesar 30 fps. Dataset terdiri dari 2.400 sampel video kata dan 1.600 sampel video frasa. Proses ekstraksi, anotasi, dan validasi telah dilakukan oleh peneliti terdahulu yang membangun dataset ini, dan didokumentasikan secara sistematis dalam dokumentasi github mereka. Oleh karena itu, dataset IndoLR

dianggap sah dan layak digunakan untuk keperluan penelitian *visual speech recognition*. Dataset ini telah dibagi menjadi tiga subset dengan rasio 8:1:1 untuk pelatihan, validasi, dan pengujian. Setiap video dilengkapi dengan label kata target yang diucapkan oleh penutur asli Bahasa Indonesia.

3.3. Diagram Alir Penelitian



Gambar 3. 1 Diagram Alir Penelitian

3.3.1. Identifikasi Masalah

Tahap awal penelitian ini diawali dengan proses identifikasi masalah, penetapan tujuan dan manfaat penelitian, serta pengumpulan dan kajian literatur yang relevan. Permasalahan utama yang menjadi fokus penelitian adalah bagaimana mengenali kata dan frasa dalam Bahasa Indonesia melalui representasi visual gerakan bibir, khususnya pada kondisi tanpa dukungan sinyal audio.

Dataset yang digunakan dalam penelitian ini terdiri atas 8 subjek dengan karakteristik bentuk bibir yang beragam, di mana seluruh subjek merupakan Warga Negara Indonesia. Keberagaman tersebut diharapkan mampu merepresentasikan karakteristik penutur asli Bahasa Indonesia, sehingga model yang dikembangkan memiliki tingkat keandalan yang baik ketika diterapkan pada kondisi dunia nyata.

Penelitian ini bertujuan untuk mengembangkan model berbasis *Graph Neural Network* (GNN) yang mampu menangkap pola hubungan spasial dan temporal antar landmark wajah, khususnya pada area bibir, guna melakukan klasifikasi kata dan frasa yang diucapkan. Model yang diusulkan diharapkan dapat menjadi alternatif solusi pada situasi di mana sinyal audio tidak tersedia atau mengalami gangguan, serta berkontribusi dalam pengembangan teknologi bantu komunikasi bagi penyandang disabilitas pendengaran.

3.3.2. Studi Literatur

Studi literatur pada penelitian ini dilakukan untuk memperoleh pemahaman komprehensif mengenai pendekatan, metode, serta konfigurasi model yang umum digunakan dalam pemodelan berbasis graf. Kajian literatur difokuskan pada beberapa aspek utama, meliputi representasi graf, pemilihan arsitektur model, penentuan parameter, metode *feature engineering*, serta evaluasi performa pada berbagai bahasa.

Pada tahap awal, literatur ditelaah untuk mengidentifikasi bagaimana struktur graf dibangun, termasuk definisi *node* dan *edge*. *Node* umumnya merepresentasikan *landmark* wajah, khususnya pada area bibir, sedangkan *edge* digunakan untuk merepresentasikan hubungan spasial antar *landmark* berdasarkan kedekatan geometris atau konektivitas anatomis.

Selanjutnya, studi literatur juga membahas arsitektur GNN yang populer digunakan, seperti *Graph Convolutional Network* (GCN), GraphSAGE, dan *Graph Isomorphism Network* (GIN). Pemilihan model dalam penelitian-penelitian tersebut umumnya disesuaikan dengan kompleksitas data dan kebutuhan untuk menangkap hubungan non-linear antar *landmark*. Parameter penting seperti jumlah *layer*, *batch size*, fungsi agregasi, & *learning rate*, dianalisis sebagai acuan dalam perancangan model pada penelitian ini.

Selain arsitektur model, metode *feature engineering* menjadi fokus penting dalam studi literatur. Fitur yang umum digunakan meliputi fitur geometris, seperti jarak antar *landmark*, sudut, dan rasio bentuk bibir, serta fitur gerak (*motion features*), seperti perbedaan posisi *landmark* antar *frame* atau vektor kecepatan.

Selain itu, literatur juga ditelusuri untuk mengidentifikasi penelitian-penelitian sebelumnya [3] yang menggunakan dataset yang sama. Beberapa penelitian menyediakan kode pembagian data (*data splitting*) dan seed agar konsisten pada penelitian ini dalam pembagian *training*, *validation*, dan *testing*, yang dipublikasikan melalui repositori GitHub. Pada penelitian ini, skema pembagian data yang sama diadopsi untuk menjaga konsistensi dan memungkinkan perbandingan performa yang adil dengan penelitian terdahulu.

Berdasarkan hasil studi literatur, dapat disimpulkan bahwa hingga saat ini penerapan GNN untuk VSR pada Bahasa Indonesia masih sangat terbatas atau belum banyak dieksplorasi. Oleh karena itu, penelitian ini diharapkan dapat mengisi celah penelitian tersebut dengan mengkaji efektivitas GNN dalam mengenali kata dan frasa Bahasa Indonesia berbasis gerakan bibir.

3.3.3. Data Collection

Dataset yang digunakan dalam penelitian ini diperoleh dari platform Kaggle melalui repositori *IndoLR* yang tersedia pada tautan <https://www.kaggle.com/datasets/abasset/indolr>.

3.3.4. Data Understanding

Pada tahap *data understanding*, dilakukan pemahaman terhadap karakteristik dataset yang digunakan, baik dari sisi subjek, variasi bentuk bibir (*lip*

shape), maupun kelas kata dan frasa yang direpresentasikan. Dataset ini terdiri atas delapan subjek dengan karakteristik bentuk bibir yang berbeda-beda. Variasi bentuk bibir tersebut diharapkan mampu merepresentasikan keragaman visual penutur Bahasa Indonesia, sehingga model yang dikembangkan tidak bergantung pada karakteristik individu tertentu.

Delapan bentuk bibir di tiap subjek yang bersesuaian adalah sebagai berikut:

1. *Natural*,
2. *Pointy Natural*
3. *Cupid's Bow*,
4. *Thin*,
5. *Unilip*,
6. *Bestung*,
7. *Smear*, dan
8. *Glamor*.

Selain variasi subjek, dataset ini juga mencakup total 14 kelas yang terdiri atas 10 kata tunggal dan 4 frasa. Kelas dengan indeks 1 hingga 10 merepresentasikan kata tunggal, sedangkan kelas dengan indeks 11 hingga 14 merepresentasikan frasa. Daftar kelas kata dan frasa yang digunakan dalam penelitian ini adalah sebagai berikut:

1. Maaf,
2. Tolong,
3. Permisi,
4. Halo,
5. Mulai,
6. Berhenti,
7. Lanjut,
8. Sakit,
9. Kembali,
10. Awas,

11. Terima Kasih,
12. Saya Minta Tolong,
13. Saya Minta Maaf, *dan*
14. Minta Tolong.

Keberagaman bentuk bibir, subjek, serta variasi kelas kata dan frasa ini menjadi dasar penting dalam analisis data, sekaligus menantang model untuk mampu mempelajari pola visual gerakan bibir yang konsisten lintas individu dan lintas jenis ujaran.

3.3.5. Statistik Deskriptif & Visualisasi Data

Statistik deskriptif dan visualisasi data dilakukan untuk memperoleh gambaran umum mengenai karakteristik dataset yang digunakan, termasuk skala dataset, distribusi subjek dan kelas, serta variasi temporal dari data video. Analisis ini bertujuan untuk memastikan bahwa dataset memiliki distribusi yang memadai dan tidak mengandung bias signifikan yang dapat mempengaruhi proses pelatihan dan evaluasi model.

3.3.5.1. Statistik Keseluruhan Dataset

Secara keseluruhan, dataset terdiri atas sejumlah video yang dikumpulkan dari delapan subjek dengan total 14 kelas ujaran, yang terbagi menjadi 10 kelas kata dan 4 kelas frasa. Jumlah video untuk kelas kata dan frasa dianalisis secara terpisah untuk memastikan proporsi data yang memadai pada masing-masing tingkat ujaran. Statistik ini memberikan konteks awal mengenai skala dan komposisi dataset yang digunakan dalam penelitian.

3.3.5.2. Karakteristik Temporal (FPS dan Durasi)

Seluruh video dalam dataset direkam dengan laju *frames per second* (FPS) yang tetap, yaitu 30 FPS. Dengan demikian, tidak terdapat variasi FPS antar video yang dapat mempengaruhi representasi temporal data. Kondisi ini memberikan konsistensi temporal pada seluruh sampel dan menyederhanakan proses ekstraksi fitur gerakan bibir.

Analisis karakteristik temporal selanjutnya difokuskan pada durasi video dalam satuan detik, yang merepresentasikan panjang ujaran secara temporal. Statistik durasi mencakup nilai rata-rata, standar deviasi, nilai minimum, maksimum, dan median. Analisis ini memberikan pemahaman mengenai variasi panjang ujaran antar sampel, yang relevan terutama dalam konteks pemodelan temporal pada tugas VSR.

3.3.5.3. Distribusi Berdasarkan Subjek

Distribusi data berdasarkan subjek dianalisis secara ringkas untuk memastikan bahwa setiap subjek memiliki kontribusi data yang memadai. Analisis ini mencakup jumlah video per subjek, serta rata-rata durasi video. Evaluasi distribusi per subjek menjadi penting dalam penelitian ini mengingat penggunaan skema *Leave-One-Subject-Out* (LOSO), di mana keseimbangan data antar subjek berperan langsung terhadap stabilitas dan keandalan hasil evaluasi.

3.3.5.4. Visualisasi Data

Untuk mendukung analisis statistik deskriptif, dilakukan visualisasi data seperti diagram batang jumlah video per subjek dan jumlah video per kelas kata dan frasa. Visualisasi ini digunakan untuk mengidentifikasi pola distribusi, potensi ketimpangan data, serta variasi temporal yang terdapat dalam dataset. Informasi yang diperoleh dari visualisasi ini selanjutnya menjadi dasar dalam perancangan skema *data splitting* dan pemilihan strategi pemodelan yang sesuai.

Statistik deskriptif dan visualisasi data yang disajikan pada bagian ini menunjukkan bahwa dataset memiliki keragaman subjek dan variasi temporal yang cukup, sehingga layak digunakan untuk pengembangan dan evaluasi model GNN pada tugas VSR Bahasa Indonesia.

3.3.6. *Landmark Extraction*

Pada tahap *landmark extraction*, penelitian ini memanfaatkan *Face Mesh* untuk mengekstraksi titik-titik *landmark* wajah dari setiap frame video. *Face Mesh* menghasilkan total 468 *landmark* tiga dimensi yang merepresentasikan struktur wajah secara menyeluruh, mencakup area mata, hidung, rahang, dan mulut. Setiap

landmark ini menyediakan representasi geometris yang kaya untuk analisis gerakan wajah secara detail.

Namun demikian, untuk kebutuhan tugas VSR pada penelitian ini, hanya *landmark* yang berada pada area bibir yang digunakan. Pembatasan ini dilakukan karena informasi utama yang membentuk ujaran visual berasal dari pergerakan bibir, sedangkan area wajah lainnya cenderung memberikan informasi yang tidak relevan terhadap pembentukan kata. Selain itu, ukuran dataset yang relatif kecil berpotensi menyebabkan model mempelajari karakteristik individu (*subject-specific features*) apabila seluruh *landmark* wajah digunakan.

Dengan membatasi *landmark* hanya pada area bibir, model diarahkan untuk fokus mempelajari pola gerakan bibir yang membentuk kata dan frasa yang diucapkan, bukan menghafal ciri visual subjek tertentu. Pendekatan ini diharapkan dapat meningkatkan kemampuan generalisasi model serta menghasilkan representasi yang lebih relevan terhadap dinamika *visual speech* yang sebenarnya.

3.3.7. Graph Construction

Untuk mengubah sekumpulan titik koordinat menjadi struktur graf yang dapat diproses, penelitian ini menggunakan algoritma yang memfilter koneksi berdasarkan topologi wajah.

Segmen 3. 1 *Pseudocode Graph Construction*

```
Algorithm: ConstructLipGraph
FUNCTION build_edge_index(num_nodes=40, partition='lips'):

    // 1. Definisikan 40 landmark bibir dari MediaPipe
    LIPS_ALL = [0, 13, 14, 17, 37, ..., 415] // 40 landmark

    // 2. Mapping: MediaPipe index -> Node index (0-39)
    subset_map = {}
    FOR i = 0 to 39:
        mp_index = LIPS_ALL[i]
        subset_map[mp_index] = i

    // 3. Ambil semua koneksi dari MediaPipe Face Mesh
    all_connections = MediaPipe.FACEMESH_TESSELATION

    // 4. Filter: hanya edge antar landmark bibir
    edges = []
    FOR EACH (mp_i, mp_j) IN all_connections:
        IF mp_i IN LIPS_ALL AND mp_j IN LIPS_ALL:
            node_i = subset_map[mp_i] // Konversi ke 0-39
            node_j = subset_map[mp_j]
            // Buat edge bidirectional
            edges.append([node_i, node_j])
            edges.append([node_j, node_i])

    // 5. Format untuk PyTorch Geometric: (2, E)
    edge_index = transpose(edges)
    RETURN edge_index
END
```

Pada tahap *graph construction*, data *landmark* bibir direpresentasikan dalam bentuk graf untuk memungkinkan pemodelan hubungan spasial antar titik *landmark* menggunakan *Graph Neural Network* (GNN). Setiap *landmark* bibir diperlakukan sebagai sebuah *node*, sedangkan hubungan antar *landmark* direpresentasikan sebagai *edge* yang mencerminkan konektivitas anatomis alami pada struktur bibir.

Struktur graf dibangun dengan mengacu pada koneksi *tesselation* yang didefinisikan oleh *MediaPipe Face Mesh*. Pendekatan ini memastikan bahwa *edge* yang terbentuk merepresentasikan hubungan spasial yang realistis dan bermakna secara anatomis, dibandingkan dengan graf *fully-connected* yang berpotensi memperkenalkan hubungan yang tidak relevan. Dengan demikian, graf yang dihasilkan mampu mempertahankan topologi alami dari area bibir.

Pada penelitian ini, hanya *landmark* yang termasuk dalam area bibir (*lips partition*) yang digunakan dalam konstruksi graf. Seluruh koneksi *tesselation* dari MediaPipe difilter sehingga hanya *edge* yang menghubungkan *landmark* bibir yang dipertahankan. Setiap *edge* dibentuk secara dua arah untuk merepresentasikan graf tak berarah (*undirected graph*), sehingga informasi dapat mengalir secara simetris antar *node* selama proses agregasi pada GNN.

Untuk memastikan konsistensi antara jumlah *node* dan subset *landmark* yang digunakan, dilakukan pemetaan indeks *landmark* MediaPipe ke indeks lokal graf bibir. Proses ini menjamin bahwa setiap *node* dalam graf memiliki korespondensi yang tepat dengan *landmark* bibir yang diekstraksi. Struktur graf yang telah dibentuk kemudian digunakan secara konsisten pada seluruh *frame* video, sehingga perubahan yang dipelajari oleh model sepenuhnya berasal dari dinamika fitur *node*, bukan dari perubahan topologi graf.

Pendekatan konstruksi graf berbasis *MediaPipe Tesselation* ini diharapkan dapat membantu model GNN dalam menangkap pola hubungan spasial antar *landmark* bibir secara lebih efektif, sekaligus mengurangi risiko model mempelajari hubungan yang bersifat artifisial atau tidak relevan terhadap proses artikulasi ujaran visual.

3.3.8. *Speech-Level*

Pada penelitian ini, unit ujaran (*speech level*) dibedakan menjadi dua tingkat, yaitu kata (*word-level*) dan frasa (*phrase-level*). Pembagian ini dilakukan karena karakteristik temporal dan kompleksitas visual antara ujaran kata dan frasa memiliki perbedaan yang signifikan, terutama dalam durasi, pola transisi antar gerakan bibir, serta variasi dinamika artikulasi.

Merujuk pada penelitian-penelitian sebelumnya [3], pemodelan *visual speech recognition* pada tingkat kata dan frasa umumnya dilakukan secara terpisah untuk mengakomodasi perbedaan tersebut. Oleh karena itu, pada penelitian ini dikembangkan dua model yang berdiri sendiri, masing-masing untuk klasifikasi kata dan klasifikasi frasa. Pendekatan ini diharapkan dapat memungkinkan model untuk mempelajari representasi yang lebih spesifik dan efektif sesuai dengan tingkat ujaran yang dianalisis, serta meningkatkan performa klasifikasi pada masing-masing skenario.

3.3.9. *Feature Engineering*

Pada penelitian ini, proses *feature engineering* dirancang untuk merepresentasikan informasi visual gerakan bibir secara bertahap, mulai dari deskripsi spasial paling dasar hingga karakteristik dinamika temporal yang lebih kompleks. Pendekatan bertingkat ini bertujuan untuk menganalisis kontribusi masing-masing kelompok fitur terhadap kinerja model *Graph Neural Network* (GNN).


Secara khusus, fitur disusun dalam tiga tingkat representasi. Tingkat pertama menggunakan *normalized landmark coordinates* sebagai representasi spasial dasar. Tingkat kedua mengombinasikan *normalized landmark coordinates* dengan fitur geometris bibir, seperti rasio dan ukuran morfologis, untuk menangkap perubahan bentuk bibir. Tingkat ketiga menambahkan fitur kinematik, termasuk kecepatan dan percepatan pergerakan *landmark*, guna merepresentasikan dinamika temporal gerakan bibir secara eksplisit.

Dengan membandingkan performa model GNN pada ketiga tingkat fitur tersebut, penelitian ini bertujuan untuk mengevaluasi sejauh mana penambahan

informasi geometris dan kinematik mampu meningkatkan kemampuan model dalam membedakan *viseme* dan kata yang diucapkan.

Pendekatan bertingkat ini memungkinkan analisis terkontrol mengenai sejauh mana penambahan informasi geometris dan kinematik dapat meningkatkan kemampuan pemisahan kelas (*separability*) pada tugas *visual speech recognition*.

3.3.9.1. Normalized Coordinates



Gambar 3. 2 Koordinat *Node* yang Dinormalisasikan

merupakan representasi fitur dasar yang hanya menggunakan koordinat mentah *landmark* bibir dalam ruang tiga dimensi (x, y, z). Koordinat dinormalisasi menggunakan metode *min-max normalization* pada setiap sumbu (x, y, z) dan diterapkan secara global pada seluruh *frame* dalam satu video (*normalize per video*), bukan per *frame*. Pendekatan ini bertujuan untuk mempertahankan konsistensi spasial antar *frame* sekaligus mengurangi pengaruh skala dan posisi absolut wajah.

Fitur Normalisasi berfungsi sebagai *baseline* untuk menguji apakah informasi spasial mentah dari koordinat *landmark* saja sudah cukup untuk membedakan *viseme* dan kata yang diucapkan.


Secara umum, proses normalisasi koordinat didefinisikan sebagai berikut:

$$p_{\text{norm}} = \frac{p - p_{\min}}{p_{\max} - p_{\min}} \quad (2.19)$$

dengan $(p \in \{x, y, z\})$, serta $(p_{\min})$ dan $(p_{\max})$ masing-masing merepresentasikan nilai minimum dan maksimum dari koordinat (p) yang dihitung secara global pada seluruh *frame* dalam satu video. Hasil normalisasi berada pada rentang $([0, 1])$, sehingga setiap *node* pada graf memiliki skala fitur yang konsisten.

Normalisasi *node* ini digunakan sebagai *baseline* eksperimen untuk mengevaluasi sejauh mana informasi spasial mentah dari koordinat *landmark* bibir saja apakah sudah cukup untuk membedakan *viseme* dan kata yang diucapkan, sebelum menambahkan fitur geometris dan kinematik pada eksperimen lanjutan.

3.3.9.2. Fitur Geometris



Gambar 3. 3 Visualisasi Normalisasi *Node* Fitur Geometris

Seperti yang divisualisasikan pada Gambar 3.3, tingkatan fitur berikutnya memperkaya koordinat dasar dengan empat parameter geometris global yang secara eksplisit mengukur morfologi bibir selama proses berbicara. Parameter-parameter ini dirancang untuk menangkap konfigurasi bentuk bibir yang tidak selalu dapat direpresentasikan secara optimal hanya melalui koordinat mentah *landmark*.

Secara khusus, empat parameter geometris global yang digunakan meliputi *Mouth Aspect Ratio* (MAR), lebar bibir (*lip width*), tinggi bibir (*lip height*), serta sudut sudut bibir (*lip corner angle*). Keempat fitur ini dirancang untuk merepresentasikan karakteristik bentuk mulut secara eksplisit dan bersifat komplementer terhadap informasi koordinat *landmark* mentah.

Mouth Aspect Ratio (MAR) digunakan untuk mengukur proporsi vertikal terhadap horizontal dari bukaan mulut, sehingga mampu menangkap perbedaan bentuk mulut yang tinggi (*oval*) dan melebar (*wide*) selama artikulasi fonem. MAR didefinisikan sebagai rasio antara tinggi dan lebar mulut, yang dirumuskan sebagai:

$$\text{MAR} = \frac{h_{\text{mouth}}}{w_{\text{mouth}} + \varepsilon} \quad (2.20)$$

dengan h_{mouth} menyatakan jarak vertikal antara *landmark* bibir atas dan bawah, w_{mouth} menyatakan jarak horizontal antara sudut kiri dan kanan bibir, dan ε merupakan konstanta kecil untuk menghindari pembagian dengan nol. Nilai MAR yang lebih besar dari satu mengindikasikan bukaan mulut yang lebih tinggi (misalnya pada fonem a), sedangkan nilai yang lebih kecil dari satu menunjukkan konfigurasi mulut yang lebih melebar (misalnya pada fonem i atau e).

Selanjutnya, lebar bibir (*lip width*) merepresentasikan jarak Euclidean tiga dimensi antara sudut kiri dan kanan bibir. Fitur ini secara langsung mengukur tingkat peregangan horizontal bibir selama berbicara dan dirumuskan sebagai:

$$w_{\text{lip}} = \sqrt{(x_r - x_l)^2 + (y_r - y_l)^2 + (z_r - z_l)^2} \quad (2.21)$$

di mana (x_l, y_l, z_l) dan (x_r, y_r, z_r) masing-masing merupakan koordinat *landmark* sudut kiri dan kanan bibir. Dalam implementasi MediaPipe *Face Mesh*, *landmark* ini direpresentasikan oleh indeks 61 (kiri) dan 291 (kanan).

Tinggi bibir (*lip height*) digunakan untuk mengukur tingkat keterbukaan vertikal mulut, yang dihitung sebagai jarak Euclidean tiga dimensi antara bibir atas dan bibir bawah. Secara matematis, fitur ini dirumuskan sebagai:

$$h_{\text{lip}} = \sqrt{(x_b - x_t)^2 + (y_b - y_t)^2 + (z_b - z_t)^2} \quad (2.22)$$

dengan (x_t, y_t, z_t) dan (x_b, y_b, z_b) masing-masing menunjukkan koordinat *landmark* bibir atas dan bawah, yang pada MediaPipe *Face Mesh* diwakili oleh indeks 13 (atas) dan 14 (bawah). Nilai *lip height* yang besar mengindikasikan bukaan mulut yang lebar secara vertikal, yang penting dalam membedakan fonem vokal terbuka dan tertutup.

Parameter geometris terakhir adalah *lip corner angle*, yang merepresentasikan tingkat penyebaran atau pembulatan bibir. Sudut ini dihitung menggunakan dua vektor (v_1 & v_2) yang dibentuk dari titik bibir atas menuju sudut kiri dan kanan bibir. Secara formal, sudut tersebut didefinisikan sebagai:

$$\theta = \cos^{-1} \left(\frac{v_1 \cdot v_2}{|v_1| |v_2|} \right) \quad (2.23)$$

dengan:

$$v_1 = p_{\text{left}} - p_{\text{top}},$$

$$v_2 = p_{\text{right}} - p_{\text{top}}$$

Sudut yang lebih besar menunjukkan konfigurasi bibir yang menyebar (*spread*), seperti pada fonem i dan e, sedangkan sudut yang lebih kecil menunjukkan konfigurasi bibir yang membulat (*rounded*), seperti pada fonem o dan u.

Secara keseluruhan, kombinasi keempat fitur geometris ini memungkinkan model untuk menangkap dinamika dan morfologi bibir secara lebih diskriminatif,

terutama dalam konteks pengenalan kata berbasis gerakan bibir, di mana perbedaan bentuk mulut sering kali lebih informatif dibandingkan perubahan posisi absolut landmark semata.

3.3.9.3. Fitur Kinematik

Selain fitur spasial dan geometris, representasi fitur juga diperkaya dengan fitur dinamika, yang mencakup kecepatan (*velocity*) dan percepatan (*acceleration*) landmark bibir dalam ruang tiga dimensi. Fitur-fitur ini dirancang untuk menangkap perubahan posisi landmark dari waktu ke waktu, sehingga memungkinkan pemodelan karakteristik temporal dari gerakan bibir selama proses berbicara.

Kecepatan landmark dihitung sebagai selisih posisi antara *frame* ke- t dan *frame* sebelumnya. Secara matematis, vektor kecepatan didefinisikan sebagai

$$v_x = x_t - x_{t-1}, \quad (2.24)$$

$$v_y = y_t - y_{t-1}, \quad (2.25)$$

$$v_z = z_t - z_{t-1} \quad (2.26)$$

Komponen (v_x , v_y , v_z) masing-masing merepresentasikan kecepatan horizontal, vertikal, dan kedalaman (*depth*) dari pergerakan landmark bibir antar *frame*. Untuk menangkap intensitas gerakan tanpa memperhatikan arah, digunakan magnitudo kecepatan (*speed*) yang didefinisikan sebagai norma Euclidean dari vektor kecepatan:

$$\text{speed} = |v_t| = \sqrt{v_x^2 + v_y^2 + v_z^2} \quad (2.27)$$

Selanjutnya, percepatan landmark dihitung sebagai perubahan kecepatan antara dua *frame* berturut-turut, yang mencerminkan tingkat perubahan dinamika gerakan bibir. Vektor percepatan dirumuskan sebagai:

$$a_x = v_{x,t} - v_{x,t-1}, \quad (2.28)$$

$$a_y = v_{y,t} - v_{y,t-1}, \quad (2.29)$$

$$a_z = v_{z,t} - v_{z,t-1} \quad (2.30)$$

Mirip dengan kecepatan, magnitudo percepatan digunakan untuk merepresentasikan kekuatan perubahan gerakan secara keseluruhan tanpa memperhatikan arah tertentu. Fitur ini dihitung menggunakan norma Euclidean sebagai berikut:


$$\text{acc_mag} = |a_t| = \sqrt{a_x^2 + a_y^2 + a_z^2} \quad (2.31)$$

Dengan memasukkan komponen kecepatan dan percepatan ini, model memperoleh kemampuan untuk menangkap pola transisi temporal gerakan bibir, seperti perubahan cepat, perlambatan, dan akselerasi artikulasi. Informasi ini sangat krusial dalam tugas pengenalan ujaran berbasis gerakan bibir, di mana perbedaan antar kata sering kali lebih ditentukan oleh dinamika pergerakan dibandingkan oleh bentuk mulut statis pada satu *frame* tertentu.

3.3.10. Dataset Splitting

Pada penelitian ini, digunakan dua skema *data splitting* yang berbeda untuk mengevaluasi performa model secara komprehensif, yaitu *standard split* dan *Leave-One-Subject-Out* (LOSO). Kedua skema ini dirancang untuk menguji kemampuan model baik dalam kondisi pembagian data konvensional maupun pada skenario generalisasi lintas subjek.

3.3.10.1. *Standard Split*




Gambar 3. 4 Diagram Cara Kerja *Standard Split*

Skema *standard split* digunakan sebagai pendekatan evaluasi dasar dan selanjutnya disebut sebagai *standard* dalam penelitian ini. Pembagian data mengikuti skema yang digunakan pada penelitian sebelumnya [3], termasuk logika pembagian dan *random seed* yang sama, guna menjaga konsistensi dan memungkinkan perbandingan yang adil.

Pada skema ini, data dibagi menjadi tiga subset, yaitu *training*, *validation*, dan *testing*, dengan proporsi 80%, 10%, dan 10%. Proses pembagian dilakukan secara bertahap menggunakan fungsi *train_test_split* dari *scikit-learn*. Pembagian pertama memisahkan *data training* (80%) dan data sementara (20%), kemudian data sementara tersebut dibagi kembali menjadi *validation* (10%) dan *testing* (10%). Stratifikasi berdasarkan kelas diterapkan apabila jumlah sampel per kelas mencukupi, untuk menjaga distribusi kelas yang seimbang.

3.3.10.2. *Leave-One-Subject-Out* (LOSO)



Gambar 3. 5 Diagram Cara Kerja LOSO *Split*

Selain *standard split*, penelitian ini juga menerapkan skema *Leave-One-Subject-Out* (LOSO) yang didefinisikan secara khusus dalam penelitian ini untuk mengevaluasi kemampuan generalisasi model terhadap subjek yang tidak pernah dilihat sebelumnya.

Pada skema LOSO, satu subjek dipisahkan sepenuhnya sebagai *data testing*, sementara subjek lainnya digabungkan dan dibagi menjadi data *training* dan *validation* dengan proporsi 80% dan 20%. Proses ini dilakukan secara iteratif untuk setiap subjek dalam dataset. Dengan total delapan subjek, maka akan dihasilkan

delapan eksperimen LOSO yang berbeda, di mana masing-masing subjek secara bergantian berperan sebagai data uji.

Hasil evaluasi dari seluruh iterasi LOSO kemudian dirata-ratakan (*mean*). Pendekatan ini memberikan gambaran yang lebih robust terhadap performa model dan mengurangi bias yang disebabkan oleh karakteristik subjek tertentu.

3.3.11. *Modeling*

Tahap pemodelan dirancang secara bertingkat (*incremental*) untuk mengidentifikasi arsitektur yang paling efektif dalam memproses data graf spatiotemporal dari bibir. Skenario eksperimen dibagi menjadi tiga tahapan utama: evaluasi model spasial dasar (*baseline*), pengembangan model hibrida, dan optimasi arsitektur terbaik.

3.3.11.1. Evaluasi *Baseline (Spatial-Only)*

Pada tahap awal, pengujian difokuskan pada kemampuan model dalam mengekstrak fitur geometris dari setiap *frame* secara independen tanpa memperhatikan urutan waktu. Tujuannya adalah untuk menetapkan *baseline* kinerja ekstraksi fitur spasial. Tiga varian arsitektur GNN akan diuji:

- *Graph Convolutional Network* (GCN): Menggunakan operasi konvolusi spektral dasar pada graf.
- GraphSAGE: Menggunakan mekanisme sampling dan agregasi tetangga (*neighbor aggregation*) untuk skalabilitas.
- *Graph Isomorphism Network* (GIN): Menggunakan agregasi berbasis MLP dengan *sum aggregation* yang secara teoritis lebih ekspresif dalam membedakan struktur graf.


3.3.11.2. Pengembangan Model *Hybrid (Spatial-Temporal)*

Mengingat *Lip Reading* adalah tugas yang sangat bergantung pada dimensi waktu (urutan gerakan bibir), tahap kedua mengintegrasikan komponen temporal ke dalam model spasial terbaik. Output fitur dari lapisan GNN akan diteruskan ke dalam lapisan *Long Short-Term Memory* (LSTM) tipe *Bidirectional*. Arsitektur hibrida ini (GCN-LSTM, GraphSAGE-LSTM, dan GIN-LSTM) bertujuan untuk

menangkap dinamika pergerakan bibir antar-*frame* dan dependensi jangka pendek hingga menengah.

3.3.11.3. Optimasi Model Lanjutan (*Advanced Architecture*)

Tahap akhir berfokus pada penyempurnaan arsitektur hibrida dengan kinerja terbaik dari tahap-tahap sebelumnya. Pada tahap ini, mekanisme *State Space Model* (SSM), yaitu blok Mamba, akan diintegrasikan ke dalam arsitektur untuk meningkatkan kemampuan model dalam menangkap dependensi jangka panjang (*long-range dependencies*) yang telah terbukti meningkatkan hasil pada penelitian lainnya untuk kasus *Visual Speech Recognition*.



Gambar 3. 7 Arsitektur Model Pilihan GIN-LSTM-Mamba *End-to-End*

Pada tahap ini, blok Mamba dikonfigurasi dengan parameter $d_state = 16$, $d_conv = 4$, dan $expand = 2$ untuk meningkatkan kemampuan model dalam memodelkan dependensi temporal jangka panjang secara efisien. Parameter d_state berfungsi sebagai dimensi state internal SSM yang mengontrol kapasitas memori jangka panjang, d_conv digunakan untuk menangkap pola temporal lokal sebagai tahap awal sebelum pemrosesan sekuens, sedangkan $expand$ mengatur ekspansi dimensi dan mekanisme gating agar aliran informasi temporal dapat diseleksi secara adaptif tanpa menambah kompleksitas komputasi secara signifikan.

3.3.12. *Explainable* AI Menggunakan GNNExplainer

Untuk memvalidasi keputusan model dan memahami fitur bibir mana yang paling berpengaruh dalam klasifikasi, penelitian ini menerapkan metode interpretabilitas menggunakan GNNExplainer. Metode ini digunakan secara spesifik untuk menganalisis komponen spasial (*spatial features*) pada GIN dari arsitektur hybrid GIN-LSTM-Mamba.

Pendekatan ini bertujuan untuk menghasilkan *importance mask* yang menyoroti *node* (*landmark* bibir) dan *edge* (koneksi antar *landmark*) yang memiliki kontribusi terbesar terhadap prediksi kelas tertentu.

3.3.12.1. Adaptasi pada Model *Hybrid*

Mengingat GNNExplainer dirancang untuk *single graph instance*, sedangkan model yang diusulkan memproses data sekuensial (video), implementasi dilakukan dengan strategi berikut:

1. Isolasi Komponen Spasial (*GNNWrapper*): Dibuat sebuah modul *wrapper* yang mengekstrak lapisan GNN dari model utama. Modul ini memungkinkan analisis dilakukan pada tingkat *frame* dengan memintas sementara lapisan temporal (LSTM dan Mamba) untuk menghitung bobot fitur spasial secara langsung terhadap logit klasifikasi.
2. Analisis per-*frame*: Perhitungan *importance score* dilakukan secara independen untuk setiap *frame* dalam video, yang kemudian diagregasi (menggunakan *mean aggregation*) untuk mendapatkan gambaran fitur penting secara global untuk satu sampel kata.

3.3.12.2. Metode Perhitungan *Importance*

Penelitian ini menggunakan pendekatan berbasis gradien (*gradient-based importance*) karena efisiensi komputasi dan stabilitasnya dibandingkan optimasi *mask* iteratif. Prinsip utamanya adalah mengukur sensitivitas *output* prediksi terhadap perubahan fitur input.

Nilai kepentingan (*importance score*) untuk setiap *node* i pada fitur f dihitung menggunakan magnitudo gradien:

$$I_{i,f} = \left| x_{i,f} \cdot \frac{\partial \hat{y}}{\partial x_{i,f}} \right| \quad (2.32)$$

di mana:

- $I_{i,f}$: Skor kepentingan fitur f pada *node* i ,
- $\partial \hat{y}$: Turunan parsial dari *output* prediksi,
- $\partial x_{i,f}$: Turunan terhadap fitur *input*.

Sedangkan *Edge Importance* dihitung sebagai rata-rata dari *importance score* dua *node* yang dihubungkan oleh *edge* tersebut.

3.3.12.3. Visualisasi Hasil

Hasil analisis GNNExplainer divisualisasikan dalam dua bentuk untuk memudahkan interpretasi:

1. *Node Importance Heatmap*: Memetakan skor kepentingan ke dalam *FaceMesh* MediaPipe menggunakan *colormap*. *Node* dengan warna lebih panas (merah/kuning) mengindikasikan area bibir yang paling krusial bagi model dalam mengenali kata.
2. *Edge Importance Graph*: Menampilkan topologi graf dengan menonjolkan koneksi-koneksi (*edges*) yang memiliki bobot tertinggi, memperlihatkan struktur geometris bibir yang menjadi fokus atensi model.

BAB IV

HASIL DAN PEMBAHASAN


4.1. Hasil

4.1.1. Statistik Deskriptif & Visualisasi Data

Analisis awal dilakukan untuk memahami karakteristik dataset yang digunakan, meliputi distribusi jumlah video per subjek, distribusi per kelas kata dan frasa, serta statistik durasi video.

1. Distribusi Video per Subjek

Keseimbangan data antar subjek sangat penting dalam sistem pembacaan gerak bibir (*lip reading*) untuk mencegah model menjadi bias terhadap karakteristik fisik atau gaya bicara subjek tertentu. Gambar 4.1 memperlihatkan distribusi jumlah video yang dikumpulkan dari masing-masing subjek.



Gambar 4. 1 Distribusi Jumlah Video Setiap Subjek.


Berdasarkan grafik di atas, jumlah video yang didapatkan dari setiap subjek relatif seimbang, berkisar antara 700 hingga 796 video per subjek (gabungan kata dan frasa). Keseimbangan ini memastikan bahwa variasi data cukup representatif untuk melatih model yang *robust* dan generalis.

2. Distribusi Video per Kelas

Selain keseimbangan antar subjek, keseimbangan antar kelas (label) juga dianalisis untuk menentukan apakah diperlukan teknik augmentasi data atau *class weighting*. Tabel 4.1 berikut merincikan distribusi jumlah video untuk setiap kelas kata dan frasa di seluruh subjek.

Tabel 4. 1 Distribusi Jumlah Video per Kelas

No	Kelas (Kata/Frasa)	S1	S2	S3	S4	S5	S6	S7	S8	Total
A. Tingkat Kata										
1	Maaf	53	50	50	50	50	55	56	50	414
2	Tolong	53	50	50	50	51	55	52	50	411
3	Permisi	55	50	50	50	50	68	55	50	428
4	Halo	53	50	50	50	50	62	50	50	415
5	Mulai	54	50	50	50	50	56	51	50	411
6	Berhenti	51	50	50	50	50	55	52	50	408
7	Lanjut	56	50	50	50	50	55	64	50	425
8	Sakit	52	50	50	50	50	56	51	50	409
9	Kembali	52	50	50	50	50	58	57	50	417
10	Awas	59	50	50	50	50	56	50	50	415
<i>Subtotal Kata</i>		<i>538</i>	<i>500</i>	<i>500</i>	<i>500</i>	<i>501</i>	<i>576</i>	<i>538</i>	<i>500</i>	<i>4.153</i>
B. Tingkat Frasa										
11	Terimakasih	53	50	50	50	50	55	51	50	409
12	Saya Minta Tolong	52	50	50	50	50	55	51	50	408
13	Saya Minta Maaf	50	50	50	50	51	55	61	50	417
14	Minta Tolong	53	50	50	50	50	55	62	50	420
<i>Subtotal Frasa</i>		<i>208</i>	<i>200</i>	<i>200</i>	<i>200</i>	<i>201</i>	<i>220</i>	<i>225</i>	<i>200</i>	<i>1.654</i>
<i>Grand Total</i>		<i>746</i>	<i>700</i>	<i>700</i>	<i>700</i>	<i>702</i>	<i>796</i>	<i>763</i>	<i>700</i>	<i>5.807</i>



Gambar 4. 2 Jumlah Video Setiap Kelas untuk Kategori Kata (kiri) dan Frasa (Kanan).

Sebagaimana terlihat pada Tabel 4.1 dan Gambar 4.2, distribusi data antar kelas sangat seimbang (*balance*). Pada tingkat kata, jumlah sampel berkisar antara 408 hingga 428 video. Pada tingkat frasa, jumlah sampel berkisar antara 408 hingga 420 video. Karena tidak terdapat *class imbalance* yang signifikan, penelitian ini tidak menerapkan teknik augmentasi data maupun pembobotan kelas (*class weighting*) pada tahap pelatihan model.

3. Analisis Durasi Video

Analisis durasi dilakukan untuk menentukan panjang sekuens *input* yang optimal bagi model. Histogram durasi dan statistik rinci disajikan pada Tabel 4.2.

Tabel 4. 2 Statistik Durasi Video (Detik)

<i>Speech-Level</i>	No	Kelas	<i>Mean</i>	<i>Std</i>	<i>Min</i>	<i>Max</i>	<i>Median</i>
Kata	1	Maaf	2,14	0,57	0,40	4,26	2,13
	2	Tolong	2,24	0,82	0,31	4,96	2,16
	3	Permisi	2,44	0,75	1,20	4,77	2,42
	4	Halo	2,38	0,80	01,03	4,45	2,40
	5	Mulai	2,45	0,76	01,04	4,80	2,47
	6	Berhenti	2,66	0,88	0,99	9,27	2,80
	7	Lanjut	2,36	0,83	0,83	7,97	2,51
	8	Sakit	2,44	0,66	0,95	4,16	2,59
	9	Kembali	2,51	0,71	0,99	4,40	2,64
	10	Awas	2,45	0,71	01,03	04,02	2,63
	Rata-rata Kelas Kata		2,41	0,77	0,31	9,27	2,48
Frasa	11	Terimakasih	2,77	076	1,31	4,85	2,93

<i>Speech-Level</i>	No	Kelas	<i>Mean</i>	<i>Std</i>	<i>Min</i>	<i>Max</i>	<i>Median</i>
	12	Saya Minta Tolong	3,19	0,86	1,39	05,04	3,24
	13	Saya Minta Maaf	03,07	0,83	1,44	4,96	3,20
	14	Minta Tolong	2,70	0,77	0,96	4,31	2,88
	Rata-rata Kelas Frasa		2,93	0,83	0,96	05,04	03,04

Secara umum, rata-rata durasi video pada tingkat frasa (2,93 detik) lebih lama dibandingkan tingkat kata (2,41 detik). Terdapat beberapa *outlier* pada durasi maksimum, seperti pada kelas "Berhenti" yang mencapai 9,27 detik dan "Lanjut" 7,97 detik, yang kemungkinan disebabkan oleh jeda diam setelah pengucapan. Namun, nilai median yang berdekatan dengan nilai mean menunjukkan bahwa distribusi data cukup terpusat. Informasi durasi ini dapat digunakan sebagai dasar penentuan *padding* atau pemotongan (*trimming*) pada tahap *preprocessing*. Namun, karena mengacu pada riset sebelumnya [3] maka tetap disamakan *preprocessing* yaitu pemotongan klip dari tengah sebesar 30 *frame* untuk level kata dan 40 *frame* untuk level frasa.

4.1.2. Landmark Extraction

Tahap selanjutnya setelah pengumpulan data adalah ekstraksi fitur visual menggunakan MediaPipe *Face Mesh*. Prosesnya Adalah sebagai berikut:

1. Deteksi Wajah pada Seluruh Subjek

Hasil penerapan ekstraksi *landmark* pada kedelapan subjek penelitian diperlihatkan pada Gambar 4.3. Sistem berhasil mendeteksi geometris wajah secara konsisten meskipun terdapat variasi bentuk wajah, pencahayaan, dan atribut fisik (seperti penggunaan hijab pada beberapa subjek).



Gambar 4. 3 Visualisasi Ekstraksi *Landmark* pada 8 subjek. Jaring abu-abu (*grey mesh*) merepresentasikan *Full FaceMesh*, sedangkan titik hijau (*green nodes*) menandakan 40 titik *landmark* bibir yang dipilih sebagai fitur utama.

Pada Gambar 4.3, titik-titik berwarna hijau menunjukkan *Region of Interest* (ROI) yang difokuskan, yaitu area bibir. Dari total 468 titik *landmark* yang dihasilkan oleh MediaPipe, penelitian ini menyeleksi 40 titik koordinat (*nodes*) yang secara spesifik memetakan pergerakan bibir.

2. Tahapan Pemrosesan *Frame*



Gambar 4. 4 Tahapan Pemrosesan Data Visual: (kiri) *Original Frame*, (tengah) Visualisasi *Overlay* Penuh MediaPipe *Face Mesh* dan *landmark* bibir, (kanan) Hasil akhir *Node Only* (40 titik *landmark* bibir) yang digunakan sebagai *input* model.

Representasi *mode* pada Gambar 4.4 disimpan dan digunakan sebagai *input* numerik bagi model *machine learning*. Dengan hanya menggunakan koordinat *landmark*, dimensi data menjadi jauh lebih kecil dan komputasi menjadi lebih efisien dibandingkan memproses keseluruhan piksel video, sekaligus menjaga privasi visual subjek karena wajah asli tidak lagi dibutuhkan dalam proses pelatihan (*training*).

4.1.3. Graph Construction

Setelah mendapatkan 40 titik *landmark* bibir (*nodes*), langkah selanjutnya adalah mendefinisikan hubungan antar titik tersebut (*edges*). Penelitian ini menggunakan melainkan memanfaatkan struktur topologi alami wajah yang disediakan oleh MediaPipe seperti di Gambar 4.4.

4.1.4. Feature Engineering

Pada tahap *feature engineering*, penelitian ini menerapkan skenario tingkatan representasi fitur untuk memperkaya informasi yang digunakan oleh model dalam mengenali pola gerakan bibir. Pendekatan bertingkat ini dirancang untuk mengintegrasikan informasi spasial, geometris, dan temporal secara bertahap, sehingga representasi fitur menjadi lebih komprehensif tanpa bergantung pada satu jenis informasi saja.

Tingkatan pertama terdiri dari fitur spasial, yaitu koordinat *landmark* bibir dalam ruang tiga dimensi (x, y, z) yang telah dinormalisasi. Fitur ini merepresentasikan posisi dasar *landmark* pada setiap frame dan berfungsi sebagai representasi geometris paling dasar.

Tingkatan kedua menambahkan fitur geometris global, yang secara eksplisit merepresentasikan morfologi dan konfigurasi bentuk bibir. Fitur pada tingkatan ini meliputi *Mouth Aspect Ratio* (MAR), lebar bibir (*lip width*), tinggi bibir (*lip height*), serta sudut bibir (*lip corner angle*). Penambahan fitur ini bertujuan untuk menangkap karakteristik bentuk mulut yang tidak selalu dapat direpresentasikan secara optimal hanya melalui koordinat *landmark* mentah.

Tingkatan ketiga memperluas representasi fitur dengan memasukkan fitur dinamika temporal, yaitu kecepatan dan percepatan *landmark* dalam ruang tiga dimensi. Fitur ini mencakup komponen kecepatan (v_x, v_y, v_z) , magnitudo kecepatan (*speed*), komponen percepatan (a_x, a_y, a_z) , serta magnitudo percepatan. Informasi ini digunakan untuk menangkap pola transisi gerakan bibir antar-*frame* yang bersifat temporal.

4.1.5. *Splitting*

Pembagian dataset dilakukan dengan dua skenario untuk mengevaluasi kinerja model, yaitu *Standard Splitting* (pembagian acak) dan *Leave-One-Subject-Out* (LOSO).

1. *Standard Splitting*

Pada skenario ini, data dibagi secara acak dengan rasio 80% untuk *Train*, 10% untuk *Validation*, dan 10% untuk *Test*. Tabel berikut menunjukkan distribusi jumlah sampel untuk kategori Kata dan Frasa.

Tabel 4. 3 Persebaran Data menggunakan *Standard Splitting*

<i>Dataset</i>	<i>Train</i>	<i>Validation</i>	<i>Test</i>	<i>Total</i>	<i>Train %</i>	<i>Val %</i>	<i>Test %</i>
Kata	3322	415	416	4153	80	10	10
Frasa	1323	165	166	1654	80	10	10

2. *Leave-One-Subject-Out (LOSO)*

Skenario kedua menggunakan metode LOSO dimana satu subjek digunakan sepenuhnya sebagai data *test*, sedangkan subjek lainnya dibagi menjadi *train* dan *validation*.

4.1.6. *Modeling*

4.1.6.1. Konfigurasi Global

Untuk memastikan perbandingan yang adil antar arsitektur, seluruh model menggunakan konfigurasi dasar yang seragam untuk parameter dimensi *hidden layer*, *dropout*, dan konfigurasi LSTM. Rincian konfigurasi global disajikan pada Tabel 4.4 .

Tabel 4. 4 Konfigurasi Global yang digunakan Tiap Model

Parameter	Nilai / Konfigurasi	Keterangan
<i>Num Nodes</i>	40	Titik <i>landmarks</i> bibir
<i>Input Features</i>	3	Koordinat (x, y, z)
<i>Output Classes</i>	10	Klasifikasi kata (<i>Words</i>)
<i>Hidden Dimension</i>	256	Dimensi fitur spasial
<i>GNN Layers</i>	2	Kedalaman lapisan graf
<i>Dropout</i>	0.5	Regularisasi
<i>LSTM Hidden</i>	128	Dimensi temporal
<i>LSTM Layers</i>	2	<i>Bidirectional</i> (Total output 256)
<i>Mamba Config</i>	d_state=16, d_conv=4, expand=2	Khusus model GIN LSTM Mamba

4.1.6.2. Ikhtisar Arsitektur Model

Tabel 4.10 merangkum karakteristik utama dari setiap model yang diuji, termasuk jenis lapisan spasial, lapisan temporal, dan total parameter yang dapat dilatih (*trainable parameters*).

Tabel 4. 5 Ikhtisar Arsitektur Setiap Model

Model	Type	Spatial Layer	Lapisan Temporal	Total Parameter	FLOPS
GCN	<i>Spatial-only</i>	GCN	<i>None</i>	70,4K	85,70M
GraphSAGE	<i>Spatial-only</i>	GraphSAGE	<i>None</i>	135,7K	85,70M
GIN	<i>Spatial-only</i>	GIN	<i>None</i>	135,7K	85,70M
GCN_LSTM	<i>Hybrid</i>	GCN	LSTM (<i>Bi-Dir</i>)	859,9K	110,87M
GraphSAGE_LSTM	<i>Hybrid</i>	GraphSAGE	LSTM (<i>Bi-Dir</i>)	926,2K	110,87M
GIN_LSTM	<i>Hybrid</i>	GIN	LSTM (<i>Bi-Dir</i>)	992,5K	110,87M
GIN_LSTM_Mamba	<i>Advanced Hybrid</i>	GIN	LSTM + <i>Mamba</i>	1.448,7K	129,02M

4.1.7. Hasil Eksperimen

Bagian ini memaparkan hasil eksperimen secara bertahap untuk mengevaluasi efektivitas fitur dan arsitektur model. Eksperimen dimulai dari model spasial dasar (*baseline*).

4.1.7.1.1. Baseline Spatial Models (Non-Temporal)


Sebagai langkah awal, evaluasi dilakukan pada model berbasis *Graph Neural Network* murni (GCN, GraphSAGE, GIN) tanpa komponen temporal. Tujuannya adalah untuk mengukur seberapa banyak informasi yang dapat diekstraksi hanya dari fitur spasial per *frame*.

Tabel 4. 6 Hasil Evaluasi *Baseline Spatial Modes (Split Standard)*

<i>Data Splitting</i>	<i>Speech-Level</i>	<i>Feature Engineering</i>	<i>Model</i>	<i>val_acc</i>	<i>test_acc</i>
<i>Standard</i>	Kata	<i>Normalized Node</i>	GCN	20,96	17,31
			GraphSAGE	18,55	15,38
			GIN	25,78	21,63
		<i>Normalized Node + Geometry Features</i>	GCN	27,95	29,09
			GraphSAGE	24,34	23,56
			GIN	33,49	31,97
		<i>Normalized Node + Geometry + Motion Features</i>	GCN	30,84	33,17
			GraphSAGE	24,58	25,00
			GIN	43,61	44,47
	Frasa	<i>Normalized Node</i>	GCN	38,18	38,55
			GraphSAGE	42,42	39,16
			GIN	41,82	40,96
		<i>Normalized Node + Geometry Features</i>	GCN	45,45	38,55
			GraphSAGE	43,64	37,35
			GIN	45,45	40,96
		<i>Normalized Node + Geometry + Motion Features</i>	GCN	43,64	39,16
			GraphSAGE	39,39	39,16
			GIN	49,70	46,99


Hasil pada Tabel 4.6 menunjukkan bahwa tanpa pemrosesan temporal, akurasi model cenderung rendah (tertinggi ~44% untuk kata dan ~46% untuk frasa). Namun, terlihat pola konsisten bahwa GIN unggul dibandingkan GCN dan GraphSAGE di hampir seluruh skenario fitur, terutama pada yang memiliki informasi kinematik.

Training History - Model Spatial-Only pada Fitur: Normalized Node, Normalized Node with Geometric Features, dan Normalized Node with Geometric + Motion Features (Words)



Gambar 4. 5 Training History Model Spatial Only Level Kata

Training History - Model Spatial-Only pada Fitur: Normalized Node, Normalized Node with Geometric Features, dan Normalized Node with Geometric + Motion Features (Phrases)



Gambar 4. 6 Training History Model Spatial Only Level Frasa

4.1.7.2. Hybrid Spatial-Temporal Models (GNN + LSTM)


Untuk menangkap dinamika pergerakan bibir, komponen LSTM ditambahkan pada arsitektur spasial. Tabel 4.7 menyajikan peningkatan performa yang signifikan setelah integrasi temporal.

Tabel 4. 7 Hasil Evaluasi *Hybrid Spatial-Temporal Models (Standard Split)*

<i>Data Splitting</i>	<i>Speech-Level</i>	<i>Feature Engineering</i>	<i>Model</i>	<i>val_acc</i>	<i>test_acc</i>
Standard	Kata	Normalized Node	GCN LSTM	24,34	29,09
			GrSAGE LSTM	32,29	32,69
			GIN LSTM	60,00	59,38
		Normalized Node + Geometry	GCN LSTM	72,77	70,91
			GraphSAGE LSTM	81,20	79,81
			GIN LSTM	86,75	87,26
		Normalized Node + Geometry + Motion	GCN LSTM	75,42	75,72
			GraphSAGE LSTM	80,72	81,73
			GIN LSTM	88,92	87,98
	Frasa	Normalized Node	GCN LSTM	29,70	31,33
			GraphSAGE LSTM	35,76	38,55
			GIN LSTM	57,58	52,41
		Normalized Node + Geometry	GCN LSTM	64,24	60,24
			GraphSAGE LSTM	72,12	68,07
			GIN LSTM	93,94	94,58
		Normalized Node + Geometry + Motion	GCN LSTM	62,42	55,42
			GraphSAGE LSTM	77,58	75,90
			GIN LSTM	97,58	93,98


Integrasi LSTM memberikan lonjakan akurasi drastis. GIN-LSTM kembali menjadi model terbaik. Menariknya, pada level Frasa, tingkatan fitur Normalisasi + Geometri memberikan hasil paling optimal dengan akurasi *test* mencapai 94.58%, lebih tinggi dibandingkan tingkatan yang dengan fitur kinematik. Hal ini mengindikasikan bahwa untuk rangkaian kata yang lebih panjang (frasa), fitur bentuk global yang stabil lebih membantu model dibandingkan fitur kinematik instan (kecepatan/percepatan) yang mungkin memiliki *noise* variasi tinggi.

Training History - Hybrid Spatial-Temporal Model pada Fitur: Normalized Node, Normalized Node with Geometric Features, dan Normalized Node with Geometric + Motion Features (Words)



Gambar 4. 7 Training History Model Hybrid (Spatial-Temporal) Level Kata

Training History - Hybrid Spatial-Temporal Model pada Fitur: Normalized Node, Normalized Node with Geometric Features, dan Normalized Node with Geometric + Motion Features (Phrases)



Gambar 4. 8 Training History Model Hyrbid (Spatial-Temporal) Level Frasa


4.1.7.3. Advanced Modeling

Berdasarkan keunggulan GIN-LSTM, eksperimen dilanjutkan dengan mengintegrasikan blok Mamba untuk meningkatkan kemampuan model menangkap dependensi jangka panjang (*long-range dependencies*) secara efisien.

Tabel 4. 8 Hasil Evaluasi Model GIN-LSTM-Mamba

<i>Data Splitting</i>	<i>model</i>	<i>Speech-Level</i>	<i>Feature Engineering</i>	<i>val acc</i>	<i>test acc</i>
<i>Standard</i>	GIN_LSTM_Mamba	Kata	<i>Normalized Node</i>	74,46	72,84
			<i>Normalized Node + Geometry</i>	94,94	92,55
			<i>Normalized Node + Geometry + Motion</i>	97,59	97,84
		Frasa	<i>Normalized Node</i>	63,03	55,42
			<i>Normalized Node + Geometry</i>	98,79	96,98
			<i>Normalized Node + Geometry + Motion</i>	99,39	95,78

Penambahan Mamba menyempurnakan performa model hingga mencapai akurasi *test* 97.84% pada level kata dan 96.98% pada level. Grafik *training history* dan laporan klasifikasi di bawah ini memperlihatkan konvergensi model yang stabil dan presisi tinggi di setiap kelas.



Gambar 4. 9 *Training History (Loss dan Accuracy) Model GIN-LSTM-Mamba Terbaik pada Level Kata (Atas) dan Level Frasa F1 (Bawah).*

Tabel 4. 9 *Classification Report untuk Level Kata pada Split Standard*

Kelas	<i>Precision</i>	<i>Recall</i>	<i>F1-score</i>	<i>Test Total Data</i>
1 Maaf	1,0000	0,9524	0,9756	42
2 Tolong	0,9302	0,9756	0,9524	41
3 Permisi	0,9767	0,9767	0,9767	43
4 Halo	0,9750	0,9512	0,9630	41
5 Mulai	1,0000	1,0000	1,0000	41
6 Berhenti	0,9524	0,9756	0,9639	41
7 Lanjut	0,9556	1,0000	0,9773	43
8 Sakit	1,0000	1,0000	1,0000	41
9 Kembali	1,0000	0,9524	0,9756	42
10 Awas	1,0000	1,0000	1,0000	41
<i>macro avg</i>	0,9790	0,9784	0,9784	416
<i>weighted avg</i>	0,9790	0,9784	0,9784	416

Tabel 4. 10 *Classification Report* untuk Level Frasa pada *Standard Split*

<i>Class</i>	<i>Precision</i>	<i>Recall</i>	<i>F1-score</i>	<i>Test Total Data</i>
11. Terimakasih	1,0000	1,0000	1,0000	41
12. Saya Minta Tolong	0,9286	0,9512	0,9398	41
13. Saya Minta Maaf	0,9756	0,9524	0,9639	42
14. Minta Tolong	0,9762	0,9762	0,9762	42
<i>macro avg</i>	0,9701	0,9699	0,9700	166
<i>weighted avg</i>	0,9702	0,9699	0,9700	166

4.1.7.4. *Generalization Analysis (LOSO Split)*

Untuk menguji ketahanan (*robustness*) model terhadap subjek yang belum pernah dilihat sebelumnya, model dievaluasi menggunakan skenario *Leave-One-Subject-Out* (LOSO). Untuk melihat skenario LOSO lengkap pada tiap subjek ada pada Lampiran 1.

Tabel 4. 11 Rata-rata Performa Model tiap Subjek pada Skenario LOSO

<i>Speech-Level</i>	<i>Feature Engineering</i>	<i>mean val acc</i>	<i>mean test acc</i>	<i>mean test loss</i>
Kata	<i>Normalized Node</i>	73,32	22,09	3,28
	<i>Normalized Node + Geometry Features</i>	94,65	45,66	2,81
	<i>Normalized Node + Geometry + Motion Features</i>	96,97	53,50	2,52
Frasa	<i>Normalized Node</i>	59,44	27,61	2,25
	<i>Normalized Node + Geometry Features</i>	96,55	60,51	2,18
	<i>Normalized Node + Geometry + Motion Features</i>	97,89	54,31	2,96

Terlihat penurunan performa yang wajar karena variasi bentuk bibir antar individu (*inter-subject variability*). Namun, terdapat temuan menarik dimana fitur dengan kinematik (*motion*) memberikan generalisasi terbaik untuk kata (53,50%), sedangkan tanpa kinematik (*motion*) lebih unggul untuk frasa (60,51%). Hal ini mengonfirmasi bahwa informasi kinematik krusial untuk membedakan kata pendek yang cepat, sementara konsistensi bentuk geometris saja lebih andal untuk mengenali frasa panjang pada subjek baru.

4.1.7.5. Komparasi dengan Penelitian Terdahulu (*Benchmarking*)

Sebagai validasi akhir, performa GIN-LSTM-Mamba dibandingkan dengan Sebagai tahap validasi akhir, penelitian ini melakukan komparasi terhadap metode *State-of-the-Art* (SOTA) terdahulu, yaitu arsitektur LRCN (CNN+LSTM) dengan konfigurasi 3-Conv Layers. Model ini direplikasi ulang menggunakan dataset yang sama untuk memastikan perbandingan yang adil (*apple-to-apple*).

Perlu dicatat bahwa hasil replikasi model LRCN pada eksperimen ini menunjukkan performa yang lebih tinggi melampaui akurasi yang dilaporkan dalam publikasi aslinya. Hal ini menetapkan standar *baseline* yang sangat kompetitif dan ketat.


Tabel 4. 12 Perbandingan GIN-LSTM-Mamba vs LRCN (*Standard Split & LOSO*)

Split Method	Speech-Level	Metode	Val Acc (%)	Test Acc (%)	Test Loss
Standard	Kata	GIN-LSTM-Mamba	97,59	97,84	0,1
		Replikasi LRCN (3-Conv)	99,75	97,84	0,09
	Frasa	GIN-LSTM-MAMBA	99,39	95,78	0,32
		Replikasi LRCN (3-Conv)	99,39	98,17	0,05
LOSO (Generalisasi)	Kata	GIN-LSTM-Mamba	96,97	53,5	2,52
		Replikasi LRCN (3-Conv)	96,91	26,95	3,85
	Frasa	GIN-LSTM-Mamba	96,55	60,51	2,18
		Replikasi LRCN (3-Conv)	96,77	41,67	2,47

4.1.8. *Explainable* AI menggunakan GNNExplainer

Untuk memvalidasi cara kerja model GIN-LSTM-Mamba, dilakukan analisis interpretabilitas menggunakan GNNExplainer. Analisis ini bertujuan untuk memvisualisasikan bagian manakah dari geometris bibir yang dianggap paling krusial oleh model dalam membedakan setiap kata, baik dari sisi titik (*node*) maupun garis hubung (*edge*).


4.1.8.1. Analisis *Node Importance*



Gambar 4. 10 Visualisasi *Node Importance*

Berdasarkan hasil visualisasi *importance heatmap*, terlihat kecenderungan yang jelas bahwa model memberikan atensi atau bobot yang lebih signifikan pada *node* di area bibir luar (*Outer Lips*). Angka pada gambar 4.11 mengindikasikan urutan *importance* untuk 10 *node* terbaik secara urut. Kumpulan *Node* yang berada di garis kontur luar ini terdeteksi memiliki warna yang lebih terang dibandingkan *node* di bagian dalam mulut. Hal ini mengindikasikan bahwa model lebih mengandalkan perubahan bentuk siluet luar bibir seperti pelebaran sudut bibir atau tinggi bukan bibir sebagai fitur utama untuk mengklasifikasikan kata, alih-alih hanya berfokus pada area internal mulut.

4.1.8.2. Analisis *Edge Importance*



Gambar 4. 11 Visualisasi *Edge Importance*

Selain titik koordinat, GNNExplainer juga menyoroti koneksi antar-titik (*edges*) yang paling berpengaruh terhadap aliran informasi spasial. Hasil visualisasi menunjukkan pola koneksi yang sangat spesifik, di mana garis-garis dengan bobot tertinggi (warna paling terang) terkonsentrasi pada tiga area utama:

- Bagian Bawah: Menangkap pergerakan mulut dan bibir bawah.
- Bagian Atas Kiri dan Atas Kanan: Menangkap tarikan otot pada lengkungan bibir atas.

Pola ini mengonfirmasi bahwa model secara efektif mempelajari struktur geometris bibir dengan memantau lengkungan pada sisi kiri, kanan, dan bawah untuk menangkap dinamika artikulasi yang halus namun distinktif antar kata.

4.2. Pembahasan

Berdasarkan hasil eksperimen yang telah dipaparkan pada sub-bab sebelumnya, bagian ini akan membahas analisis mendalam mengenai pengaruh fitur teknik, evolusi arsitektur model, serta kemampuan generalisasi model yang diusulkan dibandingkan dengan metode konvensional.

4.2.1. Analisis Efektivitas Representasi Tingkatan Fitur

Hasil eksperimen menunjukkan pola yang menarik terkait relevansi fitur terhadap kompleksitas data ucapan (kata vs. frasa).

1. Dominasi Fitur Kinematik pada Level Kata: Pada klasifikasi tingkat kata, fitur yang memuat geometris dan kinematik secara konsisten memberikan akurasi tertinggi. Hal ini logis mengingat kata-kata pendek sering kali dibedakan oleh gerakan artikulasi yang cepat dan eksplosif. Informasi dinamis mengenai seberapa cepat bibir membuka atau menutup (Δv , Δa) menjadi diskriminator yang lebih kuat daripada sekadar bentuk geometris statis.
2. Keunggulan Fitur Geometris pada Level Frasa: Sebaliknya, pada klasifikasi tingkat frasa, terutama dalam skenario LOSO, fitur geometris justru lebih unggul. Frasa terdiri dari rangkaian kata yang lebih panjang, di mana *noise* pergerakan instan (kinematik) dapat terakumulasi dan membingungkan model, terutama ketika berpindah antar subjek. Fitur global seperti *Mouth Aspect Ratio* (MAR) memberikan konteks bentuk yang lebih stabil dan konsisten sepanjang sekuens, membantu model menangkap struktur kalimat secara utuh tanpa terdistraksi oleh variasi kecepatan bicara antar individu.

4.2.2. Analisis Evolusi Arsitektur Model

Peningkatan performa yang signifikan dari model *spatial-only* ke model *hybrid* menegaskan bahwa *lip reading* adalah masalah *spatio-temporal* yang tidak dapat diselesaikan hanya dengan melihat bentuk bibir per *frame*.

1. Superioritas GIN dibandingkan GCN dan GraphSAGE: Di antara model berbasis graf murni, *Graph Isomorphism Network* (GIN) terbukti paling efektif. Hal ini disebabkan oleh kemampuan agregasi GIN yang lebih

ekspresif (menggunakan MLP) yang memungkinkannya membedakan struktur graf yang sangat mirip.

2. Peran Krusial Komponen Temporal (LSTM & Mamba): Penambahan LSTM memberikan lonjakan akurasi terbesar (dari ~40% menjadi ~90%+). Ini membuktikan bahwa informasi fonemik tersimpan dalam transisi antar bentuk, bukan pada bentuk itu sendiri. Integrasi blok Mamba pada tahap akhir memberikan penyempurnaan performa. *Mekanisme State Space Model* (SSM) pada Mamba memungkinkan model menangkap dependensi jangka panjang dengan lebih efisien secara komputasi dibandingkan hanya menumpuk layer LSTM, menghasilkan konvergensi yang lebih baik pada data uji.

4.2.3. Analisis Generalisasi dan *Robustness* (*Standard* vs *LOSO*)

Salah satu temuan terpenting dalam penelitian ini adalah kesenjangan performa antara *Standard Split* dan *Leave-One-Subject-Out* (LOSO). *Standard Split*: Seluruh model mencapai akurasi sangat tinggi (>97%). Hal ini mengindikasikan bahwa jika model pernah "melihat" gaya bicara subjek saat latihan, model dapat mengenali ucapan subjek tersebut dengan sangat presisi.

LOSO Terjadi penurunan performa pada semua model, yang mencerminkan tantangan nyata variasi antar-subjek (*inter-subject variability*). Setiap orang memiliki bentuk bibir, gigi, dan gaya artikulasi yang unik. Namun, model GIN-LSTM-Mamba menunjukkan ketahanan (*robustness*) yang jauh lebih baik dibandingkan *baseline*. Dengan mempertahankan akurasi ~53% (Kata) dan ~60% (Frasa) pada subjek yang benar-benar baru, model ini membuktikan bahwa representasi fitur berbasis *landmark* (titik koordinat) lebih universal dibandingkan representasi visual mentah.

4.2.4. Komparasi dengan Pendekatan Berbasis Piksel (LRCN)

Perbandingan dengan replikasi model LRCN (CNN+LSTM) menyoroti kelemahan fundamental dari pendekatan berbasis piksel untuk tugas ini. Meskipun LRCN mencapai akurasi mendekati sempurna pada *Standard Split* (98-99%), performanya anjlok drastis pada skenario LOSO (~26% untuk Kata). Ini

menunjukkan gejala *overfitting* terhadap identitas visual. Model LRCN cenderung "menghafal" karakteristik spesifik wajah subjek (seperti warna kulit, pencahayaan, atau tekstur wajah) alih-alih mempelajari pola gerak bibir yang esensial. Sebaliknya, pendekatan yang diusulkan (*Graph/Landmark-based*) bekerja pada ruang fitur yang lebih abstrak dan clean. Dengan hanya memproses koordinat geometris, model GIN-LSTM-Mamba "buta" terhadap variasi visual yang tidak relevan (pencahayaan, warna kulit), memungkinkannya untuk menggeneralisasi pola gerak bibir dengan jauh lebih efektif pada subjek yang belum pernah dilihat sebelumnya. Hasil ini mengukuhkan bahwa untuk aplikasi dunia nyata yang menuntut adaptabilitas terhadap pengguna baru, pendekatan berbasis *Graph/Landmark* jauh lebih potensial dibandingkan pendekatan berbasis piksel murni.

4.2.5. Analisis Interpretabilitas Fitur Bibir

Analisis menggunakan GNNExplainer mengungkapkan bahwa model GIN-LSTM-Mamba telah berhasil mempelajari struktur anatomis bibir secara efektif. Visualisasi menunjukkan adanya korelasi kuat antara titik referensi (*node*) dan garis hubung (*edge*) yang berfokus pada area bibir luar (*outer lips*).

Model secara konsisten memberikan bobot tinggi pada *node* yang membentuk siluet luar bibir, serta memperkuat koneksi struktural pada bagian bawah rahang dan sudut bibir atas (kiri-kanan). Kombinasi fokus ini menunjukkan bahwa model memprioritaskan informasi kontur global, di mana pergerakan garis luar dan tarikan sudut bibir dianggap lebih distinktif dan tahan terhadap oklusi dibandingkan fitur detail di bagian dalam mulut. Hal ini mengonfirmasi bahwa model memprediksi kata berdasarkan dinamika bentuk (morfologi) bibir yang valid secara fisiologis.

BAB V

KESIMPULAN DAN SARAN

5.1. Kesimpulan

Berdasarkan hasil eksperimen dan analisis yang telah dilakukan dalam pengembangan sistem *Lip Reading* menggunakan arsitektur berbasis *Graph Neural Network* (GNN), dapat ditarik beberapa kesimpulan utama:

1. Efektivitas Model GIN-LSTM-Mamba Penelitian ini berhasil mengembangkan model hibrida GIN-LSTM-Mamba yang mengintegrasikan ekstraksi fitur spasial berbasis graf, pemrosesan sekuensial LSTM, dan efisiensi komputasi *State Space Model* (Mamba). Model ini terbukti memberikan performa terbaik dibandingkan arsitektur *baseline* lainnya (GCN, GraphSAGE, dan GIN murni) maupun model hibrida tanpa Mamba.
2. Performa Akurasi dan Generalisasi
 - Pada skenario pengujian standar (*Standard Split*), model mencapai akurasi 97,84% untuk tingkat Kata dan 95,78% untuk tingkat Frasa.
 - Pada skenario generalisasi antar-subjek (*Leave-One-Subject-Out / LOSO*), model menunjukkan keunggulan signifikan dibandingkan metode konvensional berbasis piksel (LRCN). Model yang diusulkan mampu mempertahankan akurasi rata-rata 53,50% (Kata) dan 60,51% (Frasa), jauh melampaui LRCN yang hanya mencapai ~26% pada tingkat Kata dan ~41% pada tingkat Frasa. Hal ini membuktikan bahwa pendekatan berbasis *landmark* lebih *robust* terhadap variasi visual antar individu.
3. Peran Fitur Kinematik dan Geometris

Terdapat perbedaan karakteristik fitur yang optimal berdasarkan panjang ucapan. Fitur Normalisasi + Geometris + Kinematik yang memuat informasi kecepatan dan percepatan terbukti paling efektif untuk klasifikasi Kata pendek. Sebaliknya, Fitur Normalisasi + Geometris tanpa Kinematik lebih unggul untuk klasifikasi Frasa, karena mampu memberikan konteks bentuk yang stabil sepanjang rangkaian kalimat.

4. Validasi Interpretabilitas (*Explainable AI*)

Analisis menggunakan GNNExplainer mengonfirmasi bahwa model bekerja secara valid dengan memfokuskan atensi pada area anatomis yang relevan, yaitu bibir luar (*outer lips*), serta pergerakan pada mulut bawah dan sudut bibir. Model tidak hanya mempelajari pola statistik semata, melainkan menangkap dinamika morfologi bibir yang sesuai dengan prinsip artikulasi manusia.

5.2. Saran

Meskipun penelitian ini telah mencapai hasil yang menjanjikan, masih terdapat beberapa aspek yang dapat ditingkatkan untuk pengembangan selanjutnya:

1. Peluasan Dataset (Subjek dan Kosakata)

Salah satu tantangan terbesar dalam skenario LOSO adalah tingginya variasi gaya bicara antar individu. Penelitian selanjutnya sangat disarankan untuk menambah jumlah subjek secara signifikan guna memperkaya variasi data latih. Semakin banyak ragam bentuk bibir dan gaya bicara yang dipelajari model, kemampuan generalisasinya akan semakin meningkat. Selain itu, penambahan jumlah kelas kata dan variasi frasa yang lebih kompleks diperlukan agar sistem lebih relevan untuk diterapkan dalam komunikasi sehari-hari.

2. Eksplorasi Varian Arsitektur *Graph Neural Network* Lanjutan

Penelitian selanjutnya disarankan untuk memperluas cakupan arsitektur model di luar pendekatan spasial standar. Eksplorasi dapat diarahkan pada model berbasis Attention (seperti *Graph Attention Networks*) untuk pembobotan fitur yang lebih adaptif, pendekatan Spectral-based yang memanfaatkan teori pemrosesan sinyal graf, serta arsitektur *Graph Transformers* yang mampu menangkap konteks global dan hubungan antar-titik yang kompleks secara lebih komprehensif. Implementasi pada Perangkat *Edge (Real-Time)* mengingat pendekatan berbasis *landmark* memiliki dimensi data yang jauh lebih kecil dibandingkan video berbasis piksel (hanya 40 titik koordinat dibandingkan ribuan piksel per *frame*),

metode ini memiliki potensi besar untuk dijalankan pada perangkat dengan daya komputasi rendah (*edge devices*) seperti *smartphone* atau kacamata pintar (*smart glasses*). Pengembangan selanjutnya dapat berfokus pada optimasi model (seperti *quantization* atau *pruning*) untuk mengukur latensi dan efisiensi daya dalam penggunaan *real-time*.

3. Penanganan Variasi Pose Wajah Ekstrem

Meskipun ekstraksi *landmark* lebih tahan terhadap pencahayaan, performanya dapat menurun pada kondisi pose wajah yang ekstrem. Penelitian selanjutnya dapat mengintegrasikan mekanisme *pose normalization* atau melatih model dengan data augmentasi rotasi kepala yang lebih agresif untuk meningkatkan ketahanan sistem pada kondisi penggunaan yang tidak ideal.

DAFTAR PUSTAKA

- [1] S. Hamama and M. A. Nurseha, “Memahami Komunikasi Verbal Dalam Interaksi Manusia,” vol. 3, no. 2, pp. 136–143, 2023, [Online]. Available: <https://ejournal.iainu-kebumen.ac.id/index.php/selasar>
- [2] Badan Pusat Statistik, “Disabilitas - Long Form Sensus Penduduk 2020.”
- [3] Aripin and A. Setiawan, “*Indonesian Lip-Reading Detection and Recognition Based on Lip Shape Using Face Mesh and Long-Term Recurrent Convolutional Network*,” *Applied Computational Intelligence and Soft Computing*, vol. 2024, 2024, doi: 10.1155/2024/6479124.
- [4] G. M. Rahmatullah, S.-J. Ruan, and L. P.-H. Li, “*Recognizing Indonesian words based on visual cues of lip movement using deep learning*,” *Measurement*, vol. 250, p. 116968, 2025, doi: <https://doi.org/10.1016/j.measurement.2025.116968>.
- [5] T. Exarchos, G. N. Dimitrakopoulos, A. G. Vrahatis, G. Chrysosvitsiotis, Z. Zachou, and E. Kyrodimos, “*Lip-Reading Advancements: A 3D Convolutional Neural Network/Long Short-Term Memory Fusion for Precise Word Recognition*,” *BioMedInformatics*, vol. 4, no. 1, pp. 410–422, 2024, doi: 10.3390/biomedinformatics4010023.
- [6] D. S. Khafaga, H. A. H. Mahmoud, N. S. Alghamdi, and A. A. Albraikan, “*Novel Algorithm Utilizing Deep Learning for Enhanced Arabic Lip Reading Recognition*.” [Online]. Available: www.ijacsa.thesai.org
- [7] P. Ma, Y. Wang, J. Shen, S. Petridis, and M. Pantic, “*Lip-reading with Densely Connected Temporal Convolutional Networks*,” Sep. 2020, doi: 10.1109/WACV48630.2021.00290.
- [8] Q. T. Ngoc, S. Lee, and B. C. Song, “*Facial landmark-based emotion recognition via directed graph neural network*,” *Electronics (Switzerland)*, vol. 9, no. 5, May 2020, doi: 10.3390/electronics9050764.
- [9] C. Sheng, X. Zhu, H. Xu, M. Pietikäinen, and L. Liu, “*Adaptive Semantic-Spatio-Temporal Graph Convolutional Network for Lip Reading*,” *IEEE*

- Trans Multimedia*, vol. 24, pp. 3545–3557, 2022, doi: 10.1109/TMM.2021.3102433.
- [10] T. Swain, S. Sinha, A. Singh, K. Verma, and S. Das, “*Human Pose Estimation Using GNN*,” in *2022 International Conference on Advancements in Smart, Secure and Intelligent Computing (ASSIC)*, 2022, pp. 1–5. doi: 10.1109/ASSIC55218.2022.10088410.
- [11] M. , H. C. E. Angioi, *Systematic Literature Reviews*. University Press of Florida, 2023.
- [12] A. M. Sarhan, N. M. Elshennawy, and D. M. Ibrahim, “*HLR-Net: A Hybrid Lip-Reading Model Based on Deep Convolutional Neural Networks*,” *Computers, Materials and Continua*, vol. 68, no. 2, pp. 1531–1549, Apr. 2021, doi: 10.32604/cmc.2021.016509.
- [13] N. Zulfa, N. Suciati, and S. C. Hidayati, “*Improved Lip-Reading Language Using Gated Recurrent Units*”.
- [14] H. Huang *et al.*, “*A Novel Machine Lip Reading Model*,” in *Procedia Computer Science*, Elsevier B.V., 2021, pp. 1432–1437. doi: 10.1016/j.procs.2022.01.181.
- [15] S. Liu, S. Huang, W. Fu, and J. C. W. Lin, “*A Descriptive Human Visual Cognitive Strategy Using Graph Neural Network for Facial Expression Recognition*,” *International Journal of Machine Learning and Cybernetics*, vol. 15, no. 1, pp. 19–35, Jan. 2024, doi: 10.1007/s13042-022-01681-w.
- [16] T. Afouras, J. S. Chung, A. Senior, O. Vinyals, and A. Zisserman, “*Deep Audio-Visual Speech Recognition*,” *IEEE Trans Pattern Anal Mach Intell*, vol. 44, no. 12, pp. 8717–8727, 2022, doi: 10.1109/TPAMI.2018.2889052.
- [17] Y. J. Ahn, J. Park, S. Park, J. Choi, and K.-E. Kim, “*SyncVSR: Data-Efficient Visual Speech Recognition with End-to-End Crossmodal Audio Token Synchronization*,” Jun. 2024, [Online]. Available: <http://arxiv.org/abs/2406.12233>
- [18] S. A. Jakhete and N. Kulkarni, “*A Comprehensive Survey and Evaluation of MediaPipe Face Mesh for Human Emotion Recognition*,” in *2024 8th International Conference on Computing, Communication, Control and*

- Automation (ICCUBEA)*, 2024, pp. 1–8. doi: 10.1109/ICCUBEA61740.2024.10775188.
- [19] Google, “*Face Landmarker keypoints*,” *Google AI for Developers* – https://ai.google.dev/edge/mediapipe/solutions/vision/face_landmarker.
- [20] S. Bloemheugel, J. van den Hoogen, and M. Atzmueller, “*Graph Construction on Complex Spatiotemporal Data for Enhancing Graph Neural Network-Based Approaches*,” *Int J Data Sci Anal*, vol. 18, no. 2, pp. 157–174, 2024, doi: 10.1007/s41060-023-00452-2.
- [21] M. Grohe, “*The Logic of Graph Neural Networks*,” Apr. 2021, [Online]. Available: <http://arxiv.org/abs/2104.14624>
- [22] H. Leong FWA and H. Leong Fwa, “*Fine-Grained Detection Of Academic Emotions With Spatial Fine-Grained Detection of Academic Emotions with Spatial Temporal Graph Attention Networks Using Facial Landmarks Temporal Graph Attention Networks Using Facial Landmarks Fine-Grained Detection of Academic Emotions With Spatial Temporal Graph Attention Networks Using Facial Landmarks*,” 2022. [Online]. Available: https://ink.library.smu.edu.sg/sis_research
- [23] H. Zhang and M. Xu, “*Neighbour-level Message Interaction Encoding for Improved Representation Learning on Graphs*,” Apr. 2024, [Online]. Available: <http://arxiv.org/abs/2404.09809>
- [24] A. Longa *et al.*, “*Graph Neural Networks for Temporal Graphs: State of the Art, Open Challenges, and Opportunities*,” Feb. 2023, [Online]. Available: <http://arxiv.org/abs/2302.01018>
- [25] T. N. Kipf and M. Welling, “*Semi-Supervised Classification with Graph Convolutional Networks*,” Feb. 2017, [Online]. Available: <http://arxiv.org/abs/1609.02907>
- [26] W. L. Hamilton, R. Ying, and J. Leskovec, “*Inductive Representation Learning on Large Graphs*,” Sep. 2018, [Online]. Available: <http://arxiv.org/abs/1706.02216>

- [27] K. Xu, W. Hu, J. Leskovec, and S. Jegelka, “*How Powerful are Graph Neural Networks?*,” Feb. 2019, [Online]. Available: <http://arxiv.org/abs/1810.00826>
- [28] “*Visual Speech Recognition Using 3D CNN and LSTMS*,” *REST Journal on Data Analytics and Artificial Intelligence*, vol. 3, no. 3, pp. 31–39, Sep. 2024, doi: 10.46632/jdaai/3/3/4.
- [29] A. Gu and T. Dao, “*Mamba: Linear-Time Sequence Modeling with Selective State Spaces*,” May 2024, [Online]. Available: <http://arxiv.org/abs/2312.00752>
- [30] Y. Guo *et al.*, “*Data-centric Graph Learning: A Survey*,” Nov. 2024, [Online]. Available: <http://arxiv.org/abs/2310.04987>
- [31] F. Del Pup, A. Zanola, L. F. Tshimanga, A. Bertoldo, L. Finos, and M. Atzori, “*The Role of Data Partitioning on The Performance of EEG-Based Deep Learning Models In Supervised Cross-Subject Analysis: A Preliminary Study*,” May 2025, [Online]. Available: <http://arxiv.org/abs/2505.13021>
- [32] R. Ying, D. Bourgeois, J. You, M. Zitnik, and J. Leskovec, “*GNNExplainer: Generating Explanations for Graph Neural Networks*,” Nov. 2019, [Online]. Available: <http://arxiv.org/abs/1903.03894>

LAMPIRAN

Lampiran 1. Hasil Evaluasi Lengkap LOSO *Splitting* pada Model GIN-LSTM-Mamba dan LRCN-3CONV.

Model	Speech-Level	Feature Engineering	Subjek	<i>best_val_acc</i>	<i>test_acc</i>	<i>test_loss</i>
gin_lstm_mamba	Kata	<i>Normalized Nod</i>	1. Natural	74,14	18,03	3,51
			2. Pointy Natural	74,28	19,40	3,30
			3. Cupids Bow	71,82	30,00	2,39
			4. Thin	71,55	19,20	3,42
			5. Unilip	72,37	26,55	2,98
			6. Bestung	72,77	19,97	3,79
			7. Smear	74,83	24,35	2,63
			8. Glamor	74,83	19,20	4,19
		Rata-rata		73,32	22,09	3,28
		<i>Normalized Node + Geometry Features</i>	1. Natural	95,57	30,86	4,24
			2. Pointy Natural	95,49	52,20	2,00
			3. Cupids Bow	94,25	50,80	2,92
			4. Thin	93,71	41,60	3,79
			5. Unilip	94,39	39,52	2,92
			6. Bestung	93,30	48,09	2,21
			7. Smear	95,02	49,81	2,04
			8. Glamor	95,49	52,40	2,34
		Rata-rata		94,65	45,66	2,81
		<i>Normalized Node + Geometry + Motion Features</i>	1. Natural	97,51	48,14	3,21
			2. Pointy Natural	97,13	65,80	1,23
			3. Cupids Bow	97,26	49,60	3,15
			4. Thin	96,99	52,20	3,03
			5. Unilip	96,72	50,30	2,82
			6. Bestung	95,95	48,26	2,69
			7. Smear	96,96	53,53	2,06
			8. Glamor	97,26	60,20	1,98
		Rata-rata		96,97	53,50	2,52

Model	Speech-Level	Feature Engineering	Subjek	best_val_acc	test_acc	test_loss
	Frasa	Normalized Node	1. Natural	58,62	32,21	2,18
			2. Pointy Natural	62,89	26,50	2,85
			3. Cupids Bow	57,73	35,00	2,58
			4. Thin	63,57	22,00	2,70
			5. Unilip	64,60	22,89	2,16
			6. Bestung	50,87	29,09	2,21
			7. Smear	63,29	38,22	1,48
			8. Glamor	53,95	15,00	1,82
		Rata-rata		59,44	27,61	2,25
		Normalized Node + Geometry	1. Natural	97,93	40,87	4,17
			2. Pointy Natural	96,91	71,00	1,52
			3. Cupids Bow	95,88	81,00	0,84
			4. Thin	97,25	43,50	3,51
			5. Unilip	96,56	46,77	2,86
			6. Bestung	94,77	54,55	2,78
			7. Smear	96,50	72,89	0,98
			8. Glamor	96,56	73,50	0,79
		Rata-rata		96,55	60,51	2,18
		Normalized Node + Geometry + Motion	1. Natural	98,62	41,83	4,52
			2. Pointy Natural	97,59	82,00	0,87
			3. Cupids Bow	97,59	74,00	0,94
			4. Thin	97,25	34,00	4,31
			5. Unilip	98,63	45,27	3,37
			6. Bestung	98,61	57,73	3,05
			7. Smear	98,25	50,67	2,44
			8. Glamor	96,56	49,00	4,18
		Rata-rata		97,89	54,31	2,96
lrcn_3conv	Kata	-	1. Natural	95,14	19,96	3,73
			2. Pointy Natural	98,21	27,20	3,75
			3. Cupids Bow	97,53	19,20	3,38
			4. Thin	96,98	32,60	3,95
			5. Unilip	96,02	25,40	4,63

Model	Speech-Level	Feature Engineering	Subjek	best val acc	test acc	test loss
			6. Bestung	97,21	32,47	3,85
			7. Smear	95,97	33,21	2,67
			8. Glamor	98,21	25,60	4,87
		Rata-rata		96,91	26,95	3,85
	Frasa	-	1. Natural	95,14	25,48	3,42
			2. Pointy Natural	98,61	48,50	2,44
			3. Cupids Bow	95,49	41,00	1,77
			4. Thin	98,96	65,00	1,11
			5. Unilip	98,61	25,00	4,42
			6. Bestung	98,24	54,09	1,54
			7. Smear	93,66	39,29	2,20
			8. Glamor	95,49	35,00	2,84
		Rata-rata		96,77	41,67	2,47