

**DETEKSI CITRA KEBAKARAN MENGGUNAKAN
METODE DETEKSI OBJEK *SUPERPIXEL* DAN DETR**

Proposal Tugas Akhir

NIM 2211110014

Arvinanto Bahtiar



PROGRAM STUDI SARJANA SAINS DATA

FAKULTAS INFORMATIKA

UNIVERSITAS TELKOM

PURWOKERTO

2025

LEMBAR PENGESAHAN
DETEKSI CITRA KEBAKARAN MENGGUNAKAN
METODE DETEKSI OBJEK *SUPERPIXEL* DAN DETR

Detection of Wildfire Images Using Superpixel and DETR Object Detection
Method

NIM: 2211110014

Arvinanto Bahtiar

Proposal ini diajukan sebagai usulan pembuatan tugas akhir pada

Program Studi Sarjana Sains Data

Fakultas Informatika

Universitas Telkom Purwokerto

Purwokerto, X Mei 2025

Menyetujui

Calon Pembimbing I,

Andi Prademon Yunus, S.T., M.Sc.Eng., Ph.D

NIP: <NIP>

ABSTRAK

Kebakaran hutan dan lahan merupakan bencana lingkungan yang berdampak luas terhadap ekosistem, kesehatan, serta perekonomian. Oleh karena itu, dibutuhkan metode deteksi yang akurat dan efisien untuk meminimalkan dampak negatifnya. Penelitian ini mengusulkan metode deteksi objek api dan asap pada citra menggunakan kombinasi segmentasi *superpixel* dan model *Detection Transformer* (DETR). *Superpixel* digunakan untuk mengekstraksi dan merepresentasikan wilayah semantik penting dalam gambar secara lebih terstruktur, sehingga menghasilkan token visual yang lebih bermakna sebagai input bagi model DETR. Dataset yang digunakan adalah *Flame and Smoke Detection Dataset* (FASDD) yang terdiri dari berbagai citra api dan asap dari kamera pengawas, UAV, dan sumber citra satelit. Evaluasi dilakukan menggunakan metrik *precision*, *recall*, *average precision* (AP), dan *mean average precision* (mAP). Hasil penelitian ini diharapkan dapat memberikan kontribusi terhadap pengembangan model deteksi kebakaran yang akurat, efisien, dan siap diterapkan pada skenario dunia nyata.

Kata kunci: deteksi api dan asap, DETR, superpixel, deteksi objek

ABSTRACT

Forest and land fires are environmental disasters that have widespread impacts on ecosystems, public health, and the economy. Therefore, an accurate and efficient detection method is required to minimize these negative effects. This study proposes a method for detecting fire and smoke objects in images using a combination of superpixel segmentation and the Detection Transformer (DETR) model. Superpixels are used to extract and represent semantically important regions in the image in a more structured manner, resulting in more meaningful visual tokens as input for the DETR model. The dataset used is the Flame and Smoke Detection Dataset (FASDD), which consists of various fire and smoke images captured from surveillance cameras, UAVs, and satellite sources. Evaluation is carried out using precision, recall, average precision (AP), and mean average precision (mAP) metrics. The results of this study are expected to contribute to the development of a fire detection model that is accurate, efficient, and applicable in real-world scenarios.

Keywords: *fire and smoke detection, DETR, superpixel, object detection*

DAFTAR ISI

LEMBAR PENGESAHAN	ii
Abstrak.....	iii
<i>Abstract</i>.....	iv
DAFTAR ISI	v
DAFTAR GAMBAR	vii
DAFTAR TABEL	viii
BAB 1 Pendahuluan.....	Error! Bookmark not defined.
1.1. Latar Belakang	9
1.2. Perumusan Masalah	10
1.3. Batasan Masalah.....	11
1.4. Tujuan Penelitian.....	11
1.5. Rencana Kegiatan.....	Error! Bookmark not defined.
1.6. Jadwal Kegiatan	Error! Bookmark not defined.
BAB 2 Kajian Pustaka	13
2.1 Kajian Pustaka.....	13
2.2 Landasan Teori	19
2.2.1 Kebakaran	19
2.2.2 <i>Simple Linear Iterative Clustering</i> (SLIC)	19
2.2.3 Deteksi Objek.....	20
2.2.4 Detection Transformer (DETR)	21
2.2.5 Precision.....	22
2.2.6 Recall.....	23
2.2.7 Intersection over Union (IoU).....	24
2.2.8 Average Precision.....	24
2.2.9 Mean Average Precision (mAP).....	24
BAB 3 Alur Pemodelan	25
3.1 Subjek dan Objek Penelitian	25
3.2 Alat dan Bahan Penelitian.....	25
3.2.1 Alat Penelitian.....	25

3.2.2	Bahan Penelitian.....	25
3.3	Alur Penelitian	25
3.3.1	Identifikasi Masalah	26
3.3.2	Studi Literatur	26
3.3.3	Pengumpulan Data	26
3.3.4	Preprocessing	27
3.3.5	Pemodelan DETR.....	28
3.3.6	Evaluasi Kinerja Model.....	28
3.3.7	Analisis Hasil dan Kesimpulan	29

DAFTAR GAMBAR

Gambar 1.1 Alur Diagram Rencana Kegiatan.....	Error! Bookmark not defined.
Gambar 2. 1 Ilustrasi Luaran SLIC	20
Gambar 2. 2 Contoh Luaran Deteksi Objek.....	21
Gambar 2. 3 Arsitektur DETR Pada Proses Training.....	22
Gambar 3. 1 Diagram Alur Penelitian.....	26
Gambar 3. 2 Sampel Dataset FASDD	27

DAFTAR TABEL

Tabel 2. 1 Tinjauan Penelitian.....	15
-------------------------------------	----

BAB I

PENDAHULUAN

1.1. Latar Belakang

Kebakaran merupakan salah satu bencana yang paling parah di lingkungan liar seperti pegunungan dan hutan, yang dapat menimbulkan rangkaian dampak serius seperti kerugian ekonomi besar, polusi udara yang parah, kematian manusia dan satwa, serta pencemaran lingkungan [1]. Pada tahun 2022, kebakaran menimbulkan sekitar 17.040 korban di seluruh dunia, termasuk 3.790 jiwa meninggal, angka tertinggi sejak 2013 [2]. Sistem peringatan dini kebakaran sangat penting diterapkan untuk meminimalkan kerugian.

Metode konvensional dalam mendeteksi kebakaran sangat bergantung pada keterlibatan manusia pada proses pemantauannya, sehingga keandalannya sering terpengaruh oleh faktor eksternal seperti kondisi cuaca buruk (awan, kabut) yang menghambat pengamatan [3]. Respon dan interpretasi manual yang bergantung pada manusia di lapangan juga sering kali terlambat, sehingga api dapat menyebar lebih luas sebelum upaya pemadaman dimulai.

Dalam deteksi kebakaran terdapat dua pendekatan utama yaitu berbasis sensor dan berbasis *Computer Vision*. Sistem sensor, yang mencakup pendeteksi gas, asap, suhu, dan nyala api, sering mengalami keterbatasan berupa respons lambat dan jangkauan yang sempit sehingga kurang efektif untuk pemantauan wilayah luas [4]. Sebaliknya, metode *Computer Vision* memanfaatkan analisis citra dari kamera untuk mengidentifikasi nyala api dan asap secara real time, menawarkan cakupan area lebih luas, akurasi yang lebih tinggi, serta kemudahan instalasi. Pendekatan ini juga unggul dalam hal skalabilitas dan kemudahan pengelolaan, sehingga sangat cocok untuk infrastruktur pengawasan kebakaran modern [5].

Salah satu contoh tugas dalam bidang computer vision adalah deteksi objek. Deteksi objek bertujuan untuk menemukan dan mengklasifikasikan setiap kemunculan objek dari satu atau beberapa kelas dalam suatu gambar [6]. *Simple Linear Iterative Clustering* (SLIC) adalah salah satu algoritma *superpixel* yang paling banyak digunakan dalam pengolahan citra untuk mengelompokkan piksel

berdasarkan kemiripan dalam ruang warna CIELAB dan kedekatan spasial pada bidang citra sehingga menghasilkan segmen kecil dengan ukuran dan bentuk yang relatif seragam serta mematuhi batas objek secara presisi. Metode *superpixel* biasa digunakan untuk *salient object detection* dan segmentasi dengan beban komputasi yang rendah, karena setiap *superpixel* menyimpan informasi lokal yang kaya dan mereduksi redundansi data [7].

Beberapa metode deteksi objek terkini seperti *Detection Transformer* (DETR) dan *You Only Look Once* (YOLO) menggunakan *backbone* CNN yang kuat untuk ekstraksi fitur spasial dan hierarkis, sehingga mampu mencapai performa setara *state-of-the-art* [8][9]. Namun, keunggulan akurasi ini didapatkan dengan beban komputasi yang tinggi, memerlukan sumber daya GPU besar dan latensi inferensi yang relatif lama.

Dalam penelitian ini akan menggabungkan keunggulan SLIC *superpixel* sebagai tahap modul tambahan pada model DETR untuk pemangkasan token. Dengan demikian, struktur *end-to-end* akan memanfaatkan SLIC untuk mengurangi jumlah token yang diproses, lalu DETR sebagai model utama dalam o=deteksi objek untuk memprediksi *bounding box* dan klasifikasi objek secara efisien berdasarkan masukan token yang jumlahnya sudah tereduksi.

1.2. Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, penelitian ini bertujuan untuk mengatasi permasalahan berikut:

1. Bagaimana implementasi *superpixel* dan model DETR dapat membantu mendeteksi adanya peristiwa kebakaran?
2. Bagaimana akurasi dan bobot komputasi metode DETR dan *superpixel* dalam mendeteksi objek api dan asap pada peristiwa kebakaran?
3. Apa saja tantangan utama dalam mendeteksi objek api dan asap pada peristiwa kebakaran menggunakan metode *superpixel* dan DETR.

1.3. Tujuan Penelitian

Penelitian ini bertujuan untuk membangun dan mengevaluasi metode DETR dan superpixel guna mendeteksi peristiwa kebakaran melalui objek api dan asap, secara khusus tujuan yang ingin dicapai dalam penelitian ini adalah:

1. Membangun model deteksi api dan asap pada peristiwa kebakaran menggunakan metode *superpixel* dan DETR.
2. Menilai efektivitas metode *Superpixel*-DETR dalam mendeteksi api dan asap pada peristiwa kebakaran.
3. Mengidentifikasi keunggulan dan keterbatasan metode *Superpixel*-DETR dalam mendeteksi api dan asap pada peristiwa kebakaran.

1.4. Manfaat Penelitian

Penelitian ini diharapkan memberikan kontribusi baik dari sisi akademis maupun praktis, terutama dalam konteks pengembangan model deteksi objek berbasis transformer dalam deteksi peristiwa kebakaran. Manfaat yang dapat diambil dari penelitian ini antara lain:

1. Kontribusi akademis sebagai literatur dan studi yang mengintegrasikan algoritma SLIC *superpixel* sebagai modul tambahan pada model *Detection Transformer* (DETR) untuk pemangkasan token (*token pruning*).
2. Menyediakan hasil empiris eksperimen dan evaluasi kuantitatif terkait efektivitas serta keunggulan dan keterbatasan dari penggabungan metode *Superpixel*-DETR dalam mendeteksi nyala api dan asap.
3. Penerapan Interpretabilitas pada DETR dengan modul tambahan SLIC *superpixel* dalam mengetahui token penting dalam deteksi api dan asap

1.5. Batasan Masalah

Penelitian ini memiliki ruang lingkup yang telah ditentukan secara eksplisit untuk menjaga fokus, keterukuran, dan ketercapaian target dalam batas waktu serta sumber daya yang tersedia. Berikut adalah batasan-batasan masalah penelitian yang ditetapkan:

1. Fokus utama penelitian adalah implementasi *superpixel* dan DETR dalam mendeteksi api dan asap pada peristiwa kebakaran berdasarkan citra atau gambar.
2. Analisis kinerja metode *Superpixel*-DETR terkait dengan faktor-faktor akurasi (Precision, Recall, AP, dan mAP) dan komputasi (GFLOPs), dan tidak mencakup uji coba integrasi ke sistem aplikasi secara langsung.
3. Data yang digunakan merupakan data gambar dari *Flame and Smoke Detection Dataset* (FASDD) kategori *Computer Vision* (FASDD_CV) yang bersumber dari berbagai sosial media, *open-access datasets*, lukisan, dan *web crawling*.

BAB 2

LANDASAN TEORI

2.1 Tinjauan Pustaka

Proses pengumpulan data dalam penelitian ini dimulai dengan kajian pustaka, yang berfungsi untuk melengkapi informasi dan memperjelas fokus masalah. Beberapa artikel jurnal yang relevan dengan topik dan metode yang digunakan pada penelitian ini dipilih untuk dijadikan sumber utama.

Penelitian mengenai efisiensi arsitektur transformer saat ini menjadi fokus utama karena mekanisme self-attention konvensional memakan biaya komputasi besar akibat interaksi antar seluruh token yang berskala kuadratik terhadap panjang sekuens. Yang et al. [10] menangani tantangan ini dengan mengusulkan strategi pemangkasan token adaptif berbasis *closeness-centrality* yang memanfaatkan algoritma teori graf untuk membuang sekuens input redundan berdasarkan jarak fitur dan informasi lokasi token. Pendekatan kompresi yang lebih agresif kemudian dikembangkan oleh Wei et al. [11] melalui modul Joint Token Pruning and Squeezing (TPS) yang tidak hanya membuang token redundan, tetapi juga menggabungkan fitur esensial dari token yang dipangkas ke dalam token utama (host token) melalui mekanisme fusi berbasis *cosine similarity*. Implementasi strategi pemangkasan adaptif ini terbukti mampu memitigasi risiko hilangnya informasi kontekstual pada subjek maupun latar belakang citra yang sering kali menjadi penyebab utama penurunan akurasi pada metode pemangkasan tradisional.

Lew et al. [12] melangkah ke arsitektur transformer dengan *Superpixel Tokenization for ViT* (SuiT), yang menggantikan patch grid dengan token superpiksel (average + max pooling), meningkatkan Top-1 accuracy DeiT-Tiny dari 72,2 % ke 75,7 % dan memberikan keunggulan pada berbagai tugas transfer learning tanpa post-processing.

Penelitian [13] kemudian memfokuskan pada aplikasi asap hutan melalui SLIC dan penggabungan superpiksel kustom dengan SVM RBF, mencapai akurasi deteksi asap 77 %, false alarm 14 %, missed detection 9 % pada citra Xiaoxing'anling, namun hanya pada level blok *region*.

Seiring kebutuhan deteksi api/asap yang dapat berjalan real-time, Fang et al. [14] mengusulkan pipeline tiga tahap yakni *keyframe extraction*, CNN, dan *superpixel localization*, meraih precision 96% dan F1-score 90% untuk *bounding-box* api di video kamera pengawasan atau CCTV.

Dunnings & Breckon [15] mengevaluasi arsitektur CNN ringan (FireNet dan InceptionV1-OnFire) untuk full-frame detection dan localization via SLIC + CNN per *superpixel*, mencapai precision region 84 % dengan throughput hingga 17 FPS. Penelitian selanjutnya [16] mencoba menambahkan inovasi dengan pemodelan berbasis graf, menambahkan Graph Convolutional Network pada *superpixel segmentation* untuk dataset FLAME dan Chongli, menghasilkan MIOU 92,34 % dan inferensi 0,0207s per citra, hasil tersebut 3 hingga 6 kali lebih cepat dari *pixel-level* GCN tradisional.

Sheng et al. [17] memadukan SLIC dengan DBSCAN *clustering* pada fitur *superpixel* dan dilanjut dengan CNN untuk klasifikasi kluster smoke/fire, meraih TPR 96,7 % (fire) serta AAR > 94 % pada 3.000 citra eksperimen.

Penelitian [18] menyempurnakan *region proposal superpixel* dengan *Cauchy Mixture* dan LDB, diteruskan pada model ESE-ShuffleNet, berhasil mencapai *boundary recall* (BR) 94,5 %, *achievable segmentation accuracy* (ASA) 97,3 % pada BSDS500 dan akurasi 99,61 % (Foggia) pada deteksi tingkat *frame*. Terakhir, Wang et al. [19] menyingkirkan decoder pada transformer dengan DFFT (dua encoder ringan tanpa NMS) untuk mendeteksi api/asap secara *real-time*, meraih mAP 87,40 % tanpa mengorbankan kecepatan inferensi.

Sementara ini Lew et al. [12] telah menunjukkan bahwa tokenisasi *superpixel* secara signifikan meningkatkan koherensi semantik dan akurasi pada Vision Transformer untuk klasifikasi gambar. Namun, hingga kini belum ada penelitian yang menggabungkan kekuatan representasi superpiksel tersebut dengan set-prediction DETR untuk tugas *bounding-box detection* terkhusus pada deteksi kebakaran. Oleh karena itu, penelitian ini mengeksplorasi penggunaan SLIC *superpixel tokenization* yang kemudian diteruskan pada DETR decoder dan *prediction head* untuk membentuk model deteksi api dan asap *end-to-end*.

Tabel 2. 1 Ringkasan Penelitian terdahulu

No.	Judul dan Tahun	Pembahasan	Metode	Kelebihan dan Kekurangan	Perbedaan Penelitian
1	Adaptive Token Pruning for Vision Transformer, Yang et al., 2024 [10]	Membahas tantangan biaya komputasi tinggi pada model <i>Vision Transformer</i> (ViT) akibat redundansi fitur pada token. Penelitian ini bertujuan menekan kompleksitas komputasi dengan mengurangi panjang sekuens input melalui pemangkasan token yang tidak berkontribusi signifikan terhadap output.	Pengelompokan token berdasarkan jarak fitur (Euclidean/Cosine) dan pemangkasan token dengan nilai <i>closeness-centrality</i> rendah tanpa pelatihan ulang.	Kelebihan: Efisien mengurangi biaya komputasi tanpa memerlukan proses pelatihan model tambahan. Kekurangan: Penurunan akurasi signifikan terjadi apabila pemangkasan token dilakukan secara berlebihan.	Menggunakan metrik pusat kedekatan (<i>closeness-centrality</i>) dan informasi lokasi untuk pemangkasan token.
2	Joint Token Pruning and Squeezing Towards More Aggressive Compression of Vision Transformers, Wei et al., 2023 [11]	Menangani masalah hilangnya informasi subjek dan konteks latar belakang yang krusial akibat strategi pemangkasan token konvensional yang terlalu agresif pada ViT. Strategi ini bertujuan mempertahankan fitur-fitur penting yang biasanya terbuang untuk menjaga akurasi prediksi.	Menggunakan modul TPS (<i>Joint Token Pruning & Squeezing</i>) untuk menyatukan fitur token terbuang ke dalam token utama melalui <i>nearest neighbour</i> dan <i>cosine similarity</i> .	Kelebihan: Akurasi tinggi meskipun dilakukan pengurangan komputasi secara agresif. Kekurangan: Kendala integrasi langsung pada operasi spasial terstruktur model <i>hybrid</i> .	Penelitian ini berfokus pada asimilasi fitur token yang dibuang ke dalam token utama untuk klasifikasi.
3	Superpixel Tokenization for Vision Transformers: Preserving Semantic Integrity in Visual Tokens,	<i>Grid-based tokenization</i> pada <i>Vision Transformer</i> (ViT) konvensional menggunakan <i>patch</i> persegi yang kaku, sehingga sering mencampur berbagai konsep visual dalam satu token. Hal ini berbeda dengan NLP yang memiliki integritas	SuiT (Superpixel-Tokenized Vision Transformer) dengan pipeline Pixel-level Embedding dan Superpixel-	Kelebihan: Menjaga integritas semantik token, mendukung <i>adaptive inference</i> , meningkatkan performa pada berbagai tugas	Fokus pada pengembangan <i>backbone</i> umum untuk klasifikasi dan segmentasi dengan mengganti seluruh modul tokenisasi.

No.	Judul dan Tahun	Pembahasan	Metode	Kelebihan dan Kekurangan	Perbedaan Penelitian
	Lew et al., 2024 [12]	semantik pada tiap tokennya. Penelitian ini membahas penggunaan <i>superpixel</i> untuk memastikan setiap token menangkap satu konsep visual yang utuh dan koheren.	aware Aggregation.	<i>downstream</i> , serta lebih robust terhadap data di luar distribusi Kekurangan: Saat ini masih terbatas pada arsitektur vanilla ViT dan memiliki kecenderungan overfit lebih cepat dibanding baseline DeiT	
4	Early smoke detection of forest fires based on SVM image segmentati-on, Ding Xiong & Lu Yan, 2019 [13]	Analisis pada level piksel tradisional sering kali tidak andal di lingkungan kompleks seperti hutan. Selain itu, terdapat masalah gangguan awan dan kabut yang memiliki karakteristik spektral serupa dengan asap, sehingga sering memicu alarm palsu.	<i>Superpixel</i> SLIC yang diikuti dengan algoritma penggabungan (<i>merging</i>) baru untuk mengatasi <i>over-segmentation</i> .	Kelebihan: Efisien, sederhana, serta mampu meminimalkan gangguan awan melalui deteksi cakrawala. Kekurangan: Akurasi terbatas karena hanya menggunakan fitur spektral tanpa fitur tekstur.	Penelitian ini menggunakan SVM untuk mendeteksi asap dan deteksi cakrawala untuk eliminasi awan.
5	Fire Detection and Localization Method Based on Deep Learning in Video Surveillance, Fang et al., 2022 [14]	Menangani kendala kecepatan deteksi yang lambat serta rendahnya akurasi dan presisi lokalisasi api pada sistem pengawasan video untuk keselamatan perkotaan.	Mengekstraksi keyframe menggunakan -n metode SuperPoint yang ditingkatkan (distorsi elastis), mendeteksi api via CNN, serta melokalisasi api melalui penggabungan an superpixel	Kelebihan: Akurasi deteksi mencapai 0.96 dengan lokalisasi api yang sangat presisi. Kekurangan: Kurang memperhatikan -n bingkai non-kunci sehingga memerlukan tambahan	Penelitian ini menerapkan strategi ekstraksi <i>keyframe</i> untuk meningkatkan kecepatan deteksi.

No.	Judul dan Tahun	Pembahasan	Metode	Kelebihan dan Kekurangan	Perbedaan Penelitian
			SLIC dan CNN.	algoritma pelacakan api.	
6	Experimentally Defined Convolutional Neural Network Architecture Variants for Non-Temporal Real-Time Fire Detection, Dunnings & Breckon, 2018 [15]	Penelitian ini menyelidiki deteksi otomatis wilayah piksel api dalam citra video atau diam secara <i>real-time</i> tanpa mengandalkan informasi temporal. Fokus utamanya adalah membuktikan bahwa arsitektur CNN dengan kompleksitas rendah tetap bisa mencapai akurasi maksimal.	Dua varian arsitektur CNN yang disederhanakan: FireNet (3 lapisan konvolusi) dan Inception V1-OnFire (3 modul <i>inception</i>)	Kelebihan: Performa cepat 17 fps, arsitektur ringan, dan akurasi deteksi tinggi. Kekurangan: Akurasi lokalisasi sedikit lebih rendah dibandingkan metode pembandingan lainnya.	Menggunakan arsitektur CNN yang disederhanakan secara eksperimental untuk memprioritaskan kecepatan <i>throughput</i> pada sistem otonom dibandingkan model kompleks tradisional.
7	Superpixel-Based Graph Convolutional Network for UAV Forest Fire Image Segmentation Mu et al., 2024 [16]	Mengatasi tantangan segmentasi api pada citra UAV yang memiliki latar belakang kompleks dan bentuk api tidak teratur melalui pendekatan graf.	SCGCN (<i>Superpixel-based Graph Convolutional Network</i>) yang menggabungkan SLIC untuk bentuk node, CNN untuk ekstrak fitur, dan operator GraphSAGE untuk klasifikasi node.	Kelebihan: Sangat efektif mengenali target api kecil dengan detail batas akurat. Kekurangan: Kesalahan pengenalan masih signifikan pada api yang tertutup vegetasi lebat.	SCGCN memetakan citra ke struktur graf untuk klasifikasi node.
8	Automatic Smoke Detection Based on SLIC-DBSCAN Enhanced Convolutional Neural Network, Dali Sheng et al., 2021 [17]	Menangani variabilitas besar pada fitur warna, tekstur, dan bentuk asap akibat kondisi lingkungan kompleks yang sering menghasilkan hasil deteksi tidak konsisten. Fokus penelitian adalah mengurangi interferensi latar belakang untuk meningkatkan akurasi pengenalan mode asap.	SLIC-DBSCAN yang diperkuat dengan <i>Convolutional Neural Network</i> (CNN). Citra disegmentasi menggunakan SLIC, dikelompokkan	Kelebihan: Mampu mereduksi gangguan latar belakang kompleks secara efektif dan akurat. Kekurangan: Pemilihan parameter DBSCAN cukup sulit	Penelitian ini menggunakan DBSCAN untuk pengelompokan klaster superpixel sebelum masuk ke CNN.

No.	Judul dan Tahun	Pembahasan	Metode	Kelebihan dan Kekurangan	Perbedaan Penelitian
			an berdasarkan kemiripan menggunakan algoritma DBSCAN, lalu diklasifikasi oleh model CNN.	dilakukan secara langsung pada citra.	
9	Fire detection in video surveillance using superpixel-based region proposal and ESE-ShuffleNet, Wang et al., 2023 [18]	Menangani tingginya biaya komputasi model CNN dalam pengawasan video <i>real-time</i> serta kesulitan membedakan api dari objek bergerak yang serupa. Penelitian ini bertujuan menyeimbangkan efisiensi dan akurasi deteksi dini kebakaran hutan.	SCMM (Cauchy Mixture Model) untuk lokalisasi wilayah mencurigakan melalui deskriptor Local Difference Binary (LDB). Tahap identifikasi menggunakan ESE-ShuffleNet.	Kelebihan: Arsitektur sangat ringan, akurasi mencapai 99.61%, dan efisien untuk pengawasan <i>real-time</i> . Kekurangan: Proses segmentasi masih berjalan di CPU sehingga belum teroptimasi penuh oleh GPU.	Menggunakan <i>superpixel</i> untuk <i>region proposal</i> berbasis gerakan dan klasifikasi ringan.
10	Early smoke and flame detection based on transformer, Xinzhi Wang et al., 2023 [20]	Menangani keterbatasan generalisasi dan kegagalan deteksi objek api/asap berukuran kecil pada metode konvensional. Penelitian ini berfokus pada penggunaan <i>self-attention</i> untuk menangkap hubungan spasial global guna mendeteksi kebakaran sejak dini.	DDFT (<i>Decoder-Free Fully Transformer</i>) yang terdiri dari <i>backbone</i> DOT untuk ekstraksi fitur 4 skala, modul SAE untuk fusi fitur, dan TAE untuk penyesuaian klasifikasi-regresi.	Kelebihan: Akurasi sangat tinggi pada objek kecil dan tangguh terhadap gangguan. Kekurangan: Deteksi asap kurang optimal dibandingkan api karena fiturnya cenderung samar.	Menggunakan struktur <i>decoder-free</i> untuk efisiensi prediksi <i>dense</i> satu level.

2.2 Landasan Teori

2.2.1 Kebakaran

Insiden kebakaran di Indonesia memiliki implikasi lingkungan, ekonomi, dan sosial yang signifikan, terutama diperburuk oleh aktivitas manusia dan kondisi iklim. Kebakaran yang paling sering terjadi di lahan gambut sangat rentan terbakar dan menyumbang emisi gas rumah kaca yang besar. Pada musim kebakaran 2019 saja, lebih dari 3,11 juta hektar lahan terbakar, menimbulkan kerugian besar bagi produktivitas pertanian dan perekonomian lokal [21]. Tak hanya itu saja, kebakaran juga dapat memberikan dampak ekonomi yang sangat besar, salah satu contoh kasusnya adalah pariwisata di daerah yang terkena dampak seperti Bromo mengalami penurunan 80% dalam jumlah penghuni hotel [22].

Meskipun berbagai upaya pencegahan dan mitigasi kebakaran telah diterapkan, tantangan terus-menerus yang ditimbulkan oleh perubahan iklim dan praktik penggunaan lahan, sehingga masih memerlukan upaya berkelanjutan untuk mengurangi risiko kebakaran dan dampak terkaitnya.

2.2.2 *Simple Linear Iterative Clustering* (SLIC)

SLIC adalah algoritma superpiksel berparameter tunggal yang mengelompokkan piksel dalam ruang lima dimensi, dua dimensi spasial (x,y), dan tiga dimensi warna CIELAB (L, a, b), dengan tujuan menghasilkan segmentasi kompak, seragam, dan mematuhi batas objek dengan efisien [7].

Cara kerja SLIC diawali dengan inisialisasi pusat kluster pada interval grid $S = \sqrt{N/K}$ (di mana N adalah jumlah piksel dan K jumlah superpiksel yang diinginkan), kemudian memindahkan setiap pusat ke piksel bergradasi paling rendah dalam *neighborhood* 3×3 agar terhindar dari tepi objek. Selanjutnya, setiap piksel hanya diperiksa terhadap pusat kluster dalam wilayah $2S \times 2S$ terdekat, menggunakan ukuran jarak

$$D_s = \sqrt{(l_k - l_i)^2 + (a_k - a_i)^2 + (b_k - b_i)^2} + \frac{m}{S} \sqrt{(x_k - x_i)^2 + (y_k - y_i)^2}$$

di mana m mengontrol kekompakan superpiksel. Langkah asosiasi piksel-kluster dan pembaruan pusat diulang hingga mencapai konvergensi, lalu konektivitas ditegakkan dengan menyambung segmen terpisah ke kluster tetangga terbesar.

Output SLIC adalah peta indeks superpiksel [$1 \times H \times W$] dan, secara visual, kumpulan segmen dipenuhi piksel yang seragam dalam warna dan bentuk, dengan ukuran hampir sama serta mematuhi kontur objek.




Gambar 2. 1 Ilustrasi Luaran SLIC

SLIC umum diterapkan sebagai *pre-processing* untuk berbagai tugas seperti segmentasi semantik, estimasi kedalaman, ekstraksi fitur lokal (SIFT), pelacakan objek, dan model graf (CRF) yang mendapat keuntungan besar dari superpixel untuk mempercepat komputasi dan meningkatkan kualitas hasil.

2.2.3 Deteksi Objek

Deteksi objek adalah teknik penglihatan komputer yang mengidentifikasi dan melokalisasi objek dalam gambar atau aliran video. Ini tidak hanya menentukan lokasi objek tetapi juga mengklasifikasikannya ke dalam kelas tertentu [23], contoh kelas tertentu adalah manusia, hewan, dan kendaraan. Deteksi objek banyak diaplikasikan di bidang-bidang seperti pengambilan gambar, keamanan, sistem kendaraan otomatis, dan pengawasan [24]. Cara kerja deteksi objek adalah dengan melokalisasi setiap objek di dalam citra menggunakan kotak pembatas (bounding box) seperti dapat dilihat pada Gambar 2.2, sehingga algoritma dapat dilatih untuk mengenali dan membedakan objek-objek yang telah dilabeli.



Gambar 2. 2 Contoh Luaran Deteksi Objek

2.2.4 Detection Transformer (DETR)


Detection Transformer adalah model deteksi objek yang menyederhanakan seluruh pipeline tradisional dengan memandang deteksi sebagai masalah prediksi himpunan langsung (set prediction), menghilangkan Non-Maximum Suppression (NMS) tradisional. DETR memanfaatkan arsitektur encoder-decoder berbasis transformer yang dipadukan dengan backbone CNN konvensional untuk mengekstraksi peta fitur 2D dari citra input. Alih-alih menghasilkan ratusan ribu proposal atau jangkar (*anchors*), DETR mengeluarkan satu set terbatas (*object queries*) yang dipelajari, di mana setiap *query* diharapkan memprediksi satu *bounding box* dan label kelas secara paralel.

Pada tahap backbone, sebuah CNN (misalnya ResNet-50) memproses citra berukuran $H_0 \times W_0$ menjadi peta fitur berdimensi $C \times H \times W_C$. Peta fitur ini kemudian direduksi dimensinya melalui konvolusi 1×1 menjadi $d \times H \times W$, lalu diratakan menjadi urutan token berdimensi d sepanjang HW elemen, dan ditambahkan dengan *positional encoding sine-cosine* untuk mempertahankan informasi spasial. Token ini memasuki encoder transformer, yang terdiri dari beberapa lapisan *self-attention* dan *feed-forward network*, sehingga setiap posisi fitur dapat melihat konteks global seluruh gambar.

Bagian decoder transformer menerima dua masukan, memorinya dari encoder dan sekumpulan *object queries*, dan *positional embeddings* yang dipelajari

sebanyak N slot (e.g. $N=100$). Setiap query saling berinteraksi melalui *self-attention* dan *cross-attention* dengan output encoder, memerlukan hanya satu langkah non-autoregresif untuk memprediksi (x,y,w,h) dan distribusi kelas (termasuk kelas “no object”). Hasilnya adalah N prediksi kotak yang mewakili set deteksi akhir, tanpa perlu NMS karena duplikasi sudah dicegah oleh strategi *bipartite matching* yang unik dalam fungsi loss.

Fungsi loss DETR menggabungkan *Hungarian matching loss* dan *bounding box loss* (kombinasi L1 dan *generalized IoU*). Pertama, *bipartite matching* menggunakan *Hungarian algorithm* memastikan setiap *ground-truth* dipetakan ke satu prediksi. Kedua, setelah penugasan, dihitung loss klasifikasi (cross-entropy) dan loss regresi kotak (L1 + *GIoU*) hanya untuk pasangan yang dipilih [8].



Gambar 2. 3 Arsitektur DETR Pada Proses Training

2.2.5 Token Pruning

Token pruning (pemangkasan token) merupakan salah satu teknik kompresi model yang berfokus pada pengurangan langsung panjang sekuens input dengan cara menghapus atau mengabaikan sebagian token yang dinilai kurang informatif. Pada arsitektur berbasis transformer di bidang pemrosesan bahasa alami maupun *computer vision*, mekanisme *self-attention* mengharuskan setiap token berinteraksi dengan seluruh token lainnya, sehingga menimbulkan kompleksitas komputasi dan memori yang berskala kuadratik terhadap panjang sekuens [25][26].

Pemangkasan token didasari oleh intuisi bahwa tidak semua token dalam sebuah sekuens (seperti area latar belakang pada citra atau kata yang tidak bermakna pada teks) memiliki kontribusi yang menguntungkan terhadap performa prediksi akhir [25]. Dengan membuang token yang berlebihan atau kurang penting secara progresif pada setiap lapisan *transformer*, model dapat mengurangi panjang sekuens yang diproses pada lapisan berikutnya, sehingga secara signifikan

mempercepat proses inferensi dan mengurangi jejak memori tanpa harus menggunakan perangkat keras khusus [26].

Dalam pelaksanaannya, penentuan token yang akan dipangkas memerlukan metrik evaluasi tingkat kepentingan (*importance score*) dari setiap token. Salah satu pendekatan yang paling umum digunakan adalah dengan memanfaatkan probabilitas atensi (*attention probabilities*) yang dihasilkan oleh mekanisme *multi-head attention* [25][26]. Token yang menerima akumulasi bobot atensi yang besar dari token-token lainnya di berbagai *head* (*attention heads*) dianggap mengandung informasi yang krusial.

2.2.6 Precision

Precision adalah metrik yang menunjukkan seberapa banyak prediksi positif benar dari semua prediksi positif yang dilakukan oleh model.

$$Precision = \frac{TP}{TP + FP}$$

di mana:

TP (*True Positive*): jumlah kotak prediksi yang benar mengandung objek.

FP (*False Positive*): jumlah kotak prediksi yang salah.

2.2.7 Recall

Recall mengukur kemampuan model dalam menemukan semua contoh positif. Recall dihitung sebagai rasio prediksi benar positif terhadap total *ground-truth* positif.

$$Recall = \frac{TP}{FN + TP}$$

di mana:

TP (*True Positive*): jumlah deteksi yang benar,

FN (*False Negative*): jumlah objek yang terlewat tidak terdeteksi.

2.2.8 Intersection over Union (IoU)

IoU mengukur derajat overlap antara kotak prediksi dan ground-truth, dinyatakan sebagai rasio area irisan terhadap area gabungan.

$$IoU = \frac{area(BBoxpred \cap BBoxgt)}{area(BBoxpred \cup BBoxgt)}$$

2.2.9 Average Precision

Average Precision mengukur area di bawah kurva precision–recall untuk satu kelas objek. AP dihitung sebagai rata-rata tertimbang dari nilai precision pada recall yang berbeda.

$$AP = \sum_{n=1}^N (R_n - R_{n-1})P_n$$

di mana:

P_n dan R_n : precision dan recall pada threshold ke- n ,

N : jumlah titik pada kurva precision–recall.

2.2.10 Mean Average Precision (mAP)

mAP adalah rata-rata nilai Average Precision (AP) pada berbagai threshold IoU untuk seluruh kelas. AP sendiri merupakan luas di bawah kurva precision–recall.

$$mAP = \frac{1}{T} \sum_{t=1}^T AP(IoU = t)$$

di mana T adalah jumlah threshold yang digunakan.

BAB 3

METODE PENELITIAN

3.1 Subjek dan Objek Penelitian

Subjek penelitian ini adalah dataset dari *Flame and Smoke Detection Dataset* (FASDD) kategori *Computer Vision* (FASDD_CV) yang berisi kumpulan gambar peristiwa kebakaran di seluruh dunia melalui berbagai jenis penangkapan gambar. Sedangkan objek penelitiannya adalah kinerja metode *superpixel* dan DETR.

3.2 Alat dan Bahan Penelitian

3.2.1 Alat Penelitian

Alat yang digunakan pada penelitian ini adalah:


1. Perangkat Keras:
 - a. Processor AMD Ryzen 5 7535HS
 - b. RAM 16 GB
 - c. GPU Radeon Graphics
 - d. Server GPU NVidia GeForce RTX 4090
2. Perangkat Lunak:
 - a. *Code Editor*: Visual Studio Code
 - b. *Text Editor*: Microsoft Office
 - c. *Version Control*: Git dan Github

3.2.2 Bahan Penelitian

Bahan Penelitian yang digunakan adalah data gambar peristiwa kebakaran dari berbagai sosial media, *open-access datasets*, lukisan, dan *web crawling* yang terdapat dalam *Flame and Smoke Detection Dataset* (FASDD) kategori *Computer Vision* (FASDD_CV) berisi 95.314 citra dari tangkapan kamera standar.

3.3 Alur Penelitian

Penelitian ini akan mengikuti alur kerja terstruktur yang disusun secara sistematis agar setiap tahapan berjalan berurutan dan saling mendukung. Rangkaian proses tersebut dijelaskan melalui diagram alir pada Gambar 3. 1.



Gambar 3. 1 Diagram Alur Penelitian

3.3.1 Identifikasi Masalah

Tahap identifikasi masalah merupakan fondasi utama dalam penelitian ini, di mana peneliti menguraikan fenomena kebakaran, terutama deteksi visual nyala api dan asap, dengan melakukan identifikasi masalah ini peneliti bisa mendapatkan gambaran utuh mengenai permasalahan dari deteksi kebakaran serta tujuan dan manfaat dari penelitian ini.

3.3.2 Studi Literatur

Pada tahap ini, peneliti meninjau dan menganalisis karya ilmiah terdahulu yang relevan dengan deteksi objek, metode superpixel, dan model berbasis transformer khususnya DETR untuk memahami kemajuan, kelebihan, serta keterbatasan metode yang ada. Dengan menganalisis beragam pendekatan mulai dari kombinasi *superpixel*-CNN [14][15], variational autoencoder *superpixel* [27], hingga tokenisasi *superpixel* pada Vision Transformer [12], sehingga penelitian ini dapat mengidentifikasi celah riset dengan baik. Proses studi literatur ini penting sebagai landasan teoritis, metodologis, dan memastikan bahwa solusi yang dikembangkan memenuhi kebutuhan aktual dalam masalah deteksi kebakaran.


3.3.3 Pengumpulan Data

Penelitian ini memanfaatkan data *Flame and Smoke Detection Dataset* (FASDD) sebagai sumber data sekunder [28]. FASDD terdiri atas 120.634 citra

heterogen yang mewakili berbagai skenario kebakaran, terbagi menjadi tiga sub-dataset:

- FASDD_CV (95.314 citra) dari tangkapan kamera standar,
- FASDD_UAV (25.097 citra) dari citra udara tanpa awak,
- FASDD_RS (2.223 citra) dari citra satelit resolusi menengah.

Secara keseluruhan terdapat 113.154 objek api dan 73.072 objek asap, dengan anotasi *bounding-box* tersedia dalam format VOC, COCO, YOLO, dan TDML. Gambar-gambar ini mencakup beragam kondisi, perbedaan sudut pandang, rentang resolusi dan ukuran, variasi iluminasi seperti siang dan malam, serta latar belakang kompleks (hutan, perkotaan, awan, kabut). Pendistribusian ke dalam set pelatihan, validasi, dan pengujian mengikuti proporsi 50%:30%:20% untuk masing-masing sub-dataset.



Gambar 3. 2 Sampel Dataset FASDD

3.3.4 Preprocessing

Pada tahap ini setiap masukan citra diproses untuk mendapatkan fitur superpixel menggunakan algoritma *Simple Linear Iterative Clustering* (SLIC). SLIC membagi gambar menjadi segmen-segmen homogen berdasarkan kemiripan warna (CIELAB) dan kedekatan spasial, sehingga setiap superpixel merepresentasikan wilayah semantik lokal. Hasil segmentasi ini berupa peta label *superpixel* $[1 \times H \times W]$, yang selanjutnya disesuaikan ukurannya dengan *feature map* input menggunakan interpolasi. Dengan peta label tersebut, fitur spasial dan tekstur piksel-piksel dalam setiap superpixel di-*aggregate* (misalnya *max* atau *mean*

pooling), membentuk token *superpixel* berdimensi tetap $[B, N_{\text{spix}}, C]$. Token-token inilah yang kemudian menjadi masukan encoder menggantikan grid patch sebelum masuk ke tahap pemodelan DETR.

3.3.5 Pemodelan DETR

Tahap pemodelan menggabungkan representasi *superpixel* dengan mekanisme transformer pada DETR. Secara konseptual, token *superpixel* yang telah mengandung informasi spasial dan tekstur lokal dimasukkan ke dalam transformer encoder, yang bertugas menyatukan konteks global antar *superpixel*.

Luaran encoder selanjutnya diproses oleh transformer decoder yang diinisialisasi dengan sekumpulan *query* untuk melakukan cross-attention antara fitur *superpixel* dan *query*. Tiap *query* kemudian memproyeksikan dua skor klasifikasi objek (api, asap, atau latar belakang), dan parameter *bounding box* (x, y, w, h). Dengan menggunakan *loss function Hungarian matching* dengan kombinasi klasifikasi dan regresi kotak, seluruh rangkaian mulai dari tokenisasi *superpixel* hingga prediksi *bounding box* dilatih secara koheren. Pendekatan ini mengeliminasi kebutuhan *proposal region* maupun proses *Non-Maximum Suppression*, sehingga model dapat langsung mendeteksi dan menandai letak api dan asap secara cepat.

3.3.6 Evaluasi Kinerja Model

Evaluasi kinerja model pada penelitian ini dibagi menjadi dua pendekatan utama yakni kuantitatif dan kualitatif agar diperoleh gambaran menyeluruh tentang performa kinerja metode *superpixel*-DETR ini.

a) Evaluasi Hasil Kuantitatif

Pada pendekatan ini, performa model diukur secara objektif menggunakan berbagai metrik deteksi objek. *Precision* untuk menilai seberapa akurat kotak prediksi model memperdiksi objek api/asap, *Recall* untuk mengevaluasi kemampuan model menemukan seluruh objek positif di gambar, *Average Precision* (AP) per kelas api dan asap untuk mengetahui *trade-off precision* dan *recall*, *Mean Average Precision* (mAP) sebagai ringkasan performa keseluruhan. Metrik-metrik ini memberikan wawasan numerik tentang akurasi, kelengkapan, dan konsistensi deteksi model pada keseluruhan isi dataset (validasi dan uji).

b) Evaluasi Hasil Kualitatif

Pendekatan kualitatif meliputi tinjauan visual atas *bounding-box* yang dihasilkan pada data uji. Dengan memeriksa langsung hasil inferensi, peneliti dapat mengidentifikasi kekuatan model misalnya ketepatan batas pada kobaran api kecil atau asap tipis serta kelemahan, seperti false positive pada latar berawan atau false negative pada titik api tersembunyi. Analisis ini penting untuk memahami konteks dan kondisi nyata model.

3.3.7 Analisis Hasil dan Kesimpulan

Tahap analisis hasil merupakan langkah penting setelah proses evaluasi dilakukan, di mana peneliti akan mengkaji dan menafsirkan kinerja model berdasarkan hasil pengujian kuantitatif maupun kualitatif. Pada tahap ini, hasil evaluasi seperti nilai *precision*, *recall*, *average precision* (AP), serta *mean average precision* (mAP) akan dianalisis untuk mengetahui seberapa efektif model dalam mendeteksi objek api dan asap secara akurat. Selain itu, analisis evaluasi kualitatif dilakukan untuk mengidentifikasi kekuatan dan kelemahan model pada kondisi nyata, seperti terhadap objek kecil, tumpang tindih, atau pada latar belakang kompleks.

Setelah proses analisis selesai, peneliti menyusun kesimpulan yang merangkum keberhasilan dan pencapaian utama dari penelitian ini, termasuk efektivitas integrasi metode *superpixel* dan DETR dalam mendeteksi objek kebakaran. Kesimpulan juga mencakup penilaian terhadap apakah tujuan penelitian telah tercapai. Berdasarkan temuan tersebut, peneliti juga memberikan rekomendasi untuk pengembangan lebih lanjut dalam berbagai aspek seperti dataset, *preprocessing*, ataupun pemodelan.

DAFTAR PUSTAKA

- [1] D. M. J. S. Bowman, C. A. Kolden, J. T. Abatzoglou, F. H. Johnston, G. R. van der Werf, and M. Flannigan, "Vegetation fires in the Anthropocene," *Nat. Rev. Earth Environ.*, vol. 1, no. 10, pp. 500–515, Aug. 2020, doi: 10.1038/s43017-020-0085-3.
- [2] Y. ZHENG, Z. HUANG, B. CHEN, C. WANG, and Y. ZHANG, "Improved Real-Time Smoke Detection Model Based on RT-DETR," *International Journal of Advanced Computer Science and Applications*, vol. 15, no. 11, 2024, doi: 10.14569/IJACSA.2024.0151138.
- [3] M. L. Boughouas, Y. Kissoum, S. Mazouzi, and W. Boussouf, "Towards an Efficient Fog-Based Forest Fire Management Architecture," *International Journal of Organizational and Collective Intelligence*, vol. 13, no. 1, pp. 1–20, Feb. 2023, doi: 10.4018/IJOCL.317137.
- [4] A. Gaur *et al.*, "Fire Sensing Technologies: A Review," *IEEE Sens. J.*, vol. 19, no. 9, pp. 3191–3202, May 2019, doi: 10.1109/JSEN.2019.2894665.
- [5] Y. Valikhujaev, A. Abdusalomov, and Y. I. Cho, "Automatic Fire and Smoke Detection Method for Surveillance Systems Based on Dilated CNNs," *Atmosphere (Basel)*, vol. 11, no. 11, p. 1241, Nov. 2020, doi: 10.3390/atmos11111241.
- [6] Y. Amit, P. Felzenszwalb, and R. Girshick, "Object Detection," in *Computer Vision*, Cham: Springer International Publishing, 2021, pp. 875–883. doi: 10.1007/978-3-030-63416-2_660.
- [7] R. Achanta, A. Shaji, K. Smith, A. Lucchi, P. Fua, and S. Süsstrunk, "SLIC superpixels," 2010. [Online]. Available: <https://www.researchgate.net/publication/44234783>
- [8] N. Carion, F. Massa, G. Synnaeve, N. Usunier, A. Kirillov, and S. Zagoruyko, "End-to-End Object Detection with Transformers," May 2020, [Online]. Available: <http://arxiv.org/abs/2005.12872>
- [9] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, "You Only Look Once: Unified, Real-Time Object Detection," Jun. 2015, [Online]. Available: <http://arxiv.org/abs/1506.02640>
- [10] Y. Yang, X. Hu, and Y. Zhou, "Adaptive Token Pruning for Vision Transformer," in *2024 5th International Symposium on Computer Engineering and Intelligent Communications, ISCEIC 2024*, Institute

of Electrical and Electronics Engineers Inc., 2024, pp. 586–589. doi: 10.1109/ISCEIC63613.2024.10810243.

- [11] S. Wei, T. Ye, S. Zhang, Y. Tang, and J. Liang, “Joint Token Pruning and Squeezing Towards More Aggressive Compression of Vision Transformers,” in *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, IEEE Computer Society, 2023, pp. 2092–2101. doi: 10.1109/CVPR52729.2023.00208.
- [12] J. Lew *et al.*, “Superpixel Tokenization for Vision Transformers: Preserving Semantic Integrity in Visual Tokens,” Dec. 2024, [Online]. Available: <http://arxiv.org/abs/2412.04680>
- [13] D. Xiong and L. Yan, “Early smoke detection of forest fires based on SVM image segmentation,” *J. For. Sci. (Prague)*., vol. 65, no. 4, pp. 150–159, Apr. 2019, doi: 10.17221/82/2018-JFS.
- [14] Q. S. Fang, Z. Peng, and P. Yan, “Fire Detection and Localization Method Based on Deep Learning in Video Surveillance,” *J. Phys. Conf. Ser.*, vol. 2278, no. 1, p. 012024, May 2022, doi: 10.1088/1742-6596/2278/1/012024.
- [15] A. J. Dunning and T. P. Breckon, “EXPERIMENTALLY DEFINED CONVOLUTIONAL NEURAL NETWORK ARCHITECTURE VARIANTS FOR NON-TEMPORAL REAL-TIME FIRE DETECTION.”
- [16] Y. Mu, L. Ou, W. Chen, T. Liu, and D. Gao, “Superpixel-Based Graph Convolutional Network for UAV Forest Fire Image Segmentation,” *Drones*, vol. 8, no. 4, p. 142, Apr. 2024, doi: 10.3390/drones8040142.
- [17] D. Sheng, J. Deng, and J. Xiang, “Automatic Smoke Detection Based on SLIC-DBSCAN Enhanced Convolutional Neural Network,” *IEEE Access*, vol. 9, pp. 63933–63942, 2021, doi: 10.1109/ACCESS.2021.3075731.
- [18] P. Wang, J. Zhang, and H. Zhu, “Fire detection in video surveillance using superpixel-based region proposal and ESE-ShuffleNet,” *Multimed. Tools Appl.*, vol. 82, no. 9, pp. 13045–13072, Apr. 2023, doi: 10.1007/s11042-021-11261-9.
- [19] X. Wang, M. Li, M. Gao, Q. Liu, Z. Li, and L. Kou, “Early smoke and flame detection based on transformer,” *Journal of Safety Science and Resilience*, vol. 4, no. 3, pp. 294–304, Sep. 2023, doi: 10.1016/j.jnlssr.2023.06.002.
- [20] X. Wang, M. Li, M. Gao, Q. Liu, Z. Li, and L. Kou, “Early smoke and flame detection based on transformer,” *Journal of Safety Science and*

- Resilience*, vol. 4, no. 3, pp. 294–304, Sep. 2023, doi: 10.1016/j.jnlssr.2023.06.002.
- [21] D. Gaveau, A. Descals, M. Salim, D. Sheil, and S. Sloan, “Refined burned-area mapping protocol using Sentinel-2 data increases estimate of 2019 Indonesian burning,” May 04, 2021. doi: 10.5194/essd-2021-113.
 - [22] S. Suhardono *et al.*, “Human activities and forest fires in Indonesia: An analysis of the Bromo incident and implications for conservation tourism,” *Trees, Forests and People*, vol. 15, p. 100509, Mar. 2024, doi: 10.1016/j.tfp.2024.100509.
 - [23] A. Bondade, S. Ghate, C. Bhaisewar, P. Chaure, and A. Gaulkar, “Object Detection Using Machine Learning (Missing Object Alert),” *International Journal of Computational and Electronic Aspects in Engineering*, vol. 4, no. 3, pp. 63–68, Aug. 2023, doi: 10.26706/ijceae.4.3.20230902.
 - [24] S. T. Santhanalakshmi and R. Khilar, “An Analysis Study on the Different Approaches of Deep Learning for Object Recognition and Detection,” in *2023 International Conference on Circuit Power and Computing Technologies (ICCPCT)*, IEEE, Aug. 2023, pp. 101–108. doi: 10.1109/ICCPCT58313.2023.10245768.
 - [25] J. Yun, M. Kim, and Y. Kim, “Focus on the Core: Efficient Attention via Pruned Token Compression for Document Classification,” Jun. 2024, doi: 10.18653/v1/2023.findings-emnlp.909.
 - [26] S. Kim *et al.*, “Learned Token Pruning for Transformers,” in *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, Association for Computing Machinery, Aug. 2022, pp. 784–794. doi: 10.1145/3534678.3539260.
 - [27] B. Li, Z. Sun, and Y. Guo, “SuperVAE: Superpixelwise Variational Autoencoder for Salient Object Detection.” [Online]. Available: www.aaai.org
 - [28] M. Wang, P. Yue, L. Jiang, D. Yu, T. Tuo, and J. Li, “An open flame and smoke detection dataset for deep learning in remote sensing based fire detection,” *Geo-spatial Information Science*, pp. 1–16, Jun. 2024, doi: 10.1080/10095020.2024.2347922.